

Zeit- und Ortsabhängige Prädiktion von Umweltzuständen für die Vorhersage von Personen- Auftrittswahrscheinlichkeiten



Studienarbeit Januar/2021

Adrian Kleimeier
Matrikelnummer 3111950

Hannover, 15. Januar 2021

Erstprüfer Prof. Dr.-Ing. Tobias Ortmaier
Zweitprüfer Prof. Dr.-Ing. Vorname Nachname
Betreuer Marvin Stüde, M.Sc.

Ich, Adrian Kleimeier, versichere hiermit, dass die vorliegende Arbeit selbstständig verfasst wurde, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt wurden, alle Stellen der Arbeit, die wörtlich oder sinngemäß aus anderen Quellen übernommen wurden, als solche kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen hat.

Hannover, 15. Januar 2021

(Adrian Kleimeier)

Zeit- und Ortsabhängige Prädiktion von Umweltzuständen für die Vorhersage von Personen- Auftrittswahrscheinlichkeiten

Adrian Kleimeier, Matrikelnummer 3111950

Allgemeines:

Am Campus Maschinenbau in Garbsen wird der Serviceroboter Sobi entwickelt, welcher Studenten und Besuchern Informationen bereitstellen und bei der Orientierung auf dem Campusgelände helfen soll. Um eine möglichst hohe Rate an Mensch-Roboter-Interaktionen zu erreichen, muss der Roboter Informationen über das zeit- und ortsabhängige Personenaufkommen auf dem Campusgelände zur Verfügung haben. Diese Informationen können für die Bahnplanung verwendet werden, um die voraussichtlich benötigte Zeit einer Kontaktaufnahme mit einem Menschen zu minimieren. In der Forschung existieren Modelle zur Prädiktion dieser Umweltzustände auf Basis von binären sowie quantitativen Darstellungen.

Aufgabe:

Im Rahmen dieser Arbeit soll eine Methodik entwickelt und für den spezifischen Anwendungsfall am Maschinenbau-Campus Garbsen angepasst werden. Als Ansatz einer solchen Methodik kann das FreMEn- Modell dienen. Die Grundidee der Methode ist die Transformation binärer zeit- und ortsabhängiger Darstellungen elementarer Umweltzustände (in diesem Fall die Anwesenheit bzw. Nichtanwesenheit von Personen) in den Frequenzbereich mittels der Fouriertransformation. In diesem werden die dominantesten Frequenzen identifiziert und auf Basis dieser eine inverse Fouriertransformation durchgeführt. Als Ergebnis erhält man eine Funktion, welche die Wahrscheinlichkeit für die zukünftigen Umweltzustände angibt.

Im Rahmen dieser Arbeit ergeben sich insbesondere die folgenden Aufgabenpunkte:

- Literaturrecherche über Methoden der binären sowie quantitativen Darstellung von Umweltzuständen
- Entwicklung einer Methodik und Anpassung an den vorliegenden Anwendungsfall
- Überprüfung der Modellgüte bei unterschiedlichen Periodendauern mittels eines Testdatensatzes
- Überprüfung der Modellgüte bei unterschiedlichen Periodendauern mittels eines Simulations- Datensatzes oder eines Langzeitdatensatzes
- Ermittlung weiterführender Fragestellungen zur Optimierung der kurzfristigen Vorhersagegüte des Modells

Die Bearbeitungszeit beträgt 300 Stunden.

Ausgabe der Aufgabenstellung: 15.06.2020
Abgabe der Arbeit spätestens 15.01.2021
am:
Erstprüfer:
Zweitprüfer:
Betreuer: M. Sc. Marvin Stüde

Kurzfassung

In der Kurzfassung sollen auf maximal einer Seite die Aufgabe, die verwendeten Methoden sowie die erzielten Erkenntnisse dargestellt werden. Ein Leser soll idealerweise anhand der Kurzfassung abschätzen können, ob die Arbeit für ihn brauchbare Informationen enthält.

Inhaltsverzeichnis

1 Einleitung	1
2 Stand der Technik	2
2.1 Mathematische Grundlagen	2
2.1.1 Fourierreihen und Fouriertransformation	2
2.1.2 Diskrete Fouriertransformation	4
2.1.3 Wahrscheinlichkeitsverteilungen	5
2.1.4 Beschreibung binärer Zustandsmodelle	7
2.1.5 Beschreibung quantitativer Zustandsmodelle	14
3 Methodik	18
3.1 Binäre Zustandsmodelle	18
3.1.1 Messdatenermittlung eines Belegtheitsgitters	18
3.1.2 Verarbeitung der Messdaten Client-seitig	22
3.1.3 Verarbeitung der Messdaten Server-seitig	22
3.2 Quantitative Zustandsmodelle	25
3.2.1 Messdatenermittlung eines Occupancy-Grids	25
3.2.2 Verarbeitung der Messdaten Client-seitig	25
3.2.3 Verarbeitung der Messdaten Server-seitig	25
4 Evaluation	27
4.1 Datensätze	27
4.2 Beschreibung der Fehlermaße	27
4.2.1 Fehlermaße binäres Modell	27
4.2.2 Fehlermaße quantitatives Modell	28
4.3 Binäres Modell	29
4.3.1 Einfluss der Intervalldauer	29
4.4 Quantitatives Modell	32
4.4.1 Einfluss der Intervalldauer	32
4.5 Einfluss der Zellengröße (nur für uol-Datensatz)	37
4.6 Einfluss der Periodendauer	37

5 Tipps zur Erstellung der Arbeit	39
5.1 Darstellung von Gleichungen	39
5.2 Darstellung von Grafiken	40
5.3 Software	40
5.3.1 Matlab, Corel	40
5.3.2 LaTeX	41
5.4 Literaturverweise	41
5.5 Eigene Befehle in LaTeX	41
6 Betreuer- und/oder projektspezifische Anmerkungen	42
7 (Beispielkapitel) Robotersysteme	43
7.1 PR2	43
7.2 ROS	44
Anhang	45
Literatur	46

Nomenklatur

Selten bzw. nur abschnittsweise verwendete Symbole und Formelzeichen sowie abweichende Bedeutungen werden ausschließlich im Text beschrieben. **Achtung: Bitte bei Erstellung der Arbeit die unten stehenden Beispiele löschen und nur Abkürzungen/Zeichen aufführen, die verwendet werden!**

Allgemeine Konventionen

Skalar	Klein- oder Großbuchstabe (kursiv): a, A
Vektor	Kleinbuchstabe (fett und kursiv): \boldsymbol{a}
Matrix	Großbuchstabe (fett und kursiv): \boldsymbol{A}
Punkt	Klein- oder Großbuchstabe: a, A
Körper	Großbuchstabe (fett): \mathbf{A}

Lateinische Buchstaben

A	Querschnittsfläche
A_S	Spanungsquerschnitt

und so weiter

Griechische Buchstaben

α, β, γ	Rotationswinkel um die x -, y - und z -Achse
-------------------------	--

Koordinatensysteme

$(KS)_i$	Koordinatensystem i
$(KS)_0$	ortsfestes Inertialkoordinatensystem

Abkürzungen

AR	erweiterte Realität (Augmented Reality)
CNC	rechnergestützte numerische Steuerung (Computerized Numerical Control)
MHH	Medizinische Hochschule Hannover

1 Einleitung

Einleitungstext



zu ...

2 Stand der Technik

In diesem Kapitel wird der aktuelle Stand der Technik präsentiert. In Abschnitt 2.1 wird auf die, zum Verständnis der in dieser Arbeit verwendeten Methoden, mathematischen Grundlagen eingegangen. Neben Fourierreihen (Abschnitt 2.1.1) und der diskreten Fouriertransformation (Abschnitt 2.1.2) wird hier außerdem auf die Thematik der Wahrscheinlichkeitsverteilungen eingegangen. Aufgeführt wird neben der Binomialverteilung auch die Poissonverteilung (Abschnitt 2.1.3).

Darauf folgend werden Ergebnisse der Wissenschaft zur Beschreibung von Zustandsmodellen vorgestellt. Während Abschnitt 2.1.4 sich mit der Beschreibung binärer Zustandsmodelle beschäftigt, legt Abschnitt 2.1.5 den Fokus auf die Beschreibung quantitativer Zustandsmodelle.

2.1 Mathematische Grundlagen

2.1.1 Fourierreihen und Fouriertransformation

Periodische Signale tauchen in vielen Bereichen der Physik und Technik auf. Ein Signal bezeichnet hierbei eine Funktion, welche eine physikalische Größe in Abhängigkeit von der Zeit, dem Ort, oder einer anderen Variablen darstellt.^{Quelle} Betrachtet man periodische Funktionen, so zeichnen sich diese durch ihre Periodendauer T aus. Eine Periode enthält dabei die gesamte Information des Signals, so dass gilt: $f(t) = f(t + T)$. Jede periodische Funktion kann durch eine Überlagerung von Sinus- und Kosinusfunktionen unterschiedlicher Periodendauern $2\pi n$ approximiert werden. Dargestellt werden kann dies durch eine Fourierreihe,

$$f(t) = \frac{a_0}{2} + \sum_{n=0}^{N} [a_n \cos(n\omega t) + b_n \sin(n\omega t)], \quad (2.1)$$

Hierbei bezeichnet $\omega = 2\pi/T$ die Kreisfrequenz der Grundschwingung. Die Konstanten $a_0, a_1 \dots a_n$ werden als gerade Fourierkoeffizienten bezeichnet, $b_1, b_2 \dots b_n$ hingegen als ungerade Fourierkoeffizienten. Dies leitet sich daraus ab, dass der Cosinus eine gerade und der Sinus eine ungerade Funktion ist.

Des Weiteren lässt sich eine Fourierreihe durch Sinusfunktionen mit unterschiedlichen Alternativ?

Da dies der einzige Abschnitt des Kapitels ist, kann ich die anderen Abschnitte nicht machen.

Amplituden und Phasen beschreiben. Die Fourierreihe lautet dann:

$$f(t) = \rho_0 + \sum_{n=1}^N \rho_n \sin(n\omega t + \varphi_n) . \quad (2.2)$$

Die Grundfrequenz des Signals lautet $f_1 = 1/T = \omega/2\pi$. Die weiteren Sinus- und Kosinusfunktionen der Fourierreihe besitzen Frequenzen $f_n = n f_1$, also ganzzahlige Vielfache der Grundfrequenz. Die Umrechnung von Gleichung 2.1 nach Gleichung 2.2 erfolgt mithilfe der Definitionen:

$$\rho_0 = \frac{a_0}{2}, \quad (2.3)$$

$$\rho_n = \sqrt{a_n^2 + b_n^2}, \quad (2.4)$$

$$\varphi_n = \arctan\left(\frac{a_n}{b_n}\right), \quad (2.5)$$

Mit ρ_0 wird hierbei der Gleichanteil des Signals bezeichnet, ρ_n steht für die Amplitude der n -ten Frequenz und φ_n für die Phasenverschiebung der n -ten Frequenz. Ein Signal kann also durch sein Kosinus- und Sinusspektrum sowie durch sein Amplitudenspektrum charakterisiert werden. Grafisch veranschaulicht wird die Fourierreihe durch Bild 2.1. In der linken Grafik eingezeichnet ist ein periodisches Signal mit der Periodendauer T , für welches $f(t) = f(t + T)$ gilt. In den beiden rechten Grafiken finden sich die das Gesamtsignal definierenden Frequenzen, mit ihren zugehörigen Amplituden ρ und Phasenversetzungen φ .

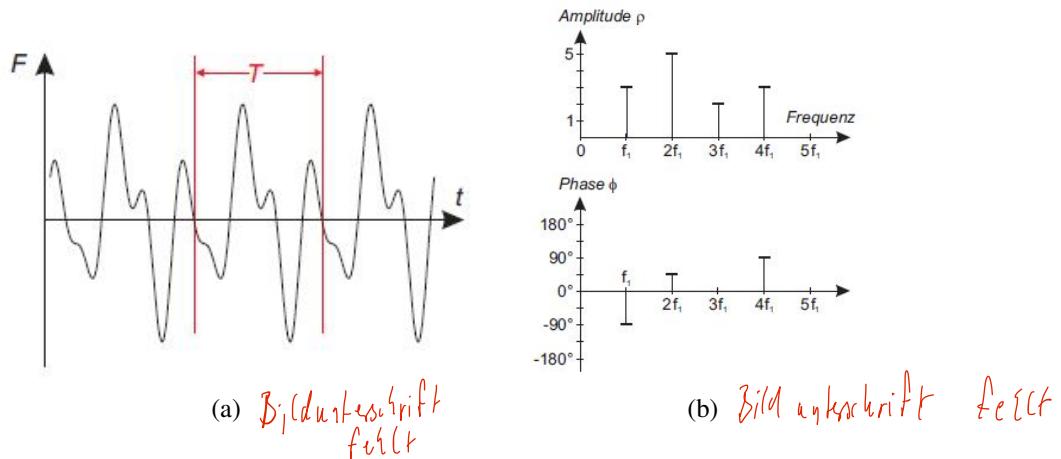


Bild 2.1: Periodisches Signal mit zugehörigem Amplituden- und Phasenspektrum [EKS06]

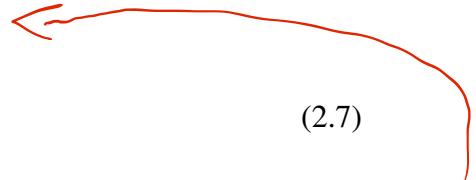
Funktion $f(t)$

Die Fouriertransformation überführt die Gleichung aus dem Zeitbereich $f(t)$ nun in den Frequenzbereich $F(\omega)$. Für analoge Signale ist die Fouriertransformation wie folgt definiert:

$$f(\omega) \text{ ist die Funktion } F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-j\omega t} dt. \quad (2.6)$$

in frey. Bereich
nicht der frey. Bereich

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega) e^{j\omega t} d\omega \quad (2.7)$$



Dieser Zusammenhang

Gleichung 2.6 überführt eine von der Zeit abhängige Funktion aus dem Zeitbereich über Integration von $-\infty$ bis ∞ über alle Zeitpunkte t in den Frequenzbereich. Die inverse Fouriertransformation wird durch Gleichung 2.7 beschrieben. Die Rücktransformation erfolgt durch Integration von $-\infty$ bis ∞ des von der Frequenz ω abhängigen Signals über alle Frequenzen ω [EKS06].

2.1.2 Diskrete Fouriertransformation

Zeitkontinuierliche

Die in Abschnitt 2.1.1 dargestellten Gleichungen gelten für analoge Funktionen. In der Praxis ist es ~~aber häufig so~~, dass keine vollständige Kenntnis über ein Signal vorliegt, sondern dies ~~es~~ nur durch Messungen zu diskreten Zeitpunkten abgetastet werden kann. Hieraus resultiert die Diskrete Fourier-Transformation (DFT). Die resultierenden Werte $F(n)$ der diskreten Fouriertransformation eines zu den Zeitpunkten k abgetasteten Signals $f(t)$ können mittels Gleichung 2.8 berechnet werden. Die inverse diskrete Fouriertransformation (IDFT) erfolgt dann durch Gleichung 2.9.

vermeiden mehrere

Gleichungen direkt

unvereinbar zu setzen

$$F(n) = \sum_{k=0}^{N-1} f[k] e^{-j\frac{2\pi}{N} kn} \quad (2.8)$$

$$f[k] = \frac{1}{N} \sum_{n=0}^{N-1} F(n) e^{j\frac{2\pi}{N} kn} \quad (2.9)$$

k u. n
teilweise kenv.,
teilweise nicht

Im Zusammenhang mit der Diskreten Fouriertransformation ist abschließend das Abtasttheorem von Nyquist und Shannon zu nennen. Das Theorem besagt, dass ein beliebig geformtes, kontinuierliches Signal immer dann durch eine zu diskreten Zeitpunkten durchgeführte Abtastung darstellbar und auch exakt wiederherstellbar ist, wenn die zum Abtasten des Signals benutzte Frequenz mindestens doppelt so hoch ist, wie die höchste im kontinuierlichen Signal enthaltene Frequenz. Beträgt die höchste Frequenz in einem Signal also beispielsweise 10 Hz, so muss es mit mindestens 20 Hz abgetastet werden, damit das Signal vollständig

Gleichungen
sollten als
Teil des
Satzes
betrachtet

werden und müssen somit aus mit entsprechender Interpretation getrennt und abgeschlossen werden. (z.B. Punkt am Satzende, Komma zwischen den Gleichungen)

Hinweis darauf, dass in der Signalverarbeitung meist noch deutlich mehr 5 Signaltreppen
wird.

rekonstruierbar ist [WA05].

Die Folgen einer zu geringen Abtastfrequenz werden in Bild 2.2 ersichtlich. Die Abtastung des Signals zu den mit schwarz markierten Zeitpunkten reicht nicht aus, um das in grau dargestellte Originalsignal zu rekonstruieren. Stattdessen ergibt sich das in rot dargestellte Signal.

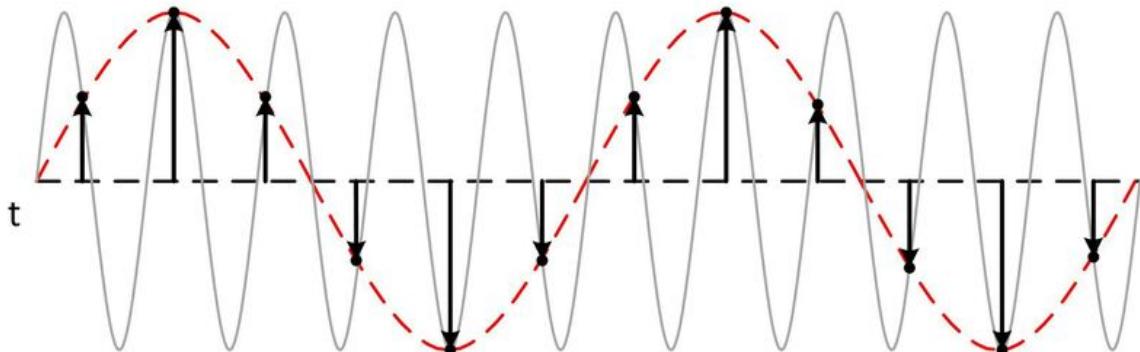


Bild 2.2: Originalsignal (grau) und durch Abtastung rekonstruiertes Signal (rot) **Quelle:** [Bun]

Jahr fehlt in Quelle

Sprachlicher Bruch / keine

Einführung. Wieso wird das hier jetzt erklärt?

Quelle fehlt

2.1.3 Wahrscheinlichkeitsverteilungen

Binomialverteilung

Als Bernoulli-Experiment wird ein Zufallsexperiment bezeichnet, bei dem es lediglich zwei Ausgänge geben kann. Ein Ereignis A tritt entweder ein oder nicht. Führt man ein Bernoulli-Experiment n mal hintereinander unter den gleichen Bedingungen durch, so erhält man eine Bernoulli-Kette der Länge n . Das Eintreten des Ereignisses A wird gemeinhin als Erfolg, die Wahrscheinlichkeit $P(A) = p$ als Erfolgswahrscheinlichkeit bezeichnet. Als Ereignis A kann hier beispielhaft das Werfen einer Münze mit dem Ausgang „Zahl“ genannt werden. Eine Binomialverteilung entsteht nun, wenn wir die Anzahl der Erfolge bei einer Bernoulli-Kette ermitteln wollen. Mathematisch formuliert lässt sich die Binomialverteilung ausdrücken als:

$$P(X = x) = \binom{n}{x} p^x q^{n-x}, \quad (2.10)$$

X bezeichnet hierbei die Anzahl der Versuchsdurchführungen, bei denen ein Erfolg eintritt. X kann die Werte $x = 0, 1, 2, \dots, n$ annehmen, p steht für die Eintrittswahrscheinlichkeit

eines Erfolges, q für die Wahrscheinlichkeit eines Misserfolges. Die Zufallsvariable X ist binomialverteilt und ihre Wahrscheinlichkeitsverteilung eine Binomialverteilung mit den Parametern n, p . Kurz: $X \sim Bi(n; p)$ [TT14]. Die grafische Darstellung einer Binomialverteilung für die Wahrscheinlichkeit der Anzahl an Würfen eines Würfels mit dem Ereignis „1“ bei sieben Würfen ist in Bild 2.3 dargestellt.

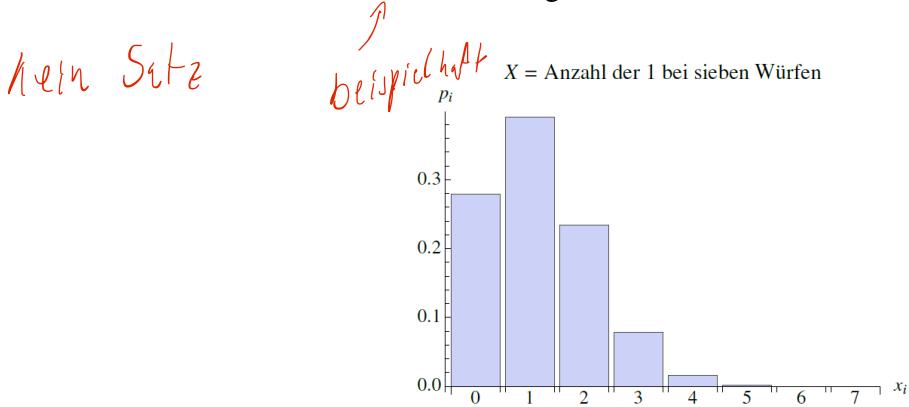


Bild 2.3: Binomialverteilung mit $n = 7, p = \frac{1}{6}$ Quelle: [TT14]

Poissonverteilung

Eine Zufallsvariable X , welche unendlich viele Werte $x = 0, 1, 2 \dots$ mit den Wahrscheinlichkeiten

$$P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (\lambda > 0) \quad (2.11)$$

annehmen kann, wird als poissonverteilt mit dem Parameter λ bezeichnet. Die zugehörige Verteilung heißt Poisson-Verteilung. Der Erwartungswert μ sowie die Varianz σ^2 der Poisson-Verteilung werden ausgedrückt als:

Wahrscheinlichkeitsverteilung

Auftrennen
S.O.

$$\mu = E(X) = \lambda \quad (2.12)$$

$$\sigma^2 = Var(X) = \lambda \quad (2.13)$$

für
Zählwerte

Anhand der obigen Formeln erkennt man, dass der Parameter der Poisson-Verteilung gleich ihres Erwartungswertes ist, selbiges gilt für die Varianz. Häufig ist es von Interesse, die Wahrscheinlichkeit für eine Anzahl X_t an Ereignissen innerhalb eines Zeitraumes $[0, t]$ zu bestimmen. Die Menge von Zufallsvariablen $X_t, t \geq 0$, wird als Poisson-Prozess mit der

Ein paar typische Beispiele nennen

Rate λ bezeichnet, falls X_t einer Poisson Verteilung folgt, es also gilt:

$$P(X_t = x) = \frac{(\lambda t)^x}{x!} e^{-\lambda t} . \quad (2.14)$$

Ein Poisson-Prozess muss dabei nach [TT14] drei Voraussetzungen erfüllen:

- Die Wahrscheinlichkeit für ein Ereignis ist proportional zur Beobachtungsdauer Δt , aber unabhängig von der Lage des Beobachtungsintervalls.
- Die Wahrscheinlichkeiten für ein Ereignis an unterschiedlichen Orten sind voneinander unabhängig.
- Für infinitesimal kleine Δt ist die Wahrscheinlichkeit, dass das Ereignis mehr als einmal auftritt, im Vergleich zur Wahrscheinlichkeit, dass es genau einmal vorkommt, vernachlässigbar klein [TT14].

2.1.4 Beschreibung binärer Zustandsmodelle

roter Faden ein. \Rightarrow Eindeutige Sätze / Motivation genau

Mobile Roboter finden immer mehr Einzug in Umgebungen, welche von Menschen bewohnt sind. Diese Menschen üben Aktivitäten aus, welche in der Folge zu Veränderungen eben dieser Umgebung führen. Man kann davon ausgehen, dass viele dieser Aktivitäten täglichen Routinen mit typischen Mustern folgen, welche von mobilen Robotern erkannt werden und zur robusteren Darstellung ihrer Umgebung genutzt werden können. Das Mapping in statischen Umgebungen, also die Kartierung, stellt ein weit erforschtes Gebiet dar [EKS06]. Für das Mapping dynamischer Umgebungen gibt es verschiedene Ansätze. Während ein Ansatz darauf abzielt, sich bewegende Objekte aus der Umgebungsdarstellung herauszufiltern [HSB02], werden in anderen diese Objekte getrackt und als bewegte Landmarken klassifiziert [MMM08]. Diese separations~~x~~ basierten Ansätze können jedoch nicht auf Langzeitveränderungen der Umgebungsstruktur reagieren.

Im Gegensatz hierzu stehen adaptive Ansätze, welche davon ausgehen, dass der Prozess der Kartierung niemals komplett abgeschlossen ist und dieser durch kontinuierliches Mapping aktualisiert werden muss. So können der Karte durch neue Observierungen des mobilen Roboters neue Features hinzugefügt werden [MW10]. In [Kra+14] wird nur versucht, die räumlich-zeitliche Dynamik einer Umgebung durch ihr Frequenzspektrum darzustellen. Die Werte von lokalen Umweltzuständen, wie zum Beispiel einer Tür, welche entweder offen oder geschlossen sein kann, sollen anhand von Wahrscheinlichkeitsfunktionen repräsentiert werden, welche aus der Superposition periodischer Funktionen resultieren. In [Kra+14] wird als Motivation dazu angeführt, dass bei den meisten Mapping-Ansätzen wichtige Umweltzustände lediglich statisch durch zwei eindeutige Zustände dargestellt werden. Eine Tür ist also

Was genau
meint
"Lage",
gibt.
zuließ
Beginn?

Quelle

→
entweder
konstanz
"Kartierung"

oder
"Mapping" Schreibe

Die
gleiche
Abschrift
ist
2.1.3
gleich
sich
noch nicht
so gut
ist da

Sätze / Motivation

entweder dauerhaft geöffnet oder geschlossen. Diese Zustände können jedoch auch durch ihre Wahrscheinlichkeit ausgedrückt werden. Hierbei beschreibt p_j die Wahrscheinlichkeit des ~~j-ten~~^{besten} Umweltzustandes einer Umgebung. Bayes-Filter gehen hierzu von einer statischen Welt aus, d.h. die Wahrscheinlichkeit des Zustandes p_j wird als konstant angesehen. Durch neue Beobachtungen können diese konstanten Annahmen verändert werden, alte Beobachtungen werden so jedoch über die Zeit „vergessen“ [Kra+14]. Nimmt man nun jedoch an, dass diese Zustandswahrscheinlichkeiten ~~Funktionen der Zeit sind, also $p_j(t)$ gilt,~~ ^{temporär vergessen} und diesen zeitlichen Veränderungen der Wahrscheinlichkeiten eine finite ~~Anzahl~~^{Anzahl} periodischer Prozesse zu Grunde liegt, so könnte man den Einfluss und die Periodizität eben dieser Prozesse identifizieren und die Zustandswahrscheinlichkeit $p_j(t)$ aus dieser Beschreibung ermitteln. In [Kra+14] wird nun die in Abschnitt 2.1.1 erläuterte Fouriertransformation benutzt, um diese periodischen Prozesse zu identifizieren. Als Beispiel wird ein Belegungsgitter herangeführt. Jede der Zellen des Belegungsgitters kann zwei Zustände $s_j = \{frei, belegt\}$ annehmen. Diese Zellzustände sind jedoch nicht konstant, sondern eine Funktion der Zeit, ~~also $s_j(t)$.~~ Die Unsicherheit des Zustandes wird nun durch seine Wahrscheinlichkeit $p_j(t)$ ausgedrückt. Da die Zellen ~~als unabhängig voneinander betrachtet werden~~ ^{je Menge} voneinander sind, kann die Fouriertransformation separat auf jede Zelle des Belegungsnetzes angewendet werden.

Die über die Zeit aufgetragenen Zustände einer Zelle $s(t)$ werden mittels der Fouriertransformation $P = FT(s(t))$ transformiert. Es werden l Koeffizienten P_i des Spektrums P ausgewählt und zusammen mit ihren Frequenzen ω_i benutzt, um mittels der inversen Fouriertransformation $p(t) = IFT(P'(t))$ die Wahrscheinlichkeitsfunktion $p(t)$ des Zellzustandes zu bestimmen. Das ~~Set~~ ^{je Menge} P besteht hierbei aus l Tripeln mit den Einträgen $(abs(P_i), arg(P_i), \omega_i)$, wobei $abs(P_i)$ für die Amplitude, $arg(P_i)$ für den Phasenversatz und ω_i für die Frequenz des jeweiligen periodischen Prozesses steht, welcher den Zustand $s(t)$ beeinflusst. Anschließend wird ein Schwellwert benutzt, um aus $p(t)$ eine Schätzung $s'(t)$ der tatsächlichen Zustandsfunktion $s(t)$ zu bestimmen.

so mit durch

Der Zustand einer Zelle kann ~~durch die Gleichung 2.15 approximiert werden~~

$$s(t) = (IFT(P) > 0.5) \quad (2.15)$$

Ist die Wahrscheinlichkeit $p(t)$ einer Zellbelegung größer als 0.5, so wird die Zelle als belegt geschätzt.

Der in Gleichung 2.15 benutzte Schwellwert von 0.5 kann willkürlich gesetzt werden. So können Vorhersagen über zukünftige Zustände der Zelle mit einem gewissen Konfidenzniveau

von c durch die Gleichung:

$$s'(t, c) = IFT(P) > c \quad (2.16)$$

getroffen werden. Diese Methodik wird im Folgenden als Frequency Map Enhancement (FreMEn) bezeichnet. Grafisch verdeutlicht wird die Methodik durch Bild 2.4.

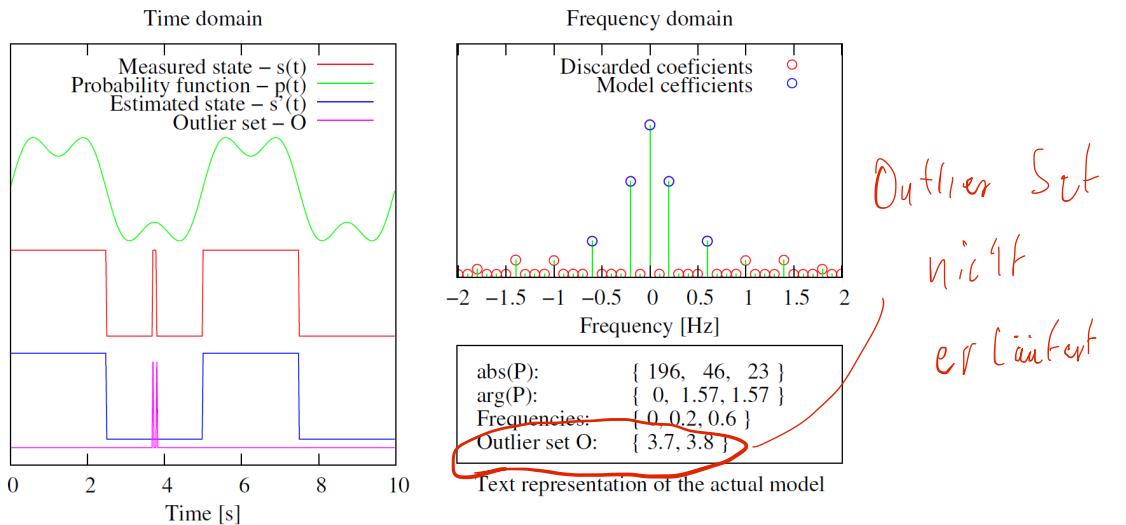


Bild 2.4: Beispiel eines über die Zeit gemessenen Zellzustandes sowie seines Spektralmodells und seiner Wahrscheinlichkeitsprädiktion ~~Quelle.~~ [Kra+14]

In der linken Grafik rot dargestellt sind die, über einen zeitlichen Verlauf aufgenommenen, binären Zustände $s(t)$ einer Beispielzelle. Der grüne Graph beschreibt das zugehörige FreMEn-Modell $p(t)$ der Ordnung $l = 3$. Zur Konstruktion von $p(t)$ wurden ~~also~~ drei periodische Prozesse verwendet. In blau aufgetragen sind die Vorhersagen $s'(t)$ des Modells, ermittelt anhand eines Schwellwertes von $c = 0.5$. Der lila Graph stellt die Zeitpunkte dar, zu denen die Modellvorhersage von den tatsächlichen Zellzuständen abweicht [Kra+14]. Die rechte obere Grafik repräsentiert das Frequenzspektrum der Zelle, die für das Modell ausgewählten Frequenzen sind durch blaue Kreise markiert. Das zuvor erwähnte Tripel bestehend aus Amplitude, Phasenversatz und Frequenz der jeweiligen periodischen Prozesse ist in der rechten unteren Grafik dargestellt. Um die Auswirkungen des Modellgrades, also der Anzahl der in das Modell einfließenden periodischen Prozesse, zu erforschen, wurde die Methodik auf einen Datensatz angewendet, bei welchem ein mobiler SCITOS-G5 Roboter, ausgestattet mit RGB-D und Lasersensoren, Personen in einem Bürogebäude über eine Dauer von einer Woche mit einer Rate von 30 Hz detektiert hat.

Die Genauigkeit des Modells $q(t_a, t_b)$ wird anhand von Gleichung 2.17 berechnet und be-

schreibt das Verhältnis von korrekt geschätzten Zellzuständen zu der Gesamtdauer des betrachteten Intervalls:

$$q(t_a, t_b) = \frac{1}{t_b - t_a} \int_{t_a}^{t_b} |s'(t) - s(t)| dt \quad (2.17)$$

Unterschieden wurde nun in [Kra+14] zwischen der Rekonstruktionsgenauigkeit q_r sowie der Prädiktionsgenauigkeit q_p . Die Rekonstruktionsgenauigkeit beschreibt, wie genau das Modell Zeitintervalle beschreibt, welche zur Ermittlung der Modellparameter verwendet wurden. Die Prädiktionsgenauigkeit hingegen beschreibt die Genauigkeit des Modells in Bezug auf Zeiträume, welche nicht zur Modellermittlung verwendet wurden. Die ermittelte Abhängigkeit der Rekonstruktions- sowie Prädiktionsgenauigkeit von der Modellordnung l ist in Bild 2.5 aufgezeigt. Hierbei erfolgte die Berechnung des Modells und der Rekonstruktionsgenauigkeit q_r anhand eines einwöchigen Datensatzes, die Evaluierung des Modells und die Ermittlung der Prädiktionsgenauigkeit q_p wurde mittels zweier externer Tage durchgeführt.

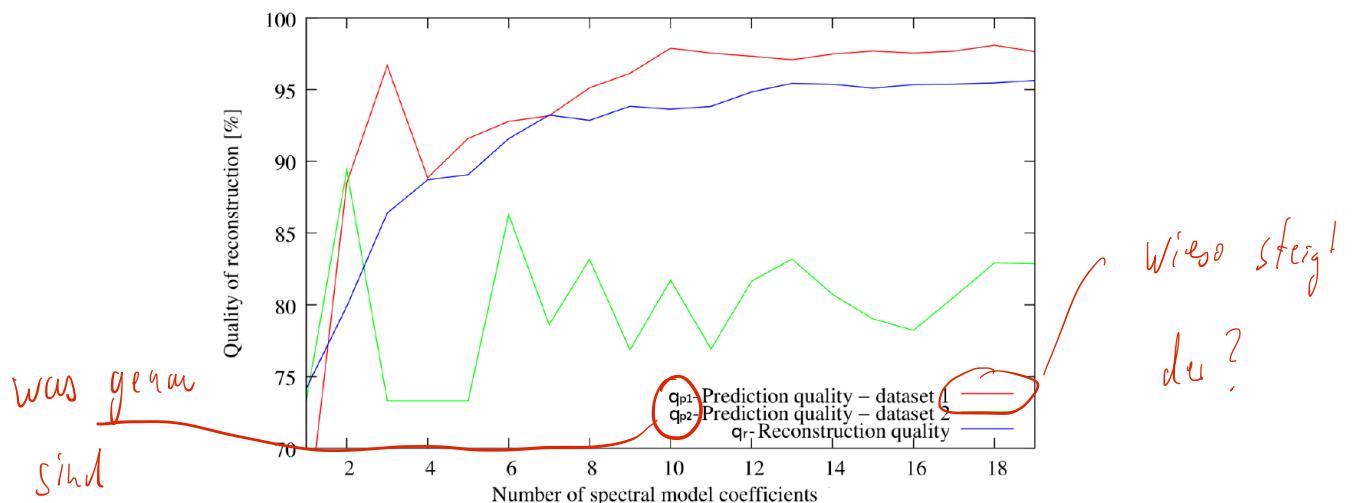


Bild 2.5: Modellgenauigkeit vs. Modellordnung **Quelle:** [Kra+14]
Was genau sind q_{p1} und q_{p2} ?

Die Rekonstruktionsgenauigkeit liegt bei einer Modellordnung von $l = 15$, d.h. es wurden 15 periodische Prozesse zum Approximieren des Zustandssignales verwendet, bei 95 %. Die Rekonstruktionsgenauigkeit q_r steigt dabei monoton mit der Modellordnung, die Prädiktionsgenauigkeit q_p hingegen nicht.

Die lokalen Maxima von q_{p1} und q_{p2} lassen den Schluss zu, dass für die Vorhersage eine Modellordnung von zwei oder drei optimal ist (siehe Bild 2.5).

Hier liegt das Maximum doch bei > 10 ?

Einen Vergleich zwischen der in [Kra+14] beschriebenen FreMEn- Methode und der Anwendung von periodischen Gauß-Mix~~modellen~~^{schen} zur Darstellung der Dynamik von binären Umweltzuständen zieht [Kra+15]. FreMEn basiert hier, wie auch schon in [Kra+14] auf der Idee, die zeitliche Funktion $s(t)$ eines Umweltzustandes durch seine Wahrscheinlichkeitsfunktion $p(t)$ zu schätzen. Auch hier wird wieder mittels einer Fouriertransformation das Frequenzspektrum $S(\omega)$ der zeitlichen Funktion $s(t)$ bestimmt, und die l prominentesten Frequenzen mit ihren Amplituden a_j , ihrem Phasenversatz φ_j sowie ihrer Frequenz ω_j abgespeichert. Die Ermittlung der Wahrscheinlichkeit $p(t)$ eines Umweltzustandes zum Zeitpunkt t ergibt sich nun durch die Superposition der l Frequenzen:~~/ zu~~

$$p(t) = a_0 + \sum_{j=1}^n a_j \cos(\omega_j t + \varphi_j) \quad (2.18)$$

Die erste spektrale Komponente a_0 stellt hierbei den Durchschnitt aller binären Werte von $s(t)$, also dessen Gleichanteil (siehe Abschnitt 2.1.1) dar. FreMEn besitzt aber laut [Kra+15] zwei wesentliche Nachteile. So erlaubt es nur einen, lediglich einen periodischen Prozess pro Frequenz zu modellieren. Des Weiteren bilde es wiederkehrende, aber kurze, Prozesse schlecht ab. Als Beispiel wird hier die morgendliche Dusche angeführt, welche eine tägliche, aber kurze Routine sei. Da in [Kra+14] herausgearbeitet wurde, dass die optimale Modellordnung l_{opt} für eine möglichst hohe Prognostizierfähigkeit bei einer Größe von lediglich zwei bis drei liegt, könnten solche kurzen Routinen schlicht nicht abgebildet werden.

Als zweiter Ansatz werden Gaussian Mixture Models (GMM) genannt. Diese können multidimensionale Funktionen als gewichtete Summe aus mehreren Gauß-Funktionen approximieren:

$$f(t) = \frac{1}{\sqrt{2\pi}} \sum_{j=1}^m \frac{\omega_j}{\sigma_j} e^{-\frac{(t-\mu_j)^2}{2\sigma_j^2}} \quad (2.19)$$

Die Parameter der individuellen Komponenten eines GMM, namentlich das Gewicht ω_j , der Durchschnitt μ_j sowie die Standardabweichung σ_j werden typischerweise mittels Trainingsdaten anhand des Iterative Expectation Maximization (EM) oder des Maximum A-Posteriori (MAP) Algorithmus ermittelt. Während GMM~~X~~ in der Lage sind, Funktionen jeglichen Aussehens zu modellieren, liegt ihre Limitation darin, dass sie definitionsgemäß keine periodischen Funktionen repräsentieren können [Kra+15]. Um diesem Problem entgegenzuwirken, wird vorab eine Periodendauer von einem Tag vorgegeben. Diese Vorgabe erlaubt es,

die gemessene Sequenz der Umweltzustände $s(t)$ in eine Sequenz $p'(t)$ umzuwandeln:

$$p'(t) = \frac{k}{\tau} \sum_{i=1}^{\frac{k}{\tau}} s(t + i\tau) \quad (2.20)$$

In Gleichung (2.20) bezeichnet τ die vorab definierte Periodendauer, k beschreibt die Länge der Sequenz $s(t)$. Nach Anwendung des Expectation Maximization Algorithmus kann nun die Wahrscheinlichkeit für einen Umweltzustand mittels Gleichung (2.21) berechnet werden:

$$p(t) = \frac{1}{\sqrt{2\pi}} \sum_{j=1}^m \frac{w_j}{\tau_j} e^{-\frac{(mod(\text{D6}) - \mu_j)^2}{2\sigma_j^2}} \quad (2.21)$$

Hierbei beschreibt τ die vorgegebene Periodendauer der Funktion $p(t)$ und mod ist der Modulo-Operator. Dass die Stärken und Schwächen dieser periodischen GMM-basierten (PerGaM) Modelle komplementär zu jenen der FreMEn-Methodik sind, wir anhand von Bild 2.6 deutlich. Das PerGaM-Modell kann selbst kurze, mehrfach auftretende Routinen

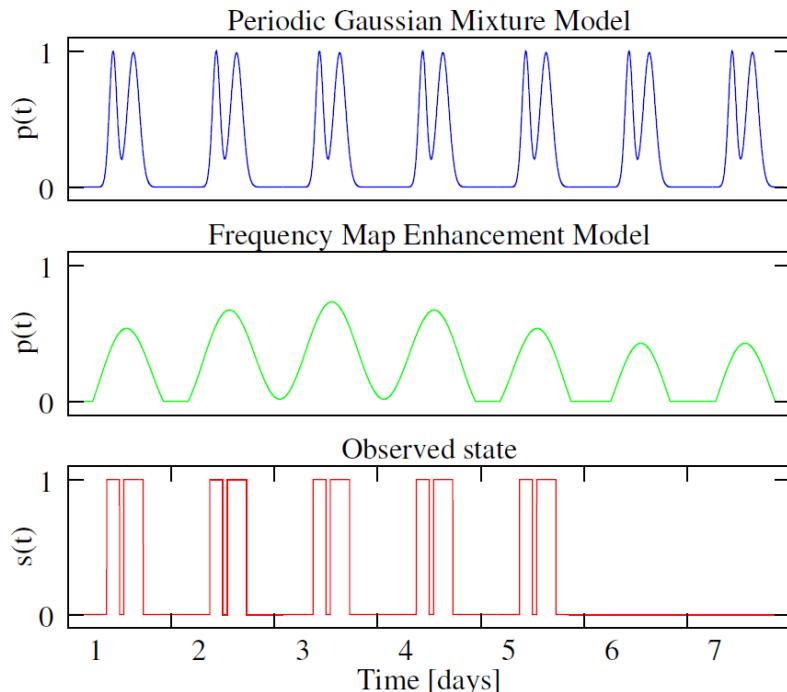


Bild 2.6: PerGaM und FreMEn Modellvergleich Quelle: [Kra+15]

approximieren, jedoch kann es lediglich eine Periodendauer repräsentieren, welche a priori bekannt bzw. festgelegt werden muss. Als Resultat werden kurzzeitige Routinen, wie z.B. Mittagspausen, gut approximiert, die wöchentliche Dynamik mit dem Fehlen von Personen am Wochenende kann hingegen jedoch nicht modelliert werden. Im Vergleich dazu sieht man das FreMEn-Modell, welches diese Wochendynamik durch ein Abflachen der Signalamplitude an den beiden Wochenendtagen abbildet (siehe Bild 2.6).

In Bezug auf die zeitlich-räumliche Kartierung durch mobile Roboter führt [KSD15] an, dass dies auch eine räumlich-zeitliche Explorationsstrategie benötigt. Im Vergleich zu klassischen Explorationsstrategien, bei denen, bedingt durch die endliche Größe der zu erforschenden Karte, die Exploration ebenfalls ~~wurde~~ finit ist, sei die Exploration dynamischer Umgebungen niemals abgeschlossen. Vielmehr ~~bekäme~~ die räumlich-zeitliche Exploration Teil der täglichen Routine des Roboters. Es stellt sich ein wesentlicher Nachteil der in [Kra+14] vorgestellten Methode zur Darstellung von binären Umweltzuständen in Bezug auf die kontinuierliche Exploration einer Karte durch einen mobilen Roboter heraus. Diese beruht auf der traditionellen Fast Fourier Transformation (FFT). Die Fast Fourier Transformation kann jedoch lediglich die komplette Sequenz eines Umweltzustandes $s(t)$ in sein Frequenzspektrum $S(\omega)$ transformieren. Außerdem erfordert der Algorithmus, dass die Zustandsobservierungen mit der immer gleichen Frequenz aufgenommen werden. Orte mit der immer selben Frequenz zu erkunden, sei jedoch nicht effizient, sodass in [KSD15] eine neue Methode zur Darstellung von binären Umweltzuständen durch zeitlich variable Wahrscheinlichkeitsfunktionen vorgestellt wird. Die Methode erlaubt ein inkrementelles und kontinuierliches Aktualisieren des räumlich-zeitlichen Umgebungsmodells durch wenige Observierungen, welche zu unterschiedlichen, nicht gleichmäßig verteilten Zeitpunkten, und an unterschiedlichen Orten aufgenommen werden können.

Jeder Umweltzustand $s(t)$ wird nun durch die ~~Nummer~~ ^{Anzahl} getätigter Observierungen n , seines Durchschnittes μ sowie zwei Sets A, B komplexer Zahlen α_k und β_k , welche zu dem Set Ω periodischer Prozesse ω_k gehören, die den Umweltzustand beeinflussen, beschrieben. Anfangs wird der Wert μ jedes Umweltzustandes zu $\mu = 0.5$ und alle α_k sowie β_k zu 0 gesetzt, was einem vollkommen unbekannten Zustand entspricht. Die inkrementelle Aktualisierung

folgender
des Modells erfolgt nun anhand der Gleichungen (2.22) - (2.25):

$$\mu \leftarrow \frac{1}{n+1}(n\mu + s(t)), \quad / \text{ hinz } \quad (2.22)$$

$$\alpha_k \leftarrow \frac{1}{n+1}(n\alpha_k + s(t)e^{-jt\omega_k}) \quad | \quad \forall \omega_k \in \Omega, \quad (2.23)$$

$$\beta_k \leftarrow \frac{1}{n+1}(n\beta_k + \mu e^{ind-jt\omega_k}) \quad | \quad \forall \omega_k \in \Omega, \quad (2.24)$$

$$n \leftarrow n + 1 \quad • \quad (2.25)$$

Die schrittweise Aktualisierung entspricht dabei einer inkrementellen Mittelwertbildung. Der Betrag $\gamma_k = |\alpha_k - \beta_k|$ entspricht hierbei dem durchschnittlichen Einfluss des periodischen Prozesses k auf den Umweltzustand $s(t)$. Wären die Zeitpunkte t der Observationen und die Frequenzen ω_k gleichmäßig verteilt, so entsprächen die obigen Formeln der diskreten Fouriertransformation. Um den zukünftigen Wert eines Umweltzustandes prognostizieren zu können, werden nun wie auch in [Kra+14] die m periodischen Prozesse mit den höchsten absoluten Werten $|\gamma_k|$ ausgewählt. Die Wahrscheinlichkeit eines Umweltzustandes wird dann mittels:

$$p(t) = \varsigma(\mu + \sum_{l=1}^m |\gamma_l| \cos(\omega_k t + arg(\gamma_l))) \quad (2.26)$$

gilt,

berechnet. Die Funktion $\varsigma(\cdot)$ sorgt dafür, dass $p(t) \in [0, 1]$. Der optimale Wert für m wird wie schon in [Kra+14] so gewählt, dass die Prädiktionsgenauigkeit q_p maximiert wird.

Übergang Lekt. Warum nötig?

2.1.5 Beschreibung quantitativer Zustandsmodelle

Eine Methodik zur Modellierung von quantitativen Umweltzuständen wird in [Jov+16] vorgestellt. Die hier genannte Methode beruht auf der Kombination von zeitveränderlichen Poisson-Prozessen und einer Frequenzanalyse. *Dabei wird die Häufigkeit des Auftretens eines Ereignisses innerhalb eines Zeitintervalls* *wird* gezählt. Anders ausgedrückt wird gezählt, wie häufig ein Umweltzustand, beispielsweise das Vorhandensein einer Person in einer Zelle, den Wert „wahr“ annimmt. Somit kann anstatt der Wahrscheinlichkeitsfunktion $p(t)$ eines Umwelt- bzw. Zellzustandes dessen „Intensität“ bzw. Rate innerhalb eines Zeitintervalls dargestellt werden. Diese Raten $\lambda(t)$ werden mit Hilfe von Poisson-Prozessen modelliert. Wie schon in Abschnitt 2.1.3 beschrieben, wird auch hier die Poisson-Verteilung mittels:

p^{r0} Zeitintervall

$$P(N; \lambda) = \frac{e^{-\lambda} \lambda^N}{N!}, \quad N = 0, 1, 2, \dots \quad (2.27)$$

berechnet, wobei $P(N; \lambda)$ die Wahrscheinlichkeit P für den Fall beschreibt, dass innerhalb eines Zeitintervalls Δt mit einer durchschnittlichen Aktivitätenanzahl, also einer durchschnittlichen Personenanzahl von λ , exakt N Aktivitäten, also Personen, gezählt werden. Die Daten in [Jov+16] wurden von einem mobilen Metralabs Scitos A5-Roboter aufgenommen, welcher sich, ausgestattet mit einem robusten Personen-Tracking-Algorithmus, einen Monat lang in einem Bürogebäude bewegte. Die Abhängigkeit der durchschnittlichen Personenanzahl λ vom betrachteten Zeitintervall wird durch $\lambda(t_i, t_j)$ ausgedrückt, wobei t_i den Anfangszeitpunkt und t_j den Endzeitpunkt des Intervalls beschreibt. Da die von dem Roboter aufgenommenen Daten nur einen kleinen Teil der Gesamtheit des Personenaufkommens repräsentiert, wird λ mittels einer Konfidenz-basierten Schätzung bestimmt. Der Poisson-Parameter λ folgt hierbei einer Gammaverteilung⁶

$$\lambda \sim \Gamma(\lambda; \alpha, \beta) \quad (2.28)$$

Die a-posteriori Wahrscheinlichkeit für $\lambda(t_i, t_j)$ berechnet sich unter Berücksichtigung der aufgenommenen Daten nun zu:⁷

$$P(\lambda|x_1, \dots, x_n) = \Gamma(\lambda, \alpha + \sum_{i=1}^n x_i, \beta + n), \quad (2.29)$$

wobei x_1, \dots, x_n die im betreffenden Intervall aufgezeichneten Daten bezeichnen, der Parameter α steht für den Formfaktor, β für den inversen Skalenparameter der Gammaverteilung. Der Datensatz wird in Wochen eingeteilt, für ein Zeitintervall wird eine Dauer von zehn Minuten gewählt. Die Maximum a posteriori-Wahrscheinlichkeit (MAP) jedes Parameters $\lambda(t_i, t_j)$ wird als Punktschätzung für λ gewählt. Die Verknüpfung sämtlicher Punktschätzungen über den definierten Zeitraum einer Woche ergibt das Poisson-Prozess-Modell, welches in Bild 2.7 grafisch aufgezeichnet ist.

Für jedes λ wurden die Daten von vier aufeinanderfolgenden Wochen verwendet, die roten Schranken zeigen die oberen und unteren Grenzen des Konfidenzintervalls für jedes λ .

Nach der Berechnung des Poisson-Prozess-Modells wird nun die Fouriertransformation auf $\lambda(t)$ angewendet. Ebenso wie in [Kra+14] werden die l Frequenzen mit den höchsten Amplituden zur Konstruktion von $\lambda' = IFT(F'(\omega))$ verwendet. Im Gegensatz zu der in [Kra+14] verwendeten und hier als ⁸Best Amplitude Model (BAM) bezeichneten Methode wird in [Jov+16] die ⁹Addition Amplitude Model (AAM) Methode verwendet. Es wird angeführt, dass das BAM den Betrag des Original-Signals nicht komplett abbilden kann, sofern die Sampling-Rate der Daten deutlich höher ist als die höchste beobachtete Frequenz. AAM hingegen berechnet das Fourierspektrum des Poisson-Prozess-Modells, findet die

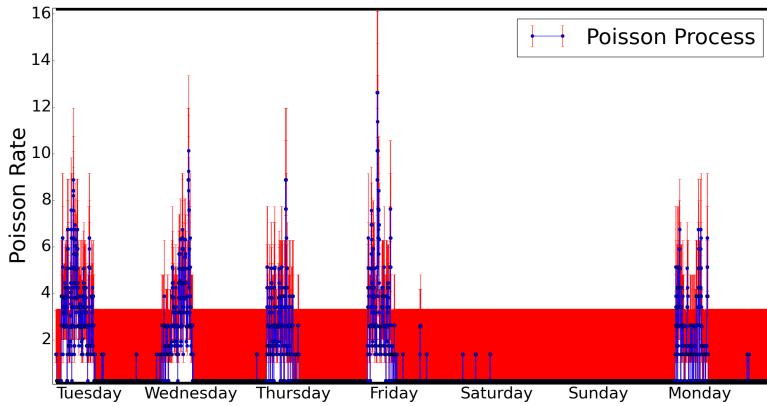


Bild 2.7: Aktivitätsraten λ des Poisson-Prozess-Modells ermittelt anhand eines 4 Wochen Zeitraumes Quelle: [Jov+16]

Frequenz ω_k mit der höchsten Amplitude und zieht es von den Daten ab. Die modifizierten Daten werden wieder transformiert und das Frequenzspektrum erneut berechnet. Findet sich in diesem Frequenzspektrum eine bereits vorher identifizierte Frequenz, so wird dessen neuerliche Amplitude auf die bereits vorhandene addiert, und die Daten erneut modifiziert. Dieses Vorgehen wird bis zur Identifikation der l Frequenzen mit den höchsten Amplituden wiederholt. Bild 2.8 bietet einen Vergleich der beiden Methoden zur Abbildung des Poisson-Prozess-Modells. Aus der Grafik wird ersichtlich, dass das AAM die Beträge des Original-Modells deutlich besser abbilden kann als das BAM. Eine genauere Beschreibung der Kalkulation des Formfaktors α und des inversen Skalenparameters β der Gammafunktion findet sich in [Mar+]. Hier wird der Parameter λ für jede Zelle eines 2D-Gitters berechnet. Die Wahrscheinlichkeit für die Anzahl N an Aktivitäten innerhalb eines Zeitintervalls in einer Zelle des Gitters kann dargestellt werden über:

$$P_{ij\tau}(N(t) = k) = \frac{(\lambda_{ij\tau}(t - t_\tau))^k}{k!} e^{-\lambda_{ij\tau}(t - t_\tau)} \quad (2.30)$$

wobei $\lambda_{ij\tau}$ für die Rate an Aktivitäten der Zelle (i, j) innerhalb des Zeitintervalls τ steht. Die der Zelle und dem jeweiligen Intervall zugehörigen Parameter $\alpha_{ij\tau}$ sowie $\beta_{ij\tau}$ werden inkrementell für jeden Zeitschritt bestimmt σ mittels der Vorschrift:

$$\alpha_\sigma = \alpha_{\sigma-1} + x_\sigma l_D(x_R, t_\sigma), \beta_\sigma = \beta_{\sigma-1} + l_D(x_R, t_\sigma) \quad (2.31)$$

nicht klar

das ist eigentlich eine eins

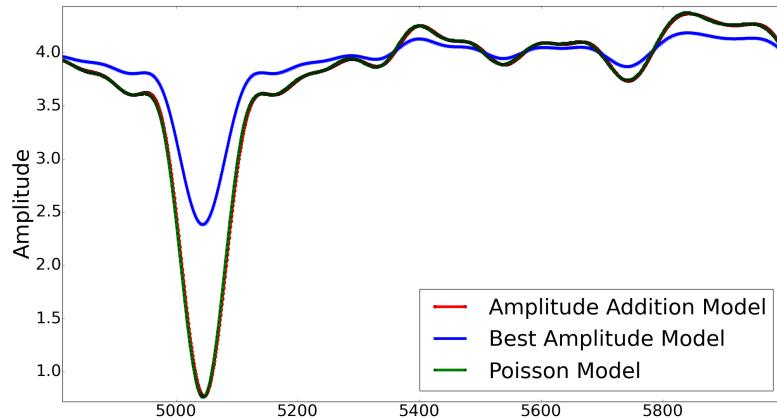


Bild 2.8: Vergleich l Best Amplitude Model und l Addition Amplitude Model Quelle: [Jov+16]

Als Anfangswerte werden $\alpha_0 = \beta_0 = 1$ gewählt. Die Indikator-Funktion $l_D(x_r, t_\sigma)$ resultiert hierbei aus dem Detektionsbereich eines Roboters bei der Pose x_R . Die a-posteriori erwarteten Werte der Aktivitätenrate λ und ihrer Varianz berechnen sich nun für jedes Intervall zu:

$$\hat{\lambda}_{ij\tau} = E[\lambda_{ij\tau}] = \frac{\alpha_{ij\tau}}{\beta_{ij\tau}}, \quad \text{Var}[\lambda_{ij\tau}] = \frac{\alpha_{ij\tau}}{\beta_{ij\tau}^2} \quad (2.32)$$

S.o.

Generell:

- Besonders die Bezeichnung der Methoden von Kraijer ist schwäbisch
- Öfters falsche Übergänge und der rote Faden leicht etwas
- Wenige Füllwörter unten („also“, „nur“, ...)

3 Methodik

3.1 Binäre Zustandsmodelle

3.1.1 Messdatenermittlung eines Belegtheitsgitters

Den ersten Schritt der Methodik bildet die Aufzeichnung von Messdaten. Als Messdaten werden hierbei die Detektionen von Personen innerhalb einer Umgebung \mathcal{U} bezeichnet. Eine Umgebung \mathcal{U} ist ein geografisch abgegrenztes Gebiet, als Beispiele können hier ein Bürogebäude, ein Apartment oder ein offenes Gelände genannt werden. Die Ermittlung der Messdaten kann dabei zum Beispiel durch einen, mit einem Personen-Detektions-Algorithmus ausgestatteten, mobilen Roboter erfolgen, oder durch mehrere, in \mathcal{U} verteilte, statische Sensoren, welche ebenfalls das Auftreten von Personen detektieren können. Werden innerhalb eines Zeitraumes T insgesamt N Personen detektiert, also N Messungen aufgezeichnet, so lässt sich die Gesamtheit der Messungen schreiben als:

$$\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)^T \quad (3.1)$$

Die Messung einer einzelnen Personendetektion lässt sich nun beschreiben als:

$$\mathbf{x}_i = (x_{\text{det}}, y_{\text{det}}, t_{\text{det}})^T \quad (3.2)$$

Eine Messung beinhaltet demnach die x-Position x_{det} der Detektion innerhalb des Umgebungskoordinatensystems $(KS)_{\mathcal{U}}$, die y-Position y_{det} der Detektion innerhalb des Umgebungskoordinatensystems, sowie den Zeitstempel t_{det} der Detektion. Für die weitere Betrachtung wird über die Umgebung \mathcal{U} nun ein Gitter gelegt, welches aus diskreten, finiten Zellen besteht. Grafisch veranschaulicht ist dieses Verfahren in Bild 3.1.

Zu sehen sind hier die schematischen Umrisse eines Bürogebäudes. In blau dargestellt und über die Büroumriss gelegt ist das oben beschriebene Gitter. Eine einzelne Zelle ist dabei durch ihre x- und y-Position innerhalb des Umgebungskoordinatensystems $(KS)_{\mathcal{U}}$ definiert. Nachdem man die Umgebung \mathcal{U} in einzelne Zellen unterteilt hat, lässt sich das

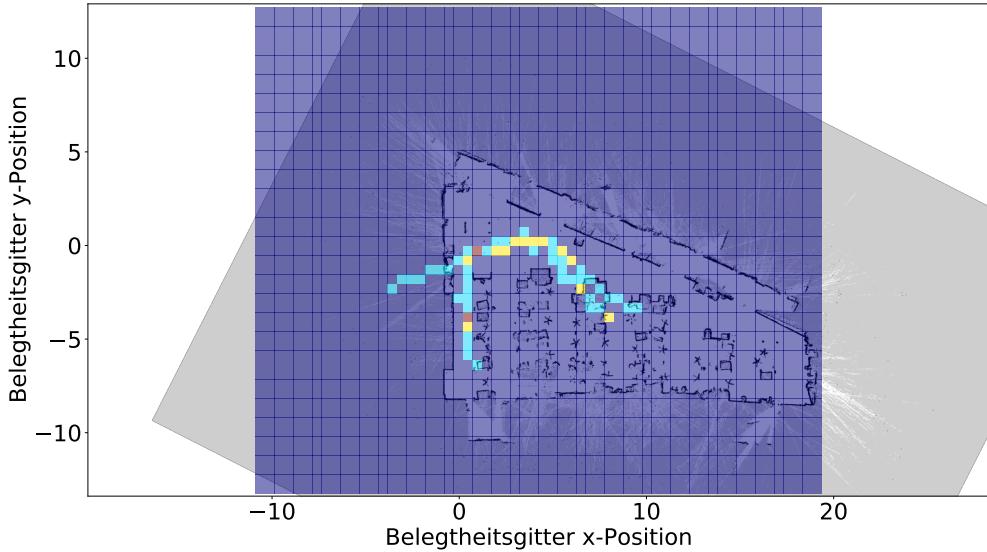


Bild 3.1: Schematische Zeichnung eines Bürogebäudes, über welches ein Gitter (blau) gelegt ist

oben beschriebene Gitter in Matrixschreibweise ausdrücken:

$$G_{\text{Gitter}} = \begin{pmatrix} A_{1,1} & A_{1,2} & \dots & A_{1,n} \\ A_{2,1} & A_{2,2} & \dots & A_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1} & A_{n,2} & \dots & A_{n,n} \end{pmatrix} \quad (3.3)$$

Hierbei bezeichnet $A_{2,2}$ die Zelle der zweiten Reihe und der zweiten Spalte des Gitters, in welches die Umgebung eingeteilt wird. Zu erwähnen ist hier, dass es sich um ein rechteckiges Gitter handelt, welches über die Umgebung \mathcal{U} gelegt wird. Der Bereich einer Zelle $A_{i,j}$ ist definiert durch ihren Bereich in x- und y-Richtung des Umgebungskoordinatensystems $(KS)_{\mathcal{U}}$. Eine Zelle $A_{i,j}$ lässt sich also beschreiben durch:

$$A_{i,j} = f(x_{\text{left}}, x_{\text{right}}, y_{\text{bottom}}, y_{\text{top}}) \quad (3.4)$$

wobei x_{left} die linke Grenze der Zelle im Umgebungskoordinatensystem bezeichnet, x_{right} die rechte Grenze, y_{bottom} die untere Grenze und y_{top} die obere Grenze. Eine Detektion x_i wird

der Zelle $A_{i,j}$ zugeordnet, sofern $x_{\text{det}} \in [x_{\text{left}}, x_{\text{right}}] \wedge y_{\text{det}} \in [y_{\text{bottom}}, y_{\text{top}}]$. Ein Eintrag in einer Zelle $A_{i,j}$ besteht nun also aus einem Tripel mit den Einträgen $(x_{\text{det}}, y_{\text{det}}, t_{\text{det}})$. Werden nun nach und nach mehr Detektionen innerhalb einer bestimmten Zelle getätig, enthält die Zelle $A_{i,j}$ ein Set \mathcal{L} bestehend aus l Tripeln. Zeichnet man nun alle Detektionen für einen bestimmten Zeitraum, zum Beispiel für eine Woche auf, kann man danach die Messungen in Zeitintervalle Δt_n unterteilen. Beträgt die Gesamtdauer des zum Aufzeichnen von Detektionen betrachteten Zeitraumes T , so ergibt sich die Gesamtzahl an Intervallen bei einer Intervalllänge von Δt zu:

$$n_{\text{timestamps}} = \frac{T}{\sigma} \quad (3.5)$$

Die Dauer des Zeitraumes $T = t_b - t_a$ wird durch seinen Startzeitpunkt t_a sowie seinen Endzeitpunkt t_b definiert. Das n-te Zeitintervall Δt_n befindet sich also innerhalb der Grenzen $[t_a + n\Delta t, t_a + (n + 1)\Delta t]$. Um die Übersichtlichkeit der Methodik weiterhin gewährleisten zu können, wird im Folgenden die Zelle $A_{i,j}$ nur noch mit A bezeichnet. Um die Aktivität beziehungsweise das Personenaufkommen in einer Zelle des Gitters bestimmen zu können, wird die Anzahl der Detektionen pro Zeitintervall aufsummiert. Für die Summe an Detektionen in der Zelle A im n-ten Zeitintervall lässt sich schreiben:

$$a_n = \sum_{k=1}^K l_k \in [t_a + n\Delta t, t_a + (n + 1)\Delta t] \quad (3.6)$$

Nach der Unterteilung des gesamten Zeitraumes in Intervalle und das Aufsummieren der Detektionen innerhalb dieser Intervalle enthält jede Zelle also die Information des zeitlichen Verlaufes des Personenaufkommens innerhalb ihrer geografischen Grenzen. Mathematisch ausgedrückt vereinfacht sich Gleichung (3.4) zu:

$$A = (\mathbf{a}, \mathbf{t})^T \quad (3.7)$$

Hierbei bezeichnet $\mathbf{a} = (a_1, a_2, \dots, a_n)^T$ alle aufsummierten Personendetektionen innerhalb der Zeitintervalle mit den korrespondierenden Zeitstempeln $\mathbf{t} = (t_1, t_2, \dots, t_n)^T$. Als Zeitstempel jeden Intervalls wird dessen Startzeitpunkt gewählt. Anschaulich beschrieben erhalten wir nun also für jeden Zeitstempel die Information, wie viele Personen sich innerhalb des betreffenden Zeitintervalls in den Zellen unseres Gitters befunden haben. Für einen Betrachtungszeitraum mit n Zeitstempeln kann man sich nun eine dreidimensionale Matrix vorstellen, bei der auf der dritten Achse n Matrizen G_{Gitter} (vgl. Gleichung (3.3)) hintereinander gestapelt werden. Im Falle des binären Zustandsmodells werden die Einträge jeder Zelle eines Zeitstempels auf dem Bereich $\{0, 1\}$ abgebildet. Das heißt, es wird lediglich

das Vorhandensein einer Person innerhalb eines Zeitintervalls in einer Zelle registriert, nicht jedoch die Anzahl der Personen innerhalb des Zeitintervalls. Ein qualitativer Vergleich der beiden Methoden kann durch Bild 3.2 gezogen werden.

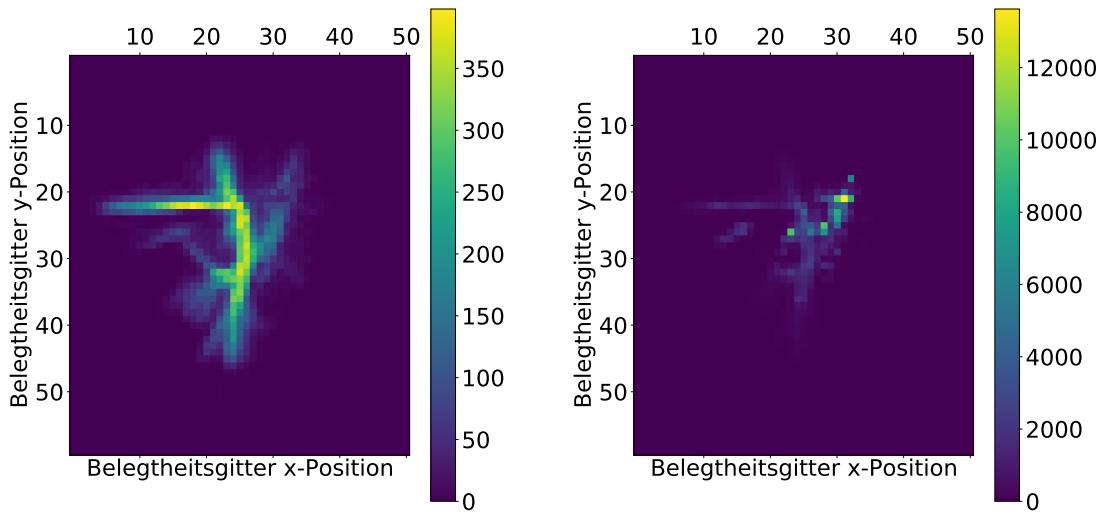


Bild 3.2: Aufsummierte Personendetektionen innerhalb eines Zeitraumes von einer Woche mit Beschränkung auf $\{0, 1\}$ (links) und ohne Beschränkung (rechts)

Beiden Abbildungen liegen aufsummierte Personendetektionen innerhalb eines Zeitraumes von einer Woche mit der Aufteilung in Zeitintervallen von $\Delta t = 600$ sec zugrunde. Im linken Bild sieht man die Darstellung von Detektionen, welche pro Zeitintervall auf $\{0,1\}$ beschränkt sind. Farblich hervorgehoben sind hier also Zellen, welche über viele Zeitintervalle hinweg häufig besucht waren. Im rechten Bild dargestellt sind die nicht beschränkten, aufsummierten Personendetektionen aufgeführt. Farblich hervorgehoben sind hier die Zellen, welche innerhalb des gesamten Betrachtungszeitraumes am häufigsten besucht wurden, dies sich aber auf eine relativ kurze Zeitspanne innerhalb des Betrachtungszeitraumes beschränken kann. Im weiteren Verlauf dieses Kapitels wird lediglich der binäre Fall behandelt, also die auf $\{0,1\}$ beschränkte Detektion von Personen innerhalb eines Zeitintervalls. Die so ermittelten Daten bilden also einen Trend über den Betrachtungszeitraum ab. Die Unterteilung in Zeitintervalle ist der Tatsache geschuldet, dass in der Praxis das Wissen über die Zellzustände lückenhaft ist. Es kann lediglich durch vom mobilen Roboter durchgeführte, stichprobenartige Messungen approximiert werden. Mit einer größer werdenden Intervalldauer lassen sich die Messungen

flexibler durchführen. Eine größere Intervalldauer geht jedoch mit einer stetig steigenden Verallgemeinerung des Zellzustandes und dem Verlust von Informationen einher. Die registrierten Daten werden in einem weiteren Schritt in einer Datenbank gespeichert. Dies ermöglicht den externen Zugriff eines in Abschnitt 3.1.2 behandelten Clients auf die Messdaten. Ein einzelner Eintrag in der Datenbank besitzt dabei immer den gleichen Aufbau. Neben dem Zellnamen werden der Zeitstempel sowie die Information, ob die Zelle im betrachteten Zeitintervall belegt oder frei war, gespeichert.

3.1.2 Verarbeitung der Messdaten Client-seitig

Auf der Client-Seite wird das Gitter G_{Gitter} mit seinen Zelleinträgen $A_{i,j}$ rekonstruiert. Hierzu greift der Client auf die in Abschnitt 3.1.1 beschriebene Datenbank zu, und erstellt seinerseits ein Gitter, in welchem jede Zelle einer Matrix bestehend aus einem Vektor an Zeitstempeln und dem dazu korrespondierenden Vektor der Personendetektionen nach Gleichung (3.7) angelegt wird. Der Zustand jeder einzelnen Zelle des Gitters ist nun also als Funktion der Zeit innerhalb des Clients gespeichert und lässt sich nach [Kra+14] als $s(t)$ schreiben. Da auch in dieser Arbeit von dem Ansatz ausgegangen wird, dass das menschliche Verhalten, also auch das örtliche Auftreten von Personen, gewissen zeitlichen Periodizitäten unterliegt, werden die Daten der einzelnen Zellen im Folgenden an einen Server geschickt, auf welchem Untersuchungen ihrer Frequenzspektren erfolgen.

3.1.3 Verarbeitung der Messdaten Server-seitig

Der Server erstellt für jede Zelle des Belegtheitsgitters ein Modell. Als Eingang dienen dem Server die von dem Client gesendeten Datenarrays der einzelnen Zellen mit den Zeitstempeln und den dazu gehörigen Belegtheitsinformationen. Da die Zellen als linear unabhängig betrachtet werden, wird für jede Zelle ein eigenes Modell erstellt. Als Eingangsgröße dient, wie schon in [Kra+14], die Belegtheit der Zelle als Funktion von der Zeit $s(t)$. Es sei darauf hingewiesen, dass $s(t)$ keine kontinuierliche, sondern eine diskrete, binäre Funktion mit Einträgen zu den Zeitpunkten der Zeitstempel ist. Das Ziel ist nun, die Funktion $s(t)$ durch eine Wahrscheinlichkeitsfunktion $p(t)$ zu approximieren. Das Vorgehen entspricht hierbei der Frequency-Map-Enhancement (FreMEn) Methodik aus [Kra+15]. Es gilt, das Frequenzspektrum der Funktion $s(t)$ zu ermitteln. Hierzu wird eine inkrementelle Fouriertransformation des Zustandsvektors $s(t)$ durchgeführt.

$$\begin{aligned}
\mu &\leftarrow \frac{1}{n+1}(n\mu + s(t)) \\
\alpha_k &\leftarrow \frac{1}{n+1}(n\alpha_k + s(t)e^{-j\omega_k}) \quad \forall \omega_k \in \Omega \\
\beta_k &\leftarrow \frac{1}{n+1}(n\beta_k + \mu e^{-j\omega_k}) \quad \forall \omega_k \in \Omega \\
n &\leftarrow n + 1
\end{aligned} \tag{3.8}$$

Gleichung (3.8) gleicht dem Vorgehen aus [KSD15]. Mit jeder neuen Detektion werden die Werte aktualisiert. Zur Erinnerung sei darauf hingewiesen, dass die Grundidee dieser Methodik darin besteht, die zeitliche Zustandsfunktion $s(t)$ jeder Zelle des Gitters durch eine Wahrscheinlichkeitsfunktion $p(t)$ zu approximieren, der l periodische Prozesse zugrunde liegen. Die Zustandsfunktion jeder Zelle wird dabei durch die Zellzustände zu den Zeitstempeln t_1, t_2, \dots, t_n , ihren Durchschnittswert μ , und zwei Sets \mathcal{A}, \mathcal{B} komplexer Zahlen α_k und β_k des korrespondierenden periodischen Prozesses mit der Frequenz ω_k aus dem Set Ω beschrieben. Initialisiert wird jede Zelle mit den Durchschnittswert $\mu = 0.5$, alle Werte α_k, β_k werden zu 0 gesetzt. Der Absolutwert $\gamma_k = |\alpha_k - \beta_k|$ entspricht dem durchschnittlichen Einfluss des periodischen Prozesses mit der Frequenz ω_k auf den Zellzustand $s(t)$.

Im Gegensatz zu [KSD15] wird hier im Vorhinein eine feste Periodendauer T von beispielsweise einer Woche vorgegeben. Da die Observationen innerhalb diskreter, über den Zeitraum T gleichmäßig verteilter Intervalle Δt erfolgen, vereinfacht sich die Gleichung (3.8) formal zur traditionellen Diskreten Fouriertransformation (DFT). Die Informationen über den Zellzustand $s(t)$ werden, wie in Abschnitt 3.1.1 beschrieben, innerhalb einer Datenbank gespeichert. Beträgt die Gesamtdauer der in der Datenbank gespeicherten Daten n mal T , sind also n Samples der a priori definierten Periodendauer T gegeben, so erfolgt eine Mittelung der Werte innerhalb korrespondierender Zeitintervalle Δt :

$$\begin{aligned}
\bar{\mu} &= \frac{1}{n} \sum_{i=1}^n \mu_i \\
\bar{\alpha}_k &= \frac{1}{n} \sum_{i=1}^n \alpha_{k,i} \\
\bar{\beta}_k &= \frac{1}{n} \sum_{i=1}^n \beta_{k,i}
\end{aligned} \tag{3.9}$$

Die Wahrscheinlichkeitsfunktion $p(t)$ des Zellzustandes $s(t)$ wird nun wie in [KSD15] mittels Extraktion der l periodischen Prozesse mit den höchsten Amplituden $\bar{\gamma}_k = |\bar{\alpha}_k - \bar{\beta}_k|$ gebildet. Nach deren Überlagerung ergibt sich die Wahrscheinlichkeitsfunktion $p(t)$ zu:

$$p(t) = \zeta(\bar{\mu} + \sum_{l=1}^m |\bar{\gamma}_l| \cos(\omega_k t + \arg(\bar{\gamma}_l))) \quad (3.10)$$

Hierbei versichert $\zeta(\cdot)$, dass die Funktion $p(t) \in [0, 1]$. Zur Erläuterung sei angemerkt, dass, obwohl die Werte von $s(t)$ im hier betrachteten binären Fall lediglich die Zustände $\{0, 1\}$ annehmen können, die durch Fouriertransformation und inverse Fouriertransformation ermittelte Funktion $p(t)$ sehr wohl Werte größer als 1 annehmen kann.

Die Berechnung von $p(t)$ durch Gleichung (3.10) erlaubt es nun, zukünftige Zustände $s(t)$ einer Zelle zu ermitteln. Ein beliebiger Zeitpunkt t wird dazu auf der entsprechenden Stelle innerhalb des Zeitintervalls T abgebildet. Die Prädiktion $s'(t)$ des Zellzustandes erfolgt mittels eines Schwellwertes c :

$$s'_i(t) = \begin{cases} 1 & \text{if } p(t) \geq c \\ 0 & \text{if } p(t) < c \end{cases} \quad (3.11)$$

Zur Ermittlung der optimalen Anzahl l_{opt} an periodischen Prozessen zur Bestimmung der Wahrscheinlichkeitsfunktion $p(t)$ wird nun noch etwas genauer auf die Einteilung des Datensatzes in ein „Estimation-Set“ sowie ein „Prediction-Set“ eingegangen. Ist die Gesamtdauer der in der Datenbank vorhandenen Zelleinträge T , so werden zur Berechnung der Modellkoefizienten nach Gleichung (3.8) Daten innerhalb des Zeitintervalls $\Delta T_{\text{Estimation}}$ verwendet. Der Schätzfehler $\epsilon_r(T)$, also die Genauigkeit, mit der das Modell die zu seiner Erstellung verwendeten Daten rekonstruieren kann, ergibt sich zu:

$$\epsilon_r(\Delta T_{\text{Estimation}}) = \frac{1}{n} \sum_{i=1}^n |s'_i(t) - s_i(t)| \quad (3.12)$$

Es sei darauf hingewiesen, dass alle zur Berechnung des Fehlers ϵ_r verwendeten Daten innerhalb des Intervalls $\Delta T_{\text{Estimation}}$ liegen müssen.

Das Zeitintervall $\Delta T_{\text{Prediction}}$ beinhaltet Messungen, welche nicht zur Erstellung des Modells verwendet wurden. Somit beschreibt der Fehler ϵ_p , wie genau das Modell zukünftige Zustände einer Zelle vorhersagen kann. Der Fehler ϵ_p berechnet sich dementsprechend zu:

$$\epsilon_p(\Delta T_{\text{Prediction}}) = \frac{1}{n} \sum_{i=1}^n |s'_i(t) - s_i(t)| \quad (3.13)$$

mit allen Messwerten innerhalb des Intervalls $\Delta T_{\text{Prediction}}$. Nach [KSD15] wird die optimale Modellordnung l_{opt} so gewählt, dass der Prädiktionsfehler ϵ_p minimiert wird.

3.2 Quantitative Zustandsmodelle

3.2.1 Messdatenermittlung eines Occupancy-Grids

Wie schon in Abschnitt 3.1 wird auch in diesem Abschnitt, welcher quantitative Zustandsmodelle behandelt, ein Gitter über eine Umgebung \mathcal{U} gelegt, und für einen Betrachtungszeitraum T , unterteilt in Intervalle mit der Intervalldauer Δt , die Personendetektionen innerhalb der Zellen gezählt. Die Methodik gleicht der des binären Modells (siehe dazu Gleichungen (3.1) - (3.6)). Jedoch erfolgt nun keine Beschränkung mehr der Detektionen pro Intervall auf $\{0,1\}$. Die Einträge einer einzelnen Zelle des Gitters werden nun ausgedrückt durch:

$$\mathbf{A} = (\boldsymbol{\lambda}, \mathbf{t})^T \quad (3.14)$$

Da im quantitativen Fall die Anzahl an Personen pro Zeitintervall Δt , also die Personenrate gezählt wird, enthält Gleichung (3.14) nun ebendiese Personenraten $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \dots, \lambda_n)$ der einzelnen Zeitintervalle sowie die Zeitstempel $\mathbf{t} = (t_1, t_2, \dots, t_n)$ der zugehörigen Intervalle. Eine Erhöhung der Intervalldauer Δt geht dabei mit steigenden Einträgen der Personenraten $\boldsymbol{\lambda}$ und einem Informationsverlust einher.

Die registrierten Daten werden, wie schon in Abschnitt 3.1.1, in einer Datenbank gespeichert. Ein Datenbankeintrag enthält dabei neben dem Zellennamen den Zeitstempel des Zeitintervalls sowie die zugehörige Personenrate λ des Intervalls.

3.2.2 Verarbeitung der Messdaten Client-seitig

Die Verarbeitung der Messdaten auf der Client-Seite gleicht dem Vorgehen in Abschnitt 3.1.2. Das Gitter $\mathbf{G}_{\text{Gitter}}$ mit seinen Zelleinträgen $A_{i,j}$ wird rekonstruiert. Jede rekonstruierte Zelle enthält einen Vektor \mathbf{t} an Zeitstempeln und den Vektor $\boldsymbol{\lambda}$ der Personenraten der einzelnen Zeitintervalle. Die beiden Vektoren jeder Zelle werden im nächsten Schritt an den Server geschickt, auf welchem Untersuchungen der Frequenzspektren der Zelle erfolgen.

3.2.3 Verarbeitung der Messdaten Server-seitig

Wie schon in Abschnitt 3.1.2 erstellt der Server auch für den quantitativen Fall für jede Zelle des Belegtheitsgitters ein Modell. Wieder wird aufgrund der linearen Unabhängigkeit der

Zellen für jede einzelne Zelle ein eigenes Modell erstellt. Als Eingangsgröße dient, wie in [Jov+16], die Personenrate $\lambda(t)$ als Funktion der Personenrate der einzelnen Zeitintervalle Δt . Die Funktion $\lambda(t)$ soll durch eine Funktion $\lambda'(t)$ approximiert werden. Nach [Kra+15] erfolgt eine inkrementelle Fouriertransformation des Personenraten-Funktion $\lambda(t)$ durch die Gleichung (3.8). Liegen in der Datenbank insgesamt n Samples der a priori definierten Periodendauer T vor, so erfolgt eine Mittelung der Werte korrespondierender Zeitintervalle Δt_i nach Gleichung (3.9). Die Approximation $\lambda'(t)$ der Personenraten-Funktion $\lambda(t)$ ergibt sich zu:

$$\lambda'(t) = \zeta(\bar{\mu} + \sum_{l=1}^m |\bar{\gamma}_l| \cos(\omega_k t + \arg(\bar{\gamma}_l))) \quad (3.15)$$

Hierbei versichert $\zeta(\cdot)$, dass die Funktion $\lambda'(t)$ immer den gerundeten Wert der nächsten natürlichen Zahl annimmt. Zur Ermittlung der optimalen Anzahl l_{opt} an periodischen Prozessen zur Bestimmung der Personenraten-Funktion $\lambda(t)$ wird der Datensatz erneut in ein „Estimation-Set“ sowie ein „Prediction-Set“ eingeteilt. Der Schätzfehler $\epsilon_r(T)$, also die Genauigkeit, mit der das Modell die zu seiner Erstellung verwendeten Daten rekonstruieren kann, ergibt sich zu:

$$\epsilon_r(\Delta T_{\text{Estimation}}) = \frac{1}{n} \sum_{i=1}^n |\lambda'_i(t) - \lambda_i(t)| \quad (3.16)$$

Alle zur Berechnung des Fehlers ϵ_r verwendeten Daten müssen innerhalb des Intervalls $\Delta T_{\text{Estimation}}$ liegen.

Das Zeitintervall $\Delta T_{\text{Prediction}}$ beinhaltet Messungen, welche nicht zur Erstellung des Modells verwendet wurden. Somit beschreibt, wie schon in Abschnitt 3.2.3, der Fehler ϵ_p , wie genau das Modell zukünftige Personenraten einer Zelle vorhersagen kann. Der Fehler ϵ_p berechnet sich zu:

$$\epsilon_p(\Delta T_{\text{Prediction}}) = \frac{1}{n} \sum_{i=1}^n |\lambda'_i(t) - \lambda_i(t)| \quad (3.17)$$

mit allen Messwerten innerhalb des Intervalls $\Delta T_{\text{Prediction}}$. Die optimale Modellordnung l_{opt} wird so gewählt, dass der Prädiktionsfehler ϵ_p minimiert wird.

4 Evaluation

4.1 Datensätze

Zur Evaluation der in dieser Arbeit präsentierten Methodik dienen zwei separate Datensätze. Der im Folgenden als „Aruba-Datensatz“ bezeichnete Datensatz zeichnete über einen Zeitraum von 16 Wochen das Personenaufkommen innerhalb einer Wohnung auf. Hierbei wurde die Wohnung in verschiedene Räume aufgeteilt, und minütlich der Aufenthaltsort einer Person innerhalb der Wohnung dokumentiert. Als Beschränkung gilt, dass sich zu jedem Zeitpunkt nur maximal eine Person in der Wohnung befinden konnte. Befand sich die Person ausserhalb der Wohnung, so ist dies im Datensatz als Raum „Outside“ dokumentiert. Die in den folgenden Abschnitten durchgeführten Untersuchungen beruhen stets auf einem Modell, welches mittels der Daten der ersten zwölf der insgesamt 16 Wochen nach Gleichung 4.8 und 4.9 trainiert wurde. Zur Evaluation des Modells wird der Prädiktionsfehler ϵ_p für die letzten vier Wochen des Datensatzes berechnet. Als Modellordnung l wird wie schon in Abschnitt 3.1.3 dargelegt die Ordnung mit dem geringsten Prädiktionsfehler ϵ_p gewählt.

Der zweite Datensatz, im Folgenden als „UOL-Datensatz grqq“ bezeichnet, wurde durch einen an einer statischen Position befindlichen Roboter ermittelt. Dieser zeichnete hier innerhalb eines Bürogebäudes mit einer Frequenz von 2 Hz Personendetektionen mit den zugehörigen Zeit- und Positionsstempeln über einen Gesamtzeitraum von 23 Tagen auf. Zur Modellberechnung wurden jeweils die ersten zwei Wochen des Datensatzes verwendet. Zur Evaluierung wurde ϵ_p mittels der Daten der dritten Woche berechnet. Als Modellordnung wird auch hier die Ordnung mit dem geringsten Prädiktionsfehler ϵ_p gewählt.

4.2 Beschreibung der Fehlermaße

4.2.1 Fehlermaße binäres Modell

Für die Bewertung der Auswirkungen der in den folgenden Abschnitten betrachteten Parameter auf das Zustandsmodell wird ein einheitliches Fehlermaß benutzt. Wie schon in Abschnitt 2 beschrieben und auch in [Kra+14] erwähnt, führt eine Erhöhung der Modellordnung dazu, dass die zur Erstellung des Modells verwendeten Daten genauer modelliert werden können. Der Schätzfehler ϵ_r sinkt also. Der Einfluss auf den Prädiktionsfehler ϵ_p , also die Genauigkeit

mit der zukünftige Zellzustände modelliert werden können ,ist jedoch komplexer. Grafisch dargestellt sind diese Beziehungen in Bild 4.1.

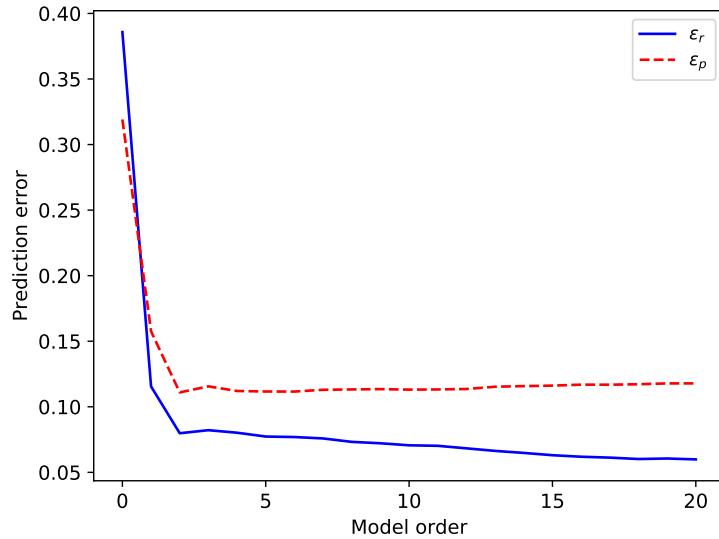


Bild 4.1: Rekonstruktionsfehler ϵ_r und Prädiktionsfehler ϵ_p mit steigender Modellordnung

Somit wird zur Bewertung der Modellgenauigkeiten in den kommenden Abschnitten stets die Modellordnung mit dem geringsten Prädiktionsfehler ϵ_p gewählt. Der Fehler berechnet sich dabei nach 3.13. Die maximale Modellordnung wurde dabei in den folgenden Abschnitten als $l_{\max} = 20$ gewählt. Als Schwellwert wurde $c = 0.5$ gesetzt.

4.2.2 Fehlermaße quantitatives Modell

Auch bei dem quantitativen Modell berechnet sich die optimale Modellordnung zu solcher, die den Prädiktionsfehler ϵ_p minimiert. Da für den quantitativen Fall jedoch die Personenraten $\lambda'(t)$ für die einzelnen Intervalle berechnet werden, erfolgt die Ermittlung des Prädiktionsfehlers nach Gleichung xxx mit Hilfe der „least-square mean-error“ Methode. Die Rate $\lambda'(t)$ wird dabei durch Rundung an die nächste natürliche Zahl berechnet. Auch hier wurde die maximale Modellordnung zu $l_{\max} = 20$ gewählt.

4.3 Binäres Modell

4.3.1 Einfluss der Intervalldauer

In diesem Abschnitt wird der Einfluss der Intervalldauer Δt auf das Modell untersucht. Da hier noch der binäre Fall betrachtet wird, berechnen sich die Detektionen im n-ten Zeitintervall (siehe Gleichung (3.6)) zu:

$$a_n = \begin{cases} 1 & \text{if } a_n \geq 1 \\ 0 & \text{else} \end{cases} \quad (4.1)$$

Die Summe an Zeitstempeln innerhalb der Periodendauer reduziert sich also mit steigendem Δt . Wurde innerhalb des zugehörigen Zeitintervalls mindestens eine Person gefunden, wird der Zellzustand $s(t)$ gleich eins gesetzt. Die Auswirkungen davon verdeutlicht Bild 4.2.

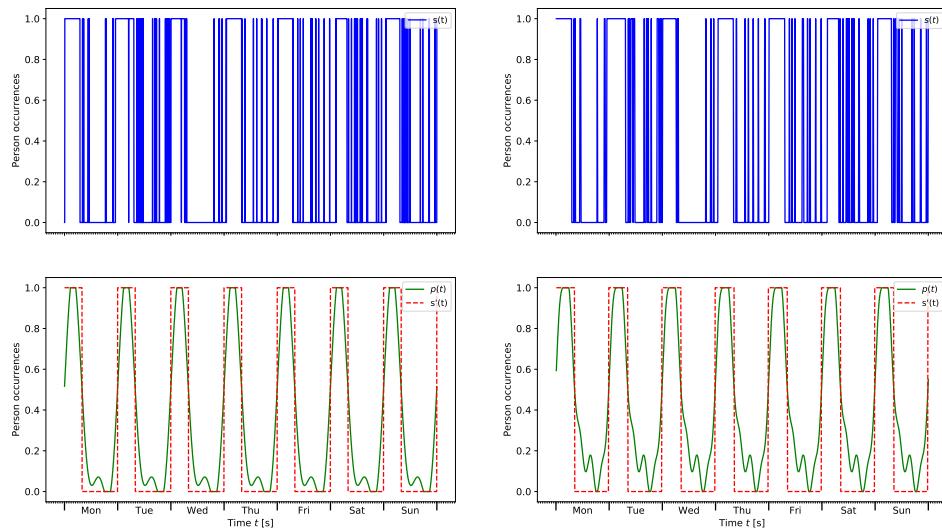


Bild 4.2: Vergleich des Zellzustandes $p(t)$ des Schlafzimmers des Apartments mit einer Intervalllänge von $\Delta T = 60$ sec (links) und $\Delta T = 600$ sec (rechts)

Betrachtet wurde hierbei das Schlafzimmer des Apartments des „Aruba-Datensatzes“. Die beiden Grafiken auf der linken Seite zeigen den Zellzustand $s(t)$ (oben) über einen Gesamtzeitraum von einer Woche, dargestellt mit einem Zeitintervall von $\Delta t = 60$ sec, die Wahrscheinlichkeitsfunktion $p(t)$ der Zelle sowie der anhand des Schwellwertes $c = 0.5$

prognostizierte Zellzustand $s'(t)$. Auf der rechten Seite der Abbildung befinden sich der Zellzustand $s(t)$ des Schlafzimmers mit einem Zeitintervall $\Delta t = 600 \text{ sec}$, die untere Grafik zeigt ebenfalls die Wahrscheinlichkeitsfunktion $p(t)$ der Zelle sowie den prognostizierten Zellzustand $s'(t)$. Während zur Bestimmung von $p(t)$ im Falle von $\Delta t = 60 \text{ sec}$ eine Modellordnung von $l = 2$ den Prädiktionsfehler auf einen Wert von $\epsilon_p = 0.178$ minimierte, beträgt die optimale Modellordnung bei $\Delta t = 600 \text{ sec}$ hingegen $l = 3$ mit einem Prädiktionsfehler von $\epsilon_p = 0.178$. Für den statischen Fall, also die Annahme einer konstanten Wahrscheinlichkeit $p_{\text{stat}}(t) = \text{const.}$, ergibt sich $\epsilon_p = 0.405$ für eine Intervalllänge von $\Delta t = 600 \text{ sec}$, der statische Prädiktionsfehler bei einer Intervalllänge von $\Delta t = 60 \text{ sec}$ berechnet sich zu $\epsilon_p = 0.353$. Die größere Intervalldauer spiegelt sich in dem Modell derart wieder, dass die Anzahl der Personendetektionen im Verhältnis zu der Anzahl n der Zeitstempel zunimmt, und die Breite der rot gestrichelten Balken in Bild 4.2 zunimmt.

Eine Limitation der Methodik ist jedoch in Bild 4.3 zu sehen. Betrachtet wurde hier der Zellzustand $s(t)$ des Gästeschlafzimmers innerhalb des Apartments.

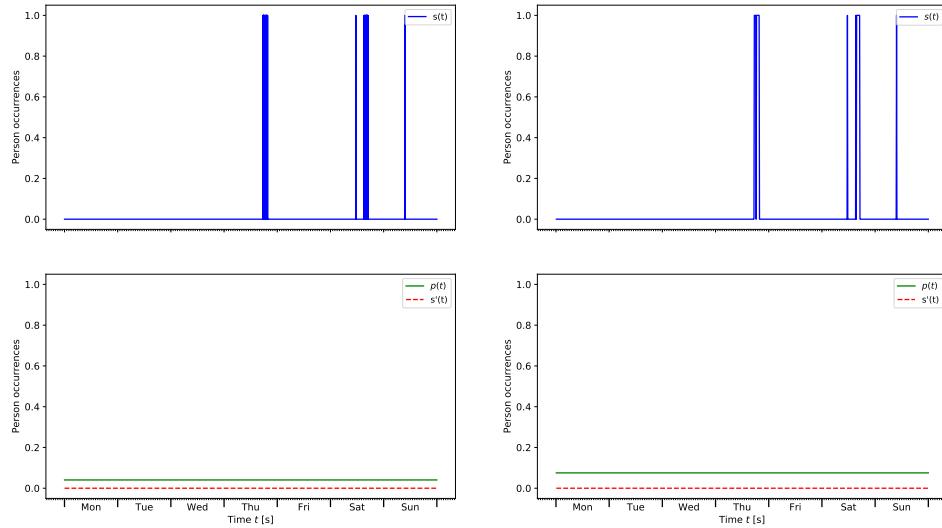


Bild 4.3: Vergleich des Zellzustandes $p(t)$ des Schlafzimmers des Apartments mit einer Intervalllänge von $\Delta T = 60 \text{ sec}$ (links) und $\Delta T = 600 \text{ sec}$ (rechts)

Bei einer Intervalldauer von $\Delta t = 60 \text{ sec}$ ergibt sich die im Sinne von Gleichung (3.13) optimale Modellordnung zu $l = 0$, dargestellt durch die konstante, statische Wahrscheinlichkeitsfunktion $p_{\text{stat}}(t)$. Zu dem selben Ergebnis kommt man bei einer Intervalldauer

von $\Delta t = 600$ sec. Auch hier beträgt die optimale Modellordnung $l = 0$. Durch die Erhöhung der Personendetektionen im Vergleich zur Anzahl der Zeitstempel liegt die statische Wahrscheinlichkeit einer Personendetektion in der rechten, unteren Grafik von Bild 4.3 bei $p_{\text{stat}}(t) = 0.075$, während in der unteren linken Grafik $p_{\text{stat}}(t) = 0.04$ gilt. Die seltenen, kurzfristigen Personendetektionen können nicht durch die maximale Modellordnung von $l_{\max} = 20$ modelliert werden. Eine weitere Erhöhung von l würde jedoch dazu führen, dass der Rekonstruktionsfehler ϵ_r zwar sinken würde, die Generalisierungsfähigkeit des Modells jedoch verloren geht und in der Folge zu einem Anstieg von ϵ_p führt. Der Prädiktionsfehler des statischen Modells bei einer Intervalldauer von $\Delta t = 600$ sec ergibt sich zu $\epsilon_p = 0.065$, im Falle von $\Delta t = 600$ sec zu $\epsilon_p = \text{NOCHEINFGEN}$

Einen zusammenfassenden Überblick der Modellfehler gibt Tabelle xxx. Hier sind, aufgeteilt nach den Intervalldauern, die Prädiktionsfehler ϵ_p aller Zellen für die optimale Modellordnung l_{opt} , sowie für den statischen Fall aufgeführt. Betrachtet wurden hierbei jedoch nur die Zellen, für welche die optimale Modellordnung nicht $l = 0$ betrug. Dies lässt sich dadurch erklären, dass für den Fall des Gästebadezimmers bei einer Intervalldauer von $\Delta t = 600$ sec der durchschnittliche Zellzustand bei $\bar{s}(t) = 0.075$ lag. Das statische Modell, welches einen konstanten Zellzustand von $s'_{\text{stat}}(t) = 0.0$ prognostiziert, liegt hier also bereits in 92.5 % der Fälle richtig. Somit lässt sich als eine Grenze des Modells erkennen, dass es nur sinnvoll auf Zellen anwendbar ist, welche einen minimalen durchschnittlichen Zellzustand $\bar{s}_{\min}(t)$ überschreiten.

Des Weiteren wurde die Methodik anhand des „UOL-Datensatzes“ evaluiert. Auch hier erfolgte die Bewertung verschiedener Intervalldauern Δt , in welche die Periodendauer T eingeteilt wurde. Wie in Abschnitt 4.1 erwähnt, wurden zur Ermittlung der Modellparameter die Daten von zwei aufeinander folgenden Wochen benutzt. Die Ermittlung der optimalen Modellordnung mittels eines minimalen Prädiktionsfehlers ϵ_p erfolgte mit Daten einer weiteren Woche. Bild 4.4 zeigt den Unterschied des binären Modells bei einer Intervalldauer von $\Delta t = 600$ sec (links) sowie für $\Delta t = 900$ sec (rechts) auf.

Für die kürzere Intervalldauer liegt die optimale Modellordnung bei $l = 10$ mit einem Prädiktionsfehler von $\epsilon_p = 0.151$. Der Prädiktionsfehler des statischen Modells liegt in diesem Fall hingegen bei $\epsilon_p = 0.285$. Des Weiteren lässt sich erkennen, dass das Modell den Wochentrend der Daten abbilden kann. An den beiden Wochenendtagen flachen die Amplituden der Wahrscheinlichkeitsfunktion des Zellzustandes $p(t)$ deutlich ab. Da sie den Schwellwert von $c = 0.5$ nicht überschreitet, liegt die Prädiktion des Zellzustandes während des Wochenendes bei $s'(t) = \text{const} = 0.0$. Bei einer Intervalldauer von $\Delta t = 900$ sec berechnet sich die optimale Modellordnung zu $l = 7$. Wie schon in Bild 4.2 resultiert eine Erhöhung der Intervalldauer T in einer Vergrößerung der Breite der rot gestrichelten Balken

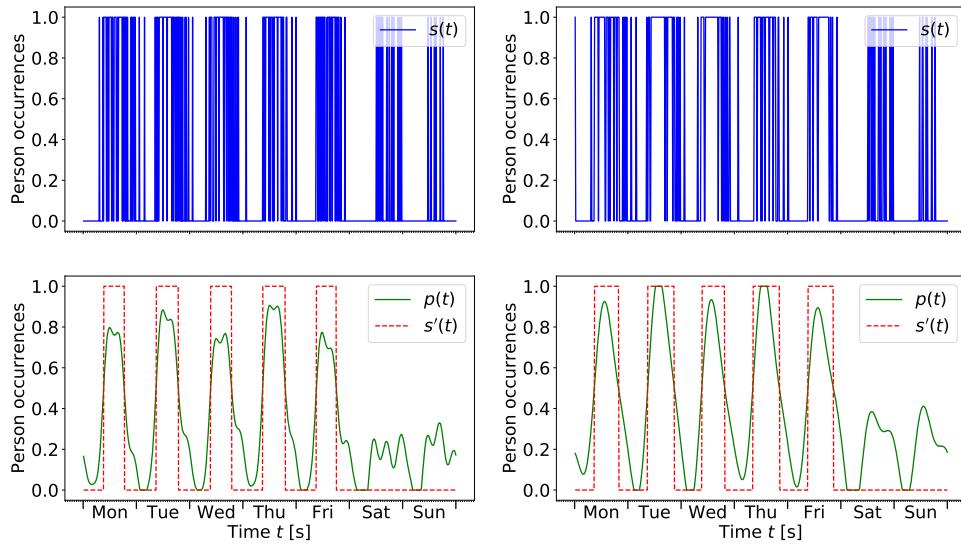


Bild 4.4: Zellzustand einer Beispielzelle des UOL-Datensatzes bei unterschiedlichen Intervalldauern

der Prädiktion des Zellzustandes $s'(t)$. Dies ist damit zu erklären, dass eine Verlängerung der Intervalldauer nach Gleichung 3.5 zu einer Erhöhung des durchschnittlichen Zellzustandes $\bar{s}(t)$ führt. Auch das Modell der größeren Intervalldauer kann den Wochentrend mit einem Abflachen der Personen-Auftrittswahrscheinlichkeiten während des Wochenendes abbilden. Liegt der Prädiktionsfehler der optimalen Modellordnung bei $\epsilon_p = 0.138$, so beträgt er bei dem statischen Zustandsmodell $\epsilon_p = 0.35$.

Einen zusammenfassenden Überblick der Modellfehler gibt Tabelle xxx. Aufgeteilt nach Intervallängen, sind hier die Prädiktionsfehler ϵ_p aller Zellen für die optimale Modellordnung l_{opt} sowie für das statische Zustandsmodell aufgelistet. Betrachtet wurden hierbei jedoch nur die Zellen, für welche die optimale Modellordnung nicht $l = 0$ betrug.

4.4 Quantitatives Modell

4.4.1 Einfluss der Intervalldauer

In diesem Abschnitt wird der Einfluss der Intervalldauer Δt auf das Modell untersucht. Betrachtet wird der quantitative Fall, d.h. der betrachtete Wert ist nun die Personenrate $\lambda(t)$, also die Anzahl von Personen innerhalb eines Zeitintervalls. Veranschaulicht wird dies in

Bild 4.5.

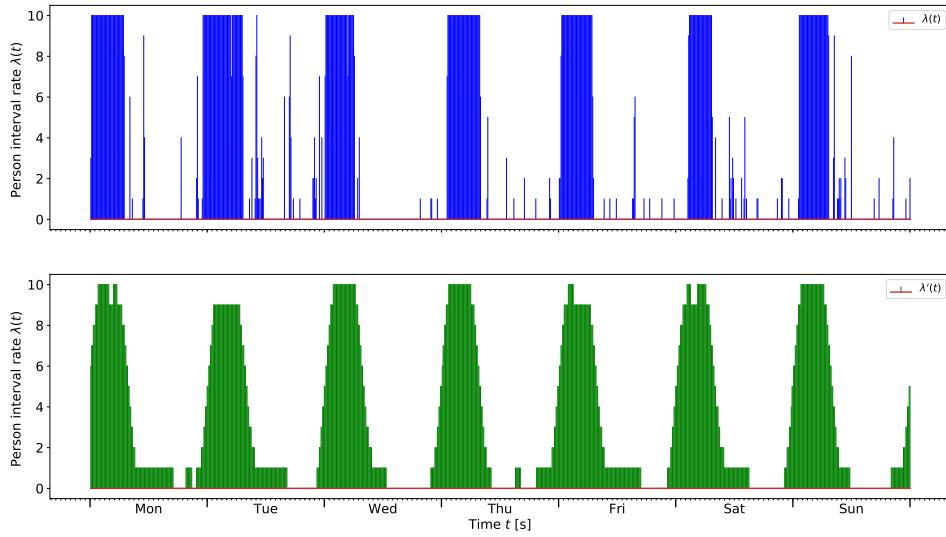


Bild 4.5: Personenrate $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 600 \text{ sec}$ (oben) und Approximation $\lambda'(t)$ (unten)

Dargestellt sind hier die Personenraten $\lambda(t)$ des Schlafzimmers des „Aruba-Datensatzes“ bei einer Intervalllänge von $\Delta t = 600 \text{ sec}$ (oben). Die optimale Modellordnung zur Berechnung von $\lambda'(t)$, also der Approximation der tatsächlichen Personenrate $\lambda(t)$, liegt hier bei $l = 5$. Die Approximation ist in der unteren Grafik von Bild 4.5 aufgezeichnet. Der Prädiktionsfehler ergibt sich zu $\epsilon_p = 2.61$. Der Fehler wurde nach dem „least-square mean error“ berechnet, die von dem Modell prognostizierte Personenrate $\lambda'(t)$ hat also eine durchschnittliche Differenz von 2.61 Personen pro Intervall von den tatsächlichen Daten. Die statische Personenrate $\lambda_{\text{stat}}(t)$ ist in Bild 4.5 als gestrichelte gelbe Linie eingezeichnet und beträgt $\lambda_{\text{stat}}(t) = xxx$. Der Prädiktionsfehler des statischen Modells liegt bei $\epsilon_p = 4.46$.

Bild 4.6 stellt $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 900 \text{ sec}$ dar. Im Vergleich zu Bild 4.5 liegen die Peaks von $\lambda(t)$ hier höher, was durch die größere Intervalldauer begründet ist. Die untere Grafik von 4.6 stellt erneut die im Sinne von Gleichung (xxx) optimale Approximation $\lambda'(t)$ von $\lambda(t)$ dar. Die Ordnung dieser liegt erneut bei $l = 5$. Der Prädiktionsfehler ϵ_p liegt hier bei 3.81. Die gelb gestrichelte Linie in der unteren Grafik stellt erneut die Personenrate $\lambda_{\text{stat}}(t) = xxx$ des statischen Modells dar. Der Prädiktionsfehler des statischen Modells liegt bei $\epsilon_p = 6.62$

Im Vergleich zum statischen Modell kann also mit einer Modellordnung von $l_{\text{opt}} = \text{xxx}$ eine Verbesserung um $\text{xxx} \%$ erreicht werden.

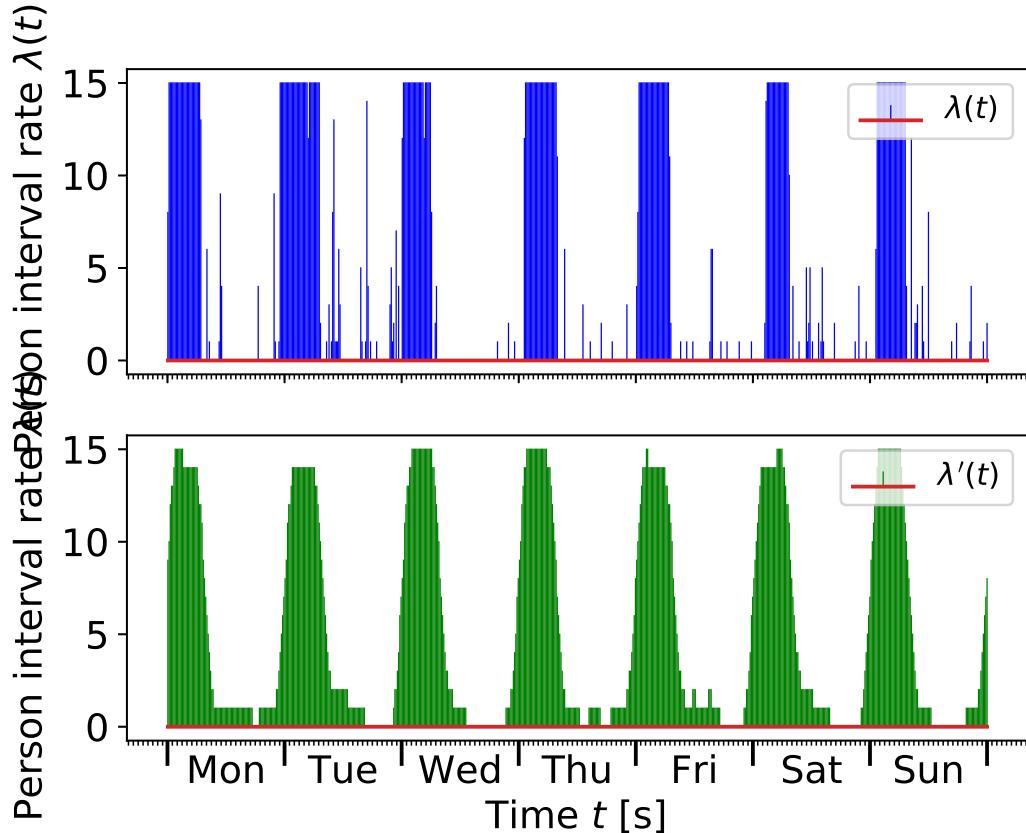


Bild 4.6: Personenrate $\lambda(t)$ bei einer Intervalldauer von $\Delta T = 600$ sec (oben) und Approximation $\lambda'(t)$ (unten)

Die Personenraten $\lambda(t)$ des Gästeschlafzimmers mit einer Intervalldauer von $\Delta t = 600$ sec sind in Bild 4.7 aufgezeichnet. Die beste Approximation $\lambda'(t)$ wird hierbei mit einer Ordnung von $l = 0$, also dem statischen Modell, erreicht. Die Prädiktion lautet für alle Intervalle $\lambda'_{\text{stat}}(t) = 0$. Der Prädiktionsfehler beträgt $\epsilon_p = 1.39$. Im Vergleich zum statischen Modell kann also mit einer Modellordnung von $l_{\text{opt}} = \text{xxx}$ eine Verbesserung um $\text{xxx} \%$ erreicht werden.

Die untere Grafik von Bild 4.8 veranschaulicht $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 900$ sec. Die beste Approximation wird in diesem Fall ebenfalls mit einer Modellordnung von $l = 0$, also dem statischen Modell mit $\lambda'_{\text{stat}}(t) = \text{const}$, erreicht. Die Prädiktion lautet nun für

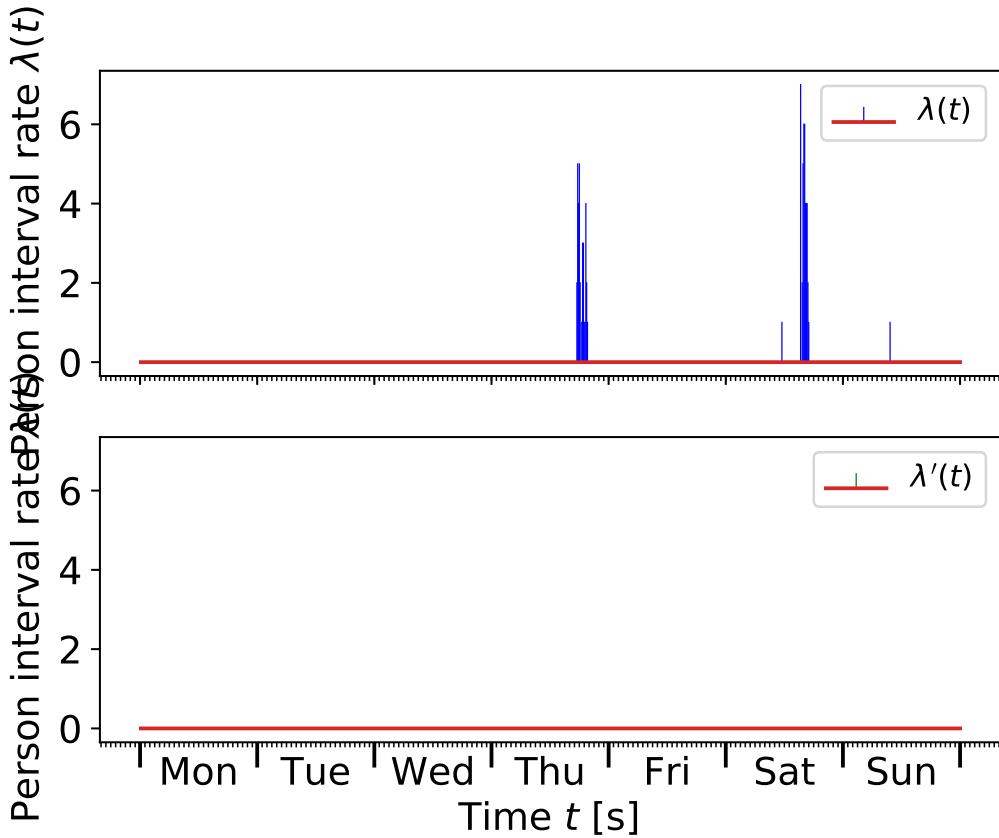


Bild 4.7: Personenrate $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 600$ sec (oben) und Approximation $\lambda'(t)$ (unten)

alle Intervalle $\lambda'_{\text{stat}}(t) = 1$. Dies ist dadurch zu begründen, dass die durchschnittliche Personenrate bei größerer Intervalldauer steigt, und somit im Gegensatz zu Bild 4.7 auf die nächstgelegene natürliche Zahl gerundet wird, welche in diesem Fall 1 beträgt.

Der Prädiktionsfehler beträgt hier $\epsilon_p = 2.04$. In Tabelle xxx sind die durchschnittlichen Prädiktionsfehler der Zellen des Datensatzes bei verschiedenen Intervalldauern aufgeführt. In die Fehlerermittlung flossen nur solche Zellen ein, bei denen die durchschnittliche Personenrate $\bar{\lambda}(t)$ über einem Wert von 0.5 lag. Erneut zeigt sich wie schon in Abschnitt 4.3 eine Limitation des Modells. Für eine Steigerung der Approximationsgenauigkeit im Vergleich zum statischen Modell muss die Zelle eine minimale Personenrate übersteigen.

Eine weitere Evaluation des Modells erfolgt anhand des „UOL-Datensatzes“. Bild 4.9 zeigt hier die Personenraten $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 600$ sec sowie die optimale

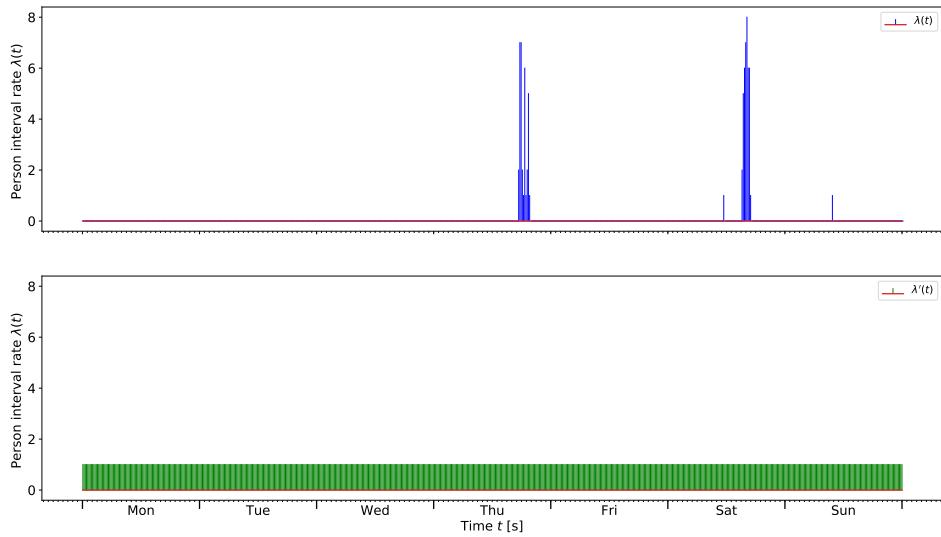


Bild 4.8: Personenrate $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 600$ sec (oben) und Approximation $\lambda'(t)$ (unten)

Modellordnung zur Minimierung des Prädiktionsfehlers ϵ_p .

Für die genannte Intervalldauer ergibt sich die optimale Modellordnung zu $l_{\text{opt}} = 2$, bei einem Prädiktionsfehler von $\epsilon_p = 11.38$. Dieser, im Vergleich zu dem quantitativen Modell des „Aruba-Datensatzes“, hohe Fehler lässt sich durch die höhere Varianz der einzelnen Wochen innerhalb des „UOL-Datensatzes“ erklären. Jedoch lassen sich auch hier der Tag-Nacht-Rhythmus sowie ein Abflachen der Personenraten während der beiden Wochenendtage erkennen. In der unteren Grafik von Bild 4.9 ist außerdem das statische Modell (gelbgestrichelte Linie) eingezeichnet. Die Annahme einer statischen Rate an Personen von $\lambda'_{\text{stat}}(t) = \text{const.} = 1.43$ resultiert in einem Prädiktionsfehler von $\epsilon_p = 11.46$. Im Vergleich zum statischen Modell kann also mit einer Modellordnung von $l_{\text{opt}} = 2$ eine Verbesserung um 0.7 % erreicht werden.

Das Modell bei einer Intervalldauer von $\Delta t = 900$ sec ist in Bild 4.10 dargestellt.

Zu erkennen ist, dass im Vergleich zu Bild 4.9 hier die Personenraten λt höher liegen. Dies ist erneut durch die längere Intervalldauer Δt zu erklären, und wird durch die in gelb gestrichelt eingezeichnete statische Personenrate $\lambda'_{\text{stat}}(t) = xxx$ deutlich. Für $\Delta t = 900$ sec liegt die optimale Modellordnung ebenfalls bei $l_{\text{opt}} = 2$, mit einem Prädiktionsfehler von $\epsilon_p = 14.51$. Im Vergleich dazu liegt der Prädiktionsfehler des statischen Modells bei $\epsilon_p = 14.65$, es

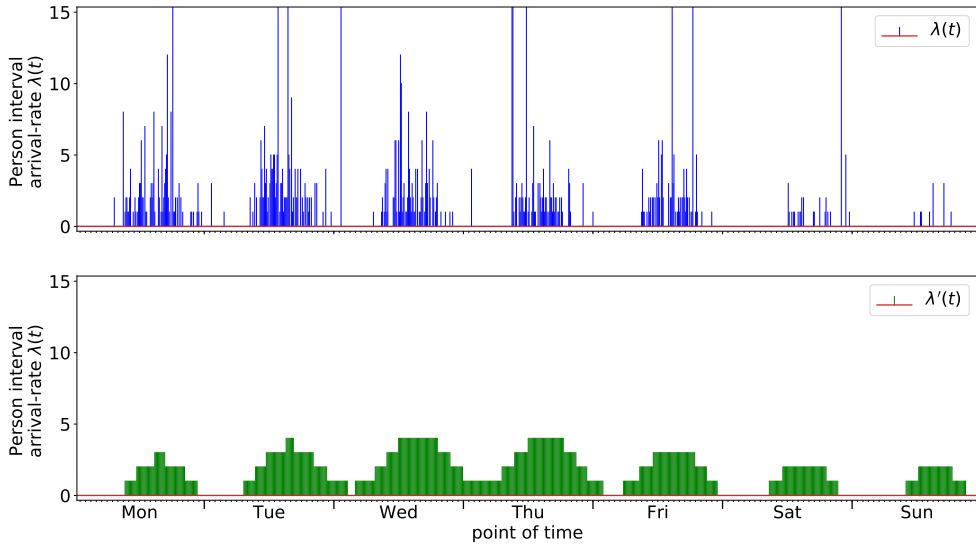


Bild 4.9: Personenraten einer Beispielzelle bei einer Intervalldauer von $\Delta t = 600$ sec mit optimaler Modellordnung und statischem Modell

konnte also eine Verbesserung um 0.95 % erreicht werden.

In Tabelle xxx sind die durchschnittlichen Prädiktionsfehler der Zellen des Datensatzes bei verschiedenen Intervalldauern aufgeführt. Verglichen werden hier erneut die Fehler der Modelle mit einer optimalen Modellordnung, demgegenüber gestellt sind die Prädiktionsfehler ϵ_p der statischen Modelle. In die Fehlerermittlung flossen nur solche Zellen ein, bei denen die durchschnittliche Personenrate $\lambda(t)$ über einem Wert von 0.5 lag.

4.5 Einfluss der Zellengröße (nur für uol-Datensatz)

4.6 Einfluss der Periodendauer

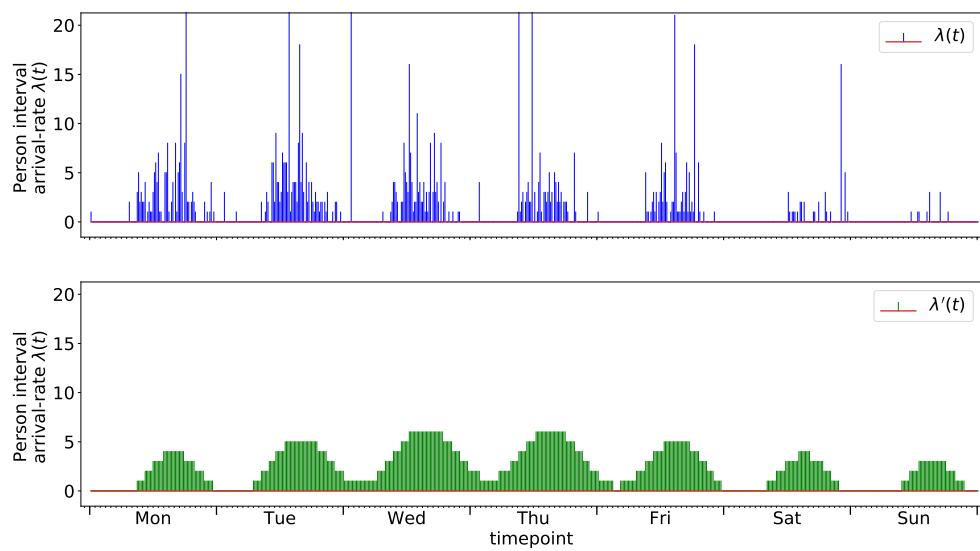


Bild 4.10: Personenraten einer Beispielzelle bei einer Intervalldauer von $\Delta t = 900$ sec mit optimaler Modellordnung und statischem Modell

5 Tipps zur Erstellung der Arbeit

Im Folgenden sind einige Tipps zur schriftlichen Ausarbeitung zu finden, z. B. zur korrekten Darstellung von Gleichungen und Grafiken oder zum Bezug der dazu notwendigen Software. Grundsätzlich lassen sich unter folgendem Link Hilfestellungen zu den meisten Problemen bei der Erstellung Arbeit finden: <http://bfy.tw/Bq9t>

5.1 Darstellung von Gleichungen

Der am imes verwendete Formelsatz entspricht der DIN 1338 und lässt sich auch in sämtlichen Skripten des imes wiederfinden, z. B. in Robotik I, Robotik II oder Mechatronische Systeme.

Grundsätzlich gilt: Variablennamen werden kursiv gesetzt (auch wenn diese als Index benutzt werden, z. B. a_i), beschreibende Indizes (z. B. b_{Reifen} oder b_R) und allgemeine Funktionen (z. B. Sinus- oder e-Funktion) aufrecht:

$$f(t) = \int_{t_{\text{start}}}^{t_{\text{end}}} \sin(\omega t) dt. \quad (5.1)$$

Bei der ersten Verwendung von Variablen sollten diese unmittelbar vor oder nach der Gleichung im Text erläutert werden, in diesem Fall die exemplarische Funktion $f(t)$, Start- und Endzeitpunkt t_{start} bzw. t_{end} , Kreisfrequenz ω und Zeit t .

Matrizen und Vektoren werden fett gedruckt dargestellt. Matrizen werden mit großen, Vektoren mit kleinen Buchstaben bezeichnet. In der Gleichung

$$\mathbf{q} = (q_1, q_2, \dots, q_n)^T \quad (5.2)$$

beschreibt \mathbf{q} den Vektor mit allen Gelenkwinkeln, q_1 hingegen den Gelenkwinkel der ersten Achse. Zahlreiche weitere Beispiele zur Darstellung von Formeln können in den oben genannten Skripten nachgeschlagen werden.

Weitere Beispiele für korrekten Formelsatz:

TODO -> versch. Stellen aus Skripten suchen und Code kopieren

5.2 Darstellung von Grafiken

Grafiken sollten nach Möglichkeit als Vektorgrafiken (z. B. .eps, .pdf) exportiert und in LaTeX eingebunden werden. Die Schriftart sollte der Schriftart der restlichen Arbeit entsprechen (Times). Die Schriftgröße in der Grafik sollte kleiner oder gleich der Größe des Fließtextes sein (nach eigenem Ermessen, solange die Lesbarkeit noch gegeben ist). Auch bei Abbildungen sind die Formatierungsschriften aus Abschnitt 5.1 einzuhalten. Ein Beispielplot aus Matlab ist in Bild 5.1 dargestellt. Das Skript zur Erstellung des Plots in Matlab ist unter `template_einfach.m` zu finden.

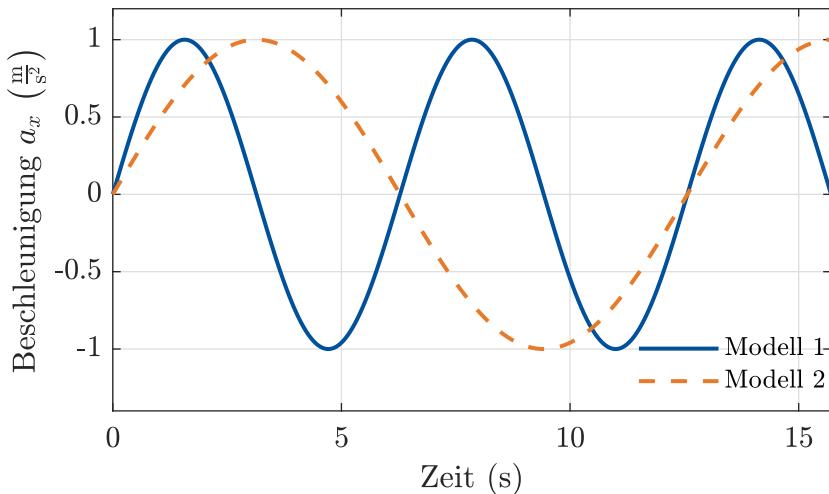


Bild 5.1: Vergleich der zeitlichen Beschleunigungsverläufe der beiden Modellierungsansätze Hü (blau) und Hott (orange gestrichelt)

5.3 Software

5.3.1 Matlab, Corel

Für Matlab und Corel sind an der Uni Hannover kostenlose Campuslizenzen verfügbar. Anleitungen zum Bezug sind unter <https://www.luis.uni-hannover.de/softwarekatalog.html> zu finden. Für Corel existiert am imes ein Plugin zur Nutzung von LaTeX-Befehlen. Das Plugin und die zugehörige Anleitung sind im Vorlagenordner zu finden. Alternativ zu Corel kann auch die freie Software Inkscape genutzt werden (<https://inkscape.org>).

5.3.2 LaTeX

Vorschläge für TeX-Distributionen:

- MiKTeX (Windows): <https://miktex.org/>
- TeXLive (allg.): <http://www.tug.org/texlive/>

Vorschläge für Texteditoren:

- TeXnicCenter (Windows): <http://www.texniccenter.org/>
- TeXMaker (allg.): <http://www.xm1math.net/texmaker/>

5.4 Literaturverweise

Beispiele für Literaturverweise sind im Literaturverzeichnis zu finden, z. B. Journalbeitrag [Ber59], Konferenzbeitrag [Hus+08], Buch [WH09]. Sofern nicht explizit anders eingestellt, taucht nur diejenige Literatur im Verzeichnis auf, auf die in der Arbeit verwiesen wird.

5.5 Eigene Befehle in LaTeX

In LaTeX können auch eigene Befehle definiert und genutzt werden, z. B. zur Verwendung immer wiederkehrender Formelzeichen. So kann beispielsweise ein Koordinatensystem $(KS)_A$ direkt mit dem Befehl `\ks{A}` eingefügt werden. Eine Liste der Befehle ist in der Datei `befehle.sty` zu finden.

6 Betreuer- und/oder projektspezifische Anmerkungen

Für Ergänzungen zur Vorlage, die nicht allgemeingültig sind, bitte ausschließlich dieses Kapitel nutzen!

ToDos für die Vorlage:

- Aufgabenstellung direkt ins Dokument, Platzhalter-pdf, manuell reinsortieren?
- mehr Beispiele für Formelsatz aus versch. Skripten reinkopieren
- Befehle.sty erläutern

7 (Beispielkapitel) Robotersysteme

Das folgende Kapitel soll als Beispielkapitel dienen. Nach der Kapitelüberschrift wird der Kapitelinhalt in ein paar Sätzen beschrieben. Hier steht weiterer Text.

7.1 PR2

Der PR2 (Willow Garage Inc., Menlo Park, USA) ist ein **menschenähnlicher** Serviceroboter, der seinen Dienst in Wohnräumen verrichten soll und derzeit im sogenannten PR2 Beta-Programm von elf Forschungseinrichtungen über einen Zeitraum von zwei Jahren getestet wird [Wil10]. Hier steht weiterer Text. d

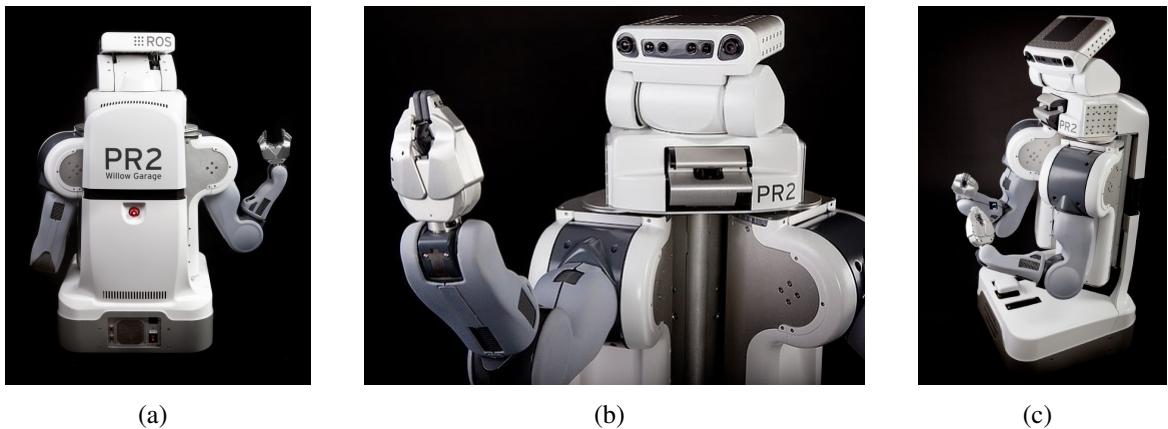


Bild 7.1: Serviceroboter PR2 von Willow Garage (Quelle: Willow Garage))

Ausgestattet ist der PR2 mit zwei Armen, die jeweils sieben Freiheitsgrade haben und an deren Enden ein Greifer montiert ist, siehe Bild 7.1. Die Sensorik des Armes besteht aus einer Kamera am Unterarm und Druck- sowie Beschleunigungssensoren am Greifer. Die Nutzlast eines Arms ist mit 1,8 kg ausgewiesen. Weiterhin verfügt der Roboter über einen dreh- und schwenkbaren Kopf, in dem eine 5-Megapixel Farbkamera, ein LED-Texturprojektor und zwei Stereokameras integriert sind, wobei eine Kamera für die Fernsicht und die andere für die Objektmanipulation genutzt wird. Unterhalb des Kopfes ist ein schwenkbarer Laserscanner und ein Inertialsensor verbaut. Die Position des Oberkörpers lässt sich in der Höhe

zwischen 1330 mm und 1645 mm (Gesamthöhe) variieren. Angetrieben wird die omnidirektionale Basis von vier gelenkten Rädern, die eine maximale Geschwindigkeit von 3,6 km/h ermöglichen. Die quadratische Basis hat eine Kantenlänge von 668 mm. Als Recheneinheit stehen zwei Server zur Verfügung, die jeweils auf acht CPU-Kernen rechnen und dabei auf 24 GB Arbeitsspeicher zugreifen können. Als Betriebssystem wird Ubuntu verwendet, auf dem das Robot Operating System, kurz ROS, die Grundlage für die Datenverarbeitung bildet. Da ROS innerhalb dieser Arbeit ebenfalls zum Einsatz kommt, wird dieses in Abschnitt 7.2 vorgestellt und an den entsprechenden Stellen weiter erläutert. Die Kosten für einen PR2-Roboter belaufen sich derzeit auf etwa 400 000 US-Dollar¹. Mit Hilfe des PR2 wurden von den zuvor erwähnten Beta-Testern Szenarien bewältigt, die innerhalb des menschlichen Wohnraumes auftreten können. An der TU München hat ein PR2-Roboter beispielsweise zusammen mit einem anderen Robotersystem einen Pfannkuchen gebacken [Mün11].

7.2 ROS

Hier steht weiterer Text.

Listing 7.1: Launchfile zum Start der hokuyo_node

```

1 <!-- launch hokuyo node -->
2 <node pkg="hokuyo_node" type="hokuyo_node" name="hokuyo_node" output
   ="screen">
3   <param name="port" value="/dev/ttyACM0"/>
4   <param name="frame_id" value="/base_laser_front_link"/>
5 </node>
```

¹Der angegebene Preis wurde am 16.08.2011 der Website <http://www.willowgarage.com/pages/pr2/order> entnommen und versteht sich exklusive Steuern und Versandkosten.

Tabelle 7.1: Technische Daten der youBot Plattform

Bezeichnung	Formelzeichen	
Gesamtlänge	a	530 mm
Gesamtbreite	b	350 mm
Höhe	h	106 mm
Radstand	l	470 mm

Anhang

Literatur

- [Ber59] R. Bertodo. „Development of High-temperature Strain Gauges“. In: *Proceedings of the Institution of Mechanical Engineers* 173.23 (1959), S. 605–616.
- [Bun] Bundesverband Geothermie, Hrsg. *Das Nyquist-Shannonsche Abtasttheorem*. URL: <https://www.geothermie.de/bibliothek/lexikon-der-geothermie/a/abtasttheorem.html>.
- [EKS06] Hans Joachim Eichler, Heinz-Detlef Kronfeldt und Jürgen Sahm. *Das neue physikalische Grundpraktikum*. Zweite, erweiterte und aktualisierte Auflage. Springer-Lehrbuch. Berlin: Springer, 2006. ISBN: 9783540299684. DOI: 10.1007/3-540-29968-8. URL: <http://site.ebrary.com/lib/alltitles/docDetail.action?docID=10145474>.
- [HSB02] D. Hahnel, D. Schulz und W. Burgard. „Map building with mobile robots in populated environments“. In: *IEEE/RSJ International Conference on Intelligent Robots and System*. IEEE, 30 Sept.-5 Oct. 2002, S. 496–501. ISBN: 0-7803-7398-7. DOI: 10.1109/IRDS.2002.1041439.
- [Hus+08] Andreas Hussong, Thomas Rau, Hubertus Eilers, Stephan Baron, Bodo Heimann, Martin Leinung, Thomas Lenarz und Omid Majdani. „Conception and design of an automated insertion tool for cochlear implants“. In: *Proc. 30th Annual Int. Conf. of the IEEE Engineering in Medicine and Biology Society EMBS 2008*. 2008, S. 5593–5596. DOI: 10.1109/EMBS.2008.4650482.
- [Jov+16] Ferdian Jovan, Jeremy Wyatt, Nick Hawes und Tomas Krajnik. „A Poisson-spectral model for modelling temporal patterns in human data observed by a robot“. In: *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (2016), S. 4013–4018. DOI: 10.1109/iros.2016.7759591.
- [Kra+14] Tomas Krajnik, Jaime Pulido Fentanes, Grzegorz Cielniak, Christian Dondrup und Tom Duckett. „Spectral analysis for long-term robotic mapping“. In: *IEEE International Conference on Robotics and Automation (ICRA), 2014*. Piscataway, NJ: IEEE, 2014, S. 3706–3711. ISBN: 978-1-4799-3685-4. DOI: 10.1109/ICRA.2014.6907396.

- [Kra+15] Tomas Krajnik, Miroslav Kulich, Lenka Mudrova, Rares Ambrus und Tom Duckett. „Where’s waldo at time t ? using spatio-temporal models for mobile robot search“. In: *2015 IEEE International Conference on Robotics and Automation (ICRA 2015)*. Piscataway, NJ: IEEE, 2015, S. 2140–2146. ISBN: 978-1-4799-6923-4. DOI: 10.1109/ICRA.2015.7139481.
- [KSD15] Tomas Krajnik, Joao M. Santos und Tom Duckett. „Life-long spatio-temporal exploration of dynamic environments“. In: *2015 European Conference on Mobile Robots (ECMR) (2015)*, S. 1–8. DOI: 10.1109/ecmr.2015.7324052.
- [Mar+] Marvin Stüde, Timo Lerche, Martin Alexander Petersen, Moritz Schappler und Tobias Ortmaier. „Behavior Tree-Based Person Search for Symbiotic Autonomous Mobile Robot Tasks“. In: *2020*.
- [MMM08] Luis Montesano, Javier Minguez und Luis Montano. „Modeling dynamic scenarios for local sensor-based motion planning“. In: *Autonomous Robots 25.3* (2008), S. 231–251. ISSN: 0929-5593. DOI: 10.1007/s10514-008-9092-9.
- [Mün11] Technische Universität München. *TUM Rosie and PR2 James make pancakes together*. Englisch. Abrufdatum: 18.12.2011. Okt. 2011. URL: <http://www.willowgarage.com/blog/2010/10/21/tum-rosie-and-pr2-james-make-pancakes-together>.
- [MW10] Michael Milford und Gordon Wyeth. „Persistent Navigation and Mapping using a Biologically Inspired SLAM System“. In: *The International Journal of Robotics Research 29.9* (2010), S. 1131–1153. ISSN: 0278-3649. DOI: 10.1177/0278364909340592.
- [TT14] Gerald Teschl und Susanne Teschl. *Mathematik für Informatiker: Band 2: Analysis und Statistik*. 3., überarb. Aufl. eXamen.press. Berlin: Springer, 2014. ISBN: 9783642542749. DOI: 10.1007/978-3-642-54274-9.
- [WA05] Andreas Wendemuth und Edin Andelic. *Grundlagen der digitalen Signalverarbeitung: Ein mathematischer Zugang*. Springer-Lehrbuch. Berlin, Heidelberg: Springer-Verlag Berlin Heidelberg, 2005. ISBN: 9783540267706. DOI: 10.1007/b138044. URL: <http://gbv.eblib.com/patron/FullRecord.aspx?p=1156293>.
- [WH09] Erich Wintermantel und Suk-Woo Ha. *Medizintechnik – Life Science Engineering*. 5. Auflage. München, Schaffhausen: Springer, März 2009. Kap. Funktionsersatz des Innenohres, S. 1401–1417.

- [Wil10] Willow Garage. *The Results Are In: PR2 Beta Program Recipients!* Englisch. Abrufdatum: 16.08.2011. Mai 2010. URL: <http://www.willowgarage.com/blog/2010/05/04/pr2-beta-program-recipients>.