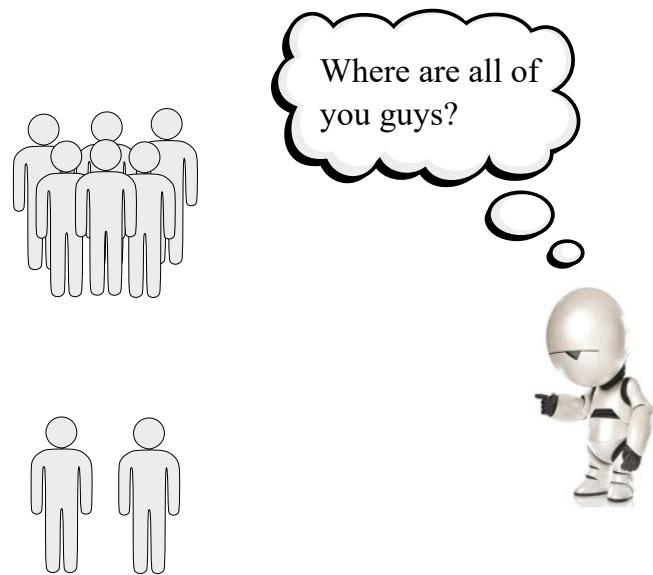


Frequenzbasierte Modellierung zur Prädiktion von Personen-Auftrittswahrscheinlichkeiten



Studienarbeit S-01/2021-997

Adrian Kleimeier
Matrikelnummer 3111950

Hannover, 14. Januar 2021

Prüfer Prof. Dr.-Ing. Tobias Ortmaier
Betreuer Marvin Stüde, M.Sc.

Ich, Adrian Kleimeier, versichere hiermit, dass die vorliegende Arbeit selbstständig verfasst wurde, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt wurden, alle Stellen der Arbeit, die wörtlich oder sinngemäß aus anderen Quellen übernommen wurden, als solche kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen hat.

Hannover, 14. Januar 2021

(Adrian Kleimeier)

Studienarbeit

Herr Adrian Kleimeier, Matr.-Nr. 3111950

Frequenzbasierte Modellierung zur Prädiktion von Personen-Auftrittswahrscheinlichkeiten

Time and location dependent prediction of environmental features for the prediction of person occurrence probabilities

Allgemeines:

Das Institut für Mechatronische Systeme beschäftigt sich mit der Erforschung der Umweltmodellierung und Verhaltenssteuerung mobiler Serviceroboter systeme. Dabei wird unter anderem ein Serviceroboter system zur Informationsbereitstellung entwickelt. Um eine möglichst hohe Rate an Mensch-Roboter-Interaktionen zu erreichen, soll der Roboter Informationen über das zeit- und ortsabhängige Personenaufkommen aufnehmen und verarbeiten um anschließend die voraussichtlich benötigte Zeit einer Kontaktaufnahme mit einem Menschen zu minimieren. In der Forschung existieren Modelle zur Prädiktion dieser Umweltzustände auf Basis von binären sowie quantitativen Darstellungen, die für diese Anwendung untersucht werden sollen.

Aufgabe:

Im Rahmen dieser Arbeit soll eine Methodik zur frequenzbasierten Umgebungsmodellierung durch mobile Robotersysteme, für typische Umgebungen wie bspw. Büroräume oder Campusflächen, entwickelt werden. Als Ansatz einer solchen Methodik kann das FrEMEn- Modell dienen. Die Grundidee der Methode ist die Transformation binärer zeit- und ortsabhängiger Darstellungen elementarer Umweltzustände in den Frequenzbereich. In diesem werden die dominantesten Frequenzen identifiziert und auf Basis dieser eine inverse Fouriertransformation durchgeführt zur Prädiktion von Umweltzuständen durchgeführt. Hierfür sollen verschiedene Zustandsrepräsentationen, wie die Erweiterung binärer Darstellungen in quantitative Darstellungen, implementiert und evaluiert werden.

Im Rahmen dieser Arbeit ergeben sich insbesondere die folgenden Aufgabenpunkte:

- Literaturrecherche über Methoden der binären sowie quantitativen Darstellung von Umweltzuständen
- Entwicklung einer Methodik und Anpassung an den vorliegenden Anwendungsfall
- Überprüfung der Modellgüte bei unterschiedlichen Periodendauern mittels eines Testdatensatzes
- Evaluation der Modellgüte bei unterschiedlichen Periodendauern mittels Simulationsdaten oder verfügbarer Datensätze
- Ermittlung weiterführender Fragestellungen zur Optimierung der kurzfristigen Vorhersagegüte des Modells

Die Bearbeitungszeit beträgt 300h

Ausgabe der Aufgabenstellung: 15.07.2021

Betreuer: M. Sc. Marvin Stüde

15

Abgabe der Arbeit: 14.01.2021

.....
(Prof. T. Ortmaier)

.....
(Adrian Kleimeier)

Inhaltsverzeichnis

1 Einleitung	1
2 Grundlagen und Stand der Technik	3
2.1 Fourierreihen und Fouriertransformation	3
2.2 Diskrete Fouriertransformation	5
2.3 Wahrscheinlichkeitsverteilungen	6
2.3.1 Binomialverteilung	6
2.3.2 Poissonverteilung	7
2.4 Beschreibung binärer Zustandsmodelle	8
2.5 Beschreibung quantitativer Zustandsmodelle	16
3 Methodik	20
3.1 Binäre Zustandsmodelle	20
3.1.1 Messdatenermittlung eines Belegtheitsgitters	20
3.1.2 Verarbeitung der Messdaten Client-seitig	24
3.1.3 Verarbeitung der Messdaten Server-seitig	25
3.2 Quantitative Zustandsmodelle	28
3.2.1 Messdatenermittlung eines Belegtheitsgitters	28
3.2.2 Verarbeitung der Messdaten Client-seitig	29
3.2.3 Verarbeitung der Messdaten Server-seitig	29
4 Evaluation	31
4.1 Datensätze	31
4.2 Beschreibung der Fehlermaße	31
4.2.1 Fehlermaße binäres Modell	31
4.2.2 Fehlermaße quantitatives Modell	32
4.3 Binäres Modell	33
4.4 Quantitatives Modell	37
5 Diskussion und Ausblick	43
Literaturverzeichnis	45

Bildverzeichnis

2.1	Periodisches Signal mit zugehörigem Amplituden- und Phasenspektrum [EKS06]	4
2.2	Originalsignal und durch Abtastung rekonstruiertes Signal	6
2.3	Binomialverteilung Beispiel	7
2.4	Beispiel eines über die Zeit gemessenen Zellzustandes sowie seines Spektralmodells und seiner Wahrscheinlichkeitsprädiktion [KFC ⁺ 14]	11
2.5	Modellgenauigkeit vs. Modellordnung [KFC ⁺ 14]	12
2.6	PerGaM und FreMEn Modellvergleich [KKM ⁺ 15]	14
2.7	Aktivitätsraten λ des Poisson-Prozess-Modells ermittelt anhand eines 4 Wochen Zeitraumes [JWHK16]	17
2.8	Vergleich l Best Amplitude Model und l Addition Amplitude Model [JWHK16]	18
3.1	Belegungskarte grafische Darstellung	21
3.2	Vergleich Personendetektion binärer und quantitativer Fall	24
3.3	Informationsfluss binäres Modell	25
3.4	Informationsfluss quantitatives Modell	29
4.1	Rekonstruktionsfehler ϵ_r und Prädiktionsfehler ϵ_p mit steigender Modellordnung	32
4.2	Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ des Schlafzimmers des Apartments mit einer Intervalldauer von $\Delta t = 600\text{ s}$ und $\Delta t = 900\text{ s}$	33
4.3	Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ des Gästeschlafzimmers des Apartments mit einer Intervalldauer von $\Delta t = 600\text{ s}$ und $\Delta t = 900\text{ s}$	35
4.4	Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ einer Beispielzelle des UOL-Datensatzes mit einer Intervalldauer von $\Delta t = 600\text{ s}$ (links) und $\Delta t = 900\text{ s}$ (rechts)	36
4.5	Personenrate $\lambda(t)$ des Schlafzimmers bei einer Intervalldauer von $\Delta t = 600\text{ s}$ und Approximation $\lambda'(t)$	37

4.6 Personenrate $\lambda(t)$ des Schlafzimmers bei einer Intervalldauer von $\Delta t = 600$ s und Approximation $\lambda'(t)$	38
4.7 Personenrate $\lambda(t)$ des Gästeschlafzimmers bei einer Intervalldauer von $\Delta t = 600$ s und Approximation $\lambda'(t)$	39
4.8 Personenrate $\lambda(t)$ des Gästeschlafzimmers bei einer Intervalldauer von $\Delta t = 600$ s und Approximation $\lambda'(t)$	40
4.9 Personenraten einer Beispielzelle des UOL Datensatzes bei einer Intervall-dauer von $\Delta t = 600$ s mit optimaler Modellordnung	41
4.10 Personenraten einer Beispielzelle des UOL Datensatzes bei einer Intervall-dauer von $\Delta t = 900$ s mit optimaler Modellordnung	42

Tabellenverzeichnis

4.1	Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern Δt (Aruba)	35
4.2	Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern Δt (UOL)	37
4.3	Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern (Aruba) Δt	40
4.4	Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern (UOL) Δt	41

Nomenklatur

Selten bzw. nur abschnittsweise verwendete Symbole und Formelzeichen sowie abweichende Bedeutungen werden ausschließlich im Text beschrieben.

Allgemeine Konventionen

Skalar	Klein- oder Großbuchstabe (kursiv): a, A
Vektor	Kleinbuchstabe (fett und kursiv): \boldsymbol{a}
Matrix	Großbuchstabe (fett und kursiv): \boldsymbol{A}
Punkt	Klein- oder Großbuchstabe: a, A

Koordinatensysteme

$(KS)_{\mathcal{U}}$ Koordinatensystem der Umgebung \mathcal{U}

Abkürzungen

FreMEn	Frequency Map Enhancement
FFT	Fast Fourier Transformation
DFT	Diskrete Fourier-Transformation
GMM	Gaussian Mixture Models

1 Einleitung

Mobile Roboter finden immer mehr Einzug in die heutige Zeit. Als Beispiele seien mobile Staubsaug-Roboter oder Rasenmäh-Roboter sowie mobile Serviceroboter, welche mit Menschen interagieren können, zu nennen. All diesen verschiedenen Roboterarten liegt die Gemeinsamkeit zugrunde, dass sie für die effektive Bearbeitung ihrer Aufgaben auf eine modellierte Repräsentation ihrer Umgebung angewiesen sind. Für eine solche Umgebungsrepräsentation bestehen verschiedene Ansätze. Einige dieser Ansätze stellen die Umgebung als statisch dar [LN03]. Dieser Ansatz kann für Anwendungsfälle wie einen Rasenmäher-Roboter, welcher wiederholt ein statisches Gebiet abfahren muss, genügen. Eine wesentliche Aufgabe mobiler Serviceroboter ist hingegen die Interaktion mit Personen innerhalb der Umgebung. Die Positionen dieser Personen sind dabei im Allgemeinen nicht statisch, sondern variieren mit der Zeit. Um seinen Aufgaben effektiv nachkommen zu können, benötigt der mobile Serviceroboter ein Modell der zeitlich und örtlich variablen Auftrittswahrscheinlichkeiten von Personen innerhalb seiner Arbeitsumgebung. Mithilfe eines solchen Modells ist der Roboter in der Lage, zu bestimmten Zeitpunkten gezielt Orte mit einem hohen Personenaufkommen anzufahren. Strebt der Roboter eine Kontaktaufnahme an, soll so die Zeit bis zum Erreichen dieser, gegenüber dem Abfahren einer zufälligen Route oder einem Verbleib und dem Warten an der aktuellen Position, reduziert werden.

In dieser Arbeit wird die Möglichkeit einer frequenzbasierten Modellierung zur Prädiktion von Personen-Auftrittswahrscheinlichkeiten untersucht. Neben einem binären Modell, welches die Auftrittswahrscheinlichkeiten von Personen prognostiziert, wird ein quantitatives Modell untersucht, welches die Anzahl von Personen innerhalb eines Zeitintervalls vorhersagen soll.

In Kapitel 2 (Grundlagen und Stand der Technik) wird auf die benötigten mathematischen Grundlagen eingegangen. Es werden Wahrscheinlichkeitsverteilungen und Funktionen vorgestellt, mittels derer binäre und quantitative Zustände modelliert werden können. Darauf aufbauend wird der aktuelle Stand der Technik im Bereich der binären und quantitativen Zustandsmodellierung präsentiert. Ein Hauptbestandteil des Kapitels ist die FreMEn (Frequency Map Enhancement) Methode. Die Methode modelliert Umweltzustände, wie das Personenaufkommen in einer Umgebung, durch zeitlich veränderliche Funktionen. Es erfolgt eine Untersuchung des Frequenzspektrums dieser zeitlich veränderlichen Funktionen und eine Approximation durch periodische, harmonische Funktionen [KFC⁺14].

In Kapitel 3 (Methodik) wird auf den Modellierungsprozess eingegangen. Es erfolgt eine Beschreibung der Messdatenermittlung und Vorverarbeitung durch ein Belegtheitsgitter, jeweils für binäre Zustandsmodelle sowie quantitative Zustandsmodelle. Im weiteren Verlauf des Kapitels wird die Server-Client-Struktur des Modells beschrieben. Der Client speichert die vorverarbeiteten Daten und schickt sie an den Server, welcher eine Frequenzanalyse der Daten durchführt und die zeitlich veränderlichen Funktionen durch eine Superposition periodischer, harmonischer Funktionen approximiert. Die ermittelten Parameter werden an den Client zurückgesendet, welcher diese speichert.

Kapitel 4 (Evaluation) evaluiert das binäre und quantitative Modell mittels zweier Datensätze. Es werden einheitliche Fehlermaße zur Bewertung der Modellgüten definiert. Darauf aufbauend erfolgt ein Vergleich der Modellgüten binärer und quantitativer Modelle mit statischen Modellen, welche Umweltzustände durch zeitlich invariable, konstante Werte approximieren. Neben Möglichkeiten der Modelle wird auch auf limitierende Faktoren eingegangen.

In Kapitel 5 (Zusammenfassung und Ausblick) werden die gesammelten Ergebnisse zusammengefasst. Es erfolgt außerdem ein Ausblick auf weiterführende Fragestellungen im Rahmen der frequenzbasierten Modellierung von Personen-Auftrittswahrscheinlichkeiten.

2 Grundlagen und Stand der Technik

In diesem Kapitel wird der aktuelle Stand der Technik zu Methoden der binären sowie quantitativen Darstellung von Umweltzuständen präsentiert. Es werden die mathematischen Grundlagen der in dieser Arbeit verwendeten Methoden behandelt. Neben Fourierreihen (Abschnitt 2.1) und der diskreten Fouriertransformation (Abschnitt 2.2) wird hier außerdem auf die Thematik der Wahrscheinlichkeitsverteilungen eingegangen. Aufgeführt wird neben der Binomialverteilung auch die Poissonverteilung (Abschnitt 2.3.2).

Darauf folgend werden Ergebnisse der Wissenschaft zur Beschreibung von Zustandsmodellen vorgestellt. Während Abschnitt 2.4 sich mit der Beschreibung binärer Zustandsmodelle beschäftigt, legt Abschnitt 2.5 den Fokus auf die Beschreibung quantitativer Zustandsmodelle.

2.1 Fourierreihen und Fouriertransformation

Periodische Signale tauchen in vielen Bereichen der Physik und Technik auf. Ein Signal bezeichnet hierbei eine Funktion, welche eine physikalische Größe in Abhängigkeit von der Zeit, dem Ort, oder einer anderen Variablen darstellt [EKS06]. Betrachtet man periodische Funktionen, so zeichnen sich diese durch ihre Periodendauer T aus. Eine Periode enthält dabei die gesamte Information des Signals, sodass gilt: $f(t) = f(t + T)$. Jede periodische Funktion kann durch eine Überlagerung von Sinus- und Kosinusfunktionen unterschiedlicher Periodendauern $2\pi n$ approximiert werden [EKS06]. Dargestellt werden kann dies durch eine Fourierreihe

$$f(t) = \frac{a_0}{2} + \sum_{n=0}^N [a_n \cos(n\omega t) + b_n \sin(n\omega t)]. \quad (2.1)$$

Hierbei bezeichnet $\omega = 2\pi/T$ die Kreisfrequenz der Grundschwingung. Die Konstanten $a_0, a_1 \dots a_n$ werden als gerade Fourierkoeffizienten bezeichnet, $b_1, b_2 \dots b_n$ hingegen als ungerade Fourierkoeffizienten. Dies leitet sich daraus ab, dass der Cosinus eine gerade und der Sinus eine ungerade Funktion ist.

Alternativ lässt sich eine Fourierreihe durch Sinusfunktionen mit unterschiedlichen Amplitu-

den und Phasen beschreiben. Die Fourierreihe lautet dann

$$f(t) = \rho_0 + \sum_{n=1}^N \rho_n \sin(n\omega t + \varphi_n). \quad (2.2)$$

Die Grundfrequenz des Signals lautet $f_1 = 1/T = \omega/2\pi$. Die weiteren Sinus- und Kosinusfunktionen der Fourierreihe besitzen Frequenzen $f_n = n f_1$, also ganzzahlige Vielfache der Grundfrequenz. Die Umrechnung von Gleichung 2.1 nach Gleichung 2.2 erfolgt mithilfe der Definitionen

$$\rho_0 = \frac{a_0}{2}, \quad (2.3)$$

$$\rho_n = \sqrt{a_n^2 + b_n^2}, \quad (2.4)$$

$$\varphi_n = \arctan\left(\frac{a_n}{b_n}\right). \quad (2.5)$$

Mit ρ_0 wird hierbei der Gleichanteil des Signals bezeichnet, ρ_n steht für die Amplitude der n -ten Frequenz und φ_n für die Phasenverschiebung der n -ten Frequenz [EKS06]. Ein Signal kann also durch sein Kosinus- und Sinusspektrum sowie durch sein Amplituden- und Phasenspektrum charakterisiert werden. Grafisch veranschaulicht wird die Fourierreihe durch Bild 2.1. In Bild 2.1a eingezeichnet ist ein periodisches Signal mit der Periodendauer T , für welches $f(t) = f(t + T)$ gilt. In Bild 2.1b finden sich die das Gesamt signal definierenden Frequenzen, mit ihren zugehörigen Amplituden ρ und Phasenversätzen φ [EKS06].

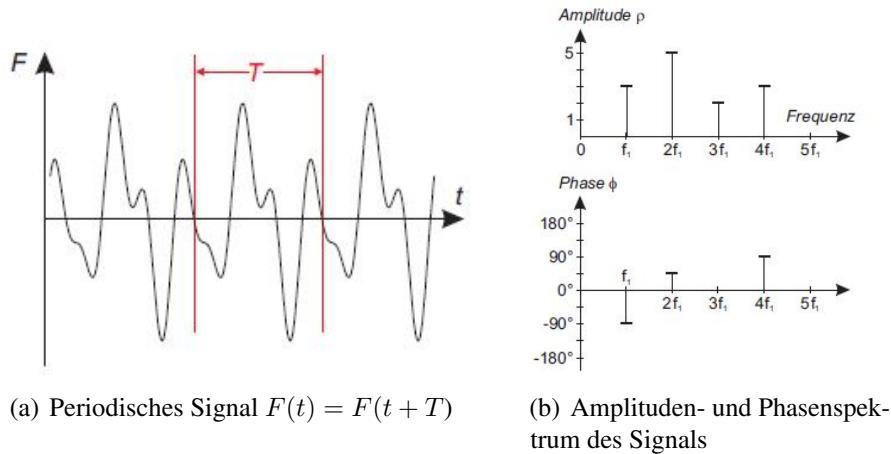


Bild 2.1: Periodisches Signal mit zugehörigem Amplituden- und Phasenspektrum [EKS06]

Die Fouriertransformation überführt die Funktion $f(t)$ aus dem Zeitbereich in den Frequenz-

bereich. Für analoge Signale ist die Fouriertransformation definiert als

$$F(\omega) = \int_{-\infty}^{\infty} f(t)e^{-j\omega} dt, \quad (2.6)$$

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega)e^{j\omega} d\omega. \quad (2.7)$$

Dieser Zusammenhang überführt eine, von der Zeit abhängige, Funktion aus dem Zeitbereich über Integration von $-\infty$ bis ∞ über alle Zeitpunkte t in den Frequenzbereich. Die inverse Fouriertransformation erfolgt durch Integration von $-\infty$ bis ∞ des von der Frequenz ω abhängigen Signals über alle Frequenzen ω [EKS06].

2.2 Diskrete Fouriertransformation

Die in Abschnitt 2.1 dargestellten Gleichungen gelten für zeitkontinuierliche Funktionen. In der Praxis ist es jedoch häufig so, dass keine vollständige Kenntnis über ein Signal vorliegt, sondern dieses nur durch Messungen zu diskreten Zeitpunkten abgetastet werden kann [EKS06]. Hieraus resultiert die Diskrete Fourier-Transformation (DFT). Die resultierenden Werte $F(n)$ der diskreten Fouriertransformation eines zu den Zeitpunkten k abgetasteten Signals $f(t)$ berechnen sich durch

$$F(n) = \sum_{k=0}^{N-1} f[k] e^{j \frac{2\pi}{N} kn}. \quad (2.8)$$

Die inverse diskrete Fouriertransformation (IDFT) erfolgt durch

$$f[k] = \frac{1}{N} \sum_{n=0}^{N-1} F(n) e^{j \frac{2\pi}{N} kn}. \quad (2.9)$$

Im Zusammenhang mit der Diskreten Fouriertransformation ist abschließend das Abtasttheorem von Nyquist und Shannon zu nennen [EKS06]. Das Theorem besagt, dass ein beliebig geformtes, kontinuierliches Signal immer dann durch eine zu diskreten Zeitpunkten durchgeführte Abtastung darstellbar und auch exakt wiederherstellbar ist, wenn die zum Abtasten des Signals benutzte Frequenz mindestens doppelt so hoch ist, wie die höchste im kontinuierlichen Signal enthaltene Frequenz [WA05]. Beträgt die höchste Frequenz in einem

Signal also beispielsweise 10 Hz, so muss es mit mindestens 20 Hz abgetastet werden, damit das Signal vollständig rekonstruierbar ist [WA05].

Die Folgen einer zu geringen Abtastfrequenz werden in Bild 2.2 ersichtlich. Die Abtastung des Signals zu den mit schwarz markierten Zeitpunkten reicht nicht aus, um das in grau dargestellte Originalsignal zu rekonstruieren. Stattdessen ergibt sich das in rot dargestellte Signal.

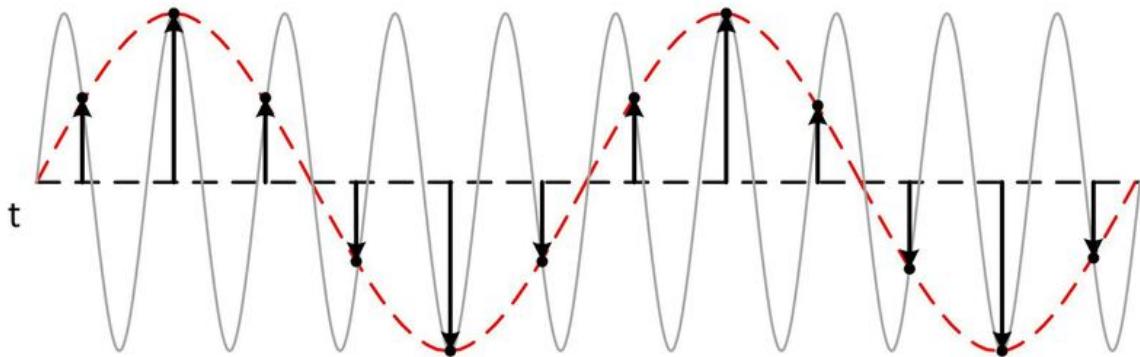


Bild 2.2: Originalsignal (grau) und durch Abtastung rekonstruiertes Signal (rot) [Bun20]

2.3 Wahrscheinlichkeitsverteilungen

Dieser Abschnitt behandelt Wahrscheinlichkeitsverteilungen. Wahrscheinlichkeitsverteilungen werden benötigt, um Aussagen über das Ergebnis einer Aktion, wie beispielsweise den Ausgang eines Münzwurfs, zu treffen [TT14]. Außerdem können mit ihrer Hilfe Aussagen über den Wert von Umweltzuständen für Zeitpunkte getroffen werden, zu denen dieser nicht direkt beobachtbar ist. Diese Aussagen werden dabei mit Hilfe gesammelter Informationen über vergangene Werte des Umweltzustandes getroffen [KSD15]. Neben der Binomialverteilung wird im Folgenden auch auf die Poissonverteilung eingegangen.

2.3.1 Binomialverteilung

Ein Münzwurf mit seinen zwei möglichen Ausgängen „Kopf“ beziehungsweise „Zahl“ stellt ein Bernoulli-Experiment dar. Als Bernoulli-Experiment wird ein Zufallsexperiment bezeichnet, bei dem es lediglich zwei Ausgänge geben kann, ein Ereignis A also entweder Eintritt oder nicht [TT14]. Führt man ein Bernoulli-Experiment n -mal hintereinander unter den gleichen Bedingungen durch, so erhält man eine Bernoulli-Kette der Länge $n \in \mathbb{N}$. Das

Eintreten des Ereignisses A wird gemeinhin als Erfolg, die Wahrscheinlichkeit $P(A) = p$ als Erfolgswahrscheinlichkeit bezeichnet [TT14]. Als Ereignis A kann hier beispielhaft das Werfen einer Münze mit dem Ausgang „Zahl“ genannt werden. Eine Binomialverteilung entsteht nun, wenn wir die Anzahl der Erfolge bei einer Bernoulli-Kette ermitteln wollen [TT14]. Mathematisch formuliert lässt sich die Binomialverteilung ausdrücken als

$$P(X = x) = \binom{n}{x} p^x q^{n-x}. \quad (2.10)$$

X bezeichnet hierbei die Anzahl der Versuchsdurchführungen, bei denen ein Erfolg eintritt. X kann die Werte $x = 0, 1, 2, \dots, n$ annehmen, p steht für die Eintrittswahrscheinlichkeit eines Erfolges, q für die Wahrscheinlichkeit eines Misserfolges. Die Zufallsvariable X ist binomialverteilt und ihre Wahrscheinlichkeitsverteilung eine Binomialverteilung mit den Parametern n, p [TT14]. Die grafische Darstellung einer Binomialverteilung für die Wahrscheinlichkeit der Anzahl an Würfen eines Würfels mit dem Ereignis „1“ bei sieben Würfen ist beispielhaft in Bild 2.3 dargestellt.

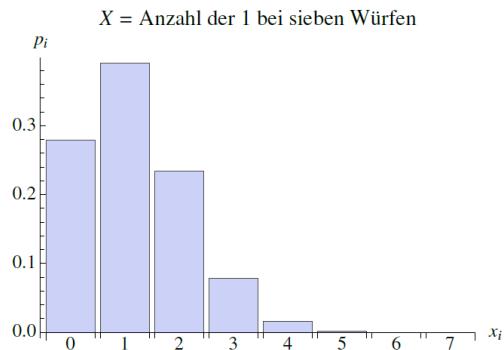


Bild 2.3: Binomialverteilung mit $n = 7, p = \frac{1}{6}$ [TT14]

2.3.2 Poissonverteilung

Es gibt viele Szenarien, in denen man sich für die Anzahl X_t bestimmter Ereignisse innerhalb eines Zeitraumes interessiert. Beispielsweise können hier die Anzahl der Verkehrsunfälle pro Tag oder die Anzahl der Fertigungsfehler innerhalb einer Produktionstranche genannt werden [TT14]. Zur stochastischen Beschreibung dieser Aufgabenstellungen eignet sich die Poissonverteilung [TT14]. Eine Zufallsvariable X , welche unendlich viele Werte $x = 0, 1, 2, \dots$ mit

den Wahrscheinlichkeiten

$$P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda} \quad \lambda > 0 \quad (2.11)$$

annehmen kann, wird als poissonverteilt mit dem Parameter λ bezeichnet. Die zugehörige Verteilung heißt Poisson-Verteilung. Der Erwartungswert μ wird beschrieben durch

$$\mu = E(X) = \lambda, \quad (2.12)$$

die Varianz σ^2 der Poisson-Verteilung berechnet sich zu

$$\sigma^2 = Var(X) = \lambda. \quad (2.13)$$

Anhand der obigen Formeln erkennt man, dass der Parameter der Poisson-Verteilung gleich ihres Erwartungswertes ist, selbiges gilt für die Varianz. Häufig ist es von Interesse, die Wahrscheinlichkeit für eine Anzahl X_t an Ereignissen innerhalb eines Zeitraumes $[0, t]$ zu bestimmen. Die Menge von Zufallsvariablen X_t mit $t \geq 0$ wird als Poisson-Prozess mit der Rate λ bezeichnet, falls gilt

$$P(X_t = x) = \frac{(\lambda t)^x}{x!} e^{-\lambda t}. \quad (2.14)$$

Ein Poisson-Prozess muss dabei nach [TT14] drei Voraussetzungen erfüllen:

- Die Wahrscheinlichkeit für ein Ereignis ist proportional zur Beobachtungsdauer Δt , aber unabhängig von den Startzeitpunkten, also der zeitlichen Lage des Beobachtungsintervalls.
- Die Wahrscheinlichkeiten für ein Ereignis an unterschiedlichen Orten sind voneinander unabhängig.
- Für infinitesimal kleine Δt ist die Wahrscheinlichkeit, dass das Ereignis mehr als einmal auftritt, im Vergleich zur Wahrscheinlichkeit, dass es genau einmal vorkommt, vernachlässigbar klein [TT14].

2.4 Beschreibung binärer Zustandsmodelle

Mobile Roboter finden immer mehr Einzug in Umgebungen, welche von Menschen bewohnt sind [KFSD]. Diese Menschen üben Aktivitäten aus, welche in der Folge zu Veränderungen dieser Umgebung führen. Man kann davon ausgehen, dass viele dieser Aktivitäten täglichen Routinen mit typischen Mustern folgen, welche von mobilen Robotern erkannt werden

und zur robusteren Darstellung ihrer Umgebung genutzt werden können. Das Mapping in statischen Umgebungen, also die Kartierung, stellt ein weit erforschtes Gebiet dar [LN03]. Für das Mapping dynamischer Umgebungen gibt es verschiedene Ansätze. Während ein Ansatz darauf abzielt, sich bewegende Objekte aus der Umgebungsdarstellung herauszufiltern [HSB02], werden in anderen diese Objekte getrackt und als bewegte Landmarken klassifiziert [MMM08]. Diese separationsbasierten Ansätze können jedoch nicht auf Langzeitveränderungen der Umgebungsstruktur reagieren.

Im Gegensatz hierzu stehen adaptive Ansätze, welche davon ausgehen, dass der Prozess des Mappings niemals komplett abgeschlossen ist und dieser kontinuierlich aktualisiert werden muss. So können der Karte durch neue Observierungen des mobilen Roboters neue Features hinzugefügt werden [MW10]. In [KFC⁺14] wird versucht, die räumlich-zeitliche Dynamik einer Umgebung durch ihr Frequenzspektrum darzustellen. Die Werte von lokalen Umweltzuständen, wie zum Beispiel einer Tür, welche entweder offen oder geschlossen sein kann, sollen anhand von Wahrscheinlichkeitsfunktionen repräsentiert werden, welche aus der Superposition periodischer Funktionen resultieren. In [KFC⁺14] wird als Motivation dazu angeführt, dass bei den meisten Mapping-Ansätzen wichtige Umweltzustände lediglich statisch durch zwei eindeutige Zustände dargestellt werden. Eine Tür ist also entweder dauerhaft geöffnet oder geschlossen. Diese Zustände können jedoch auch durch ihre Wahrscheinlichkeit ausgedrückt werden. Hierbei beschreibt p_j die Wahrscheinlichkeit des j -ten Umweltzustandes einer Umgebung. Bayes-Filter gehen hierzu von einer statischen Welt aus, d.h. die Wahrscheinlichkeit des Zustandes p_j wird als konstant angesehen. Durch neue Beobachtungen können diese konstanten Annahmen verändert werden, alte Beobachtungen werden so jedoch über die Zeit *vergessen* [KFC⁺14]. Nimmt man jedoch an, dass diese Zustandswahrscheinlichkeiten $p_j(t)$ Funktionen der Zeit sind und diesen zeitlichen Veränderungen der Wahrscheinlichkeiten eine finite Anzahl periodischer Prozesse zu Grunde liegt, so könnte man den Einfluss und die Periodizität eben dieser Prozesse identifizieren und die Zustandswahrscheinlichkeit $p_j(t)$ aus dieser Beschreibung ermitteln. In [KFC⁺14] wird die in Abschnitt 2.1 erläuterte Fouriertransformation benutzt, um diese periodischen Prozesse zu identifizieren. Als Beispiel wird ein Belegungsgitter herangeführt. Jede der Zellen des Belegungsgitters kann zwei Zustände $s_j = \{frei, belegt\}$ annehmen. Diese Zellzustände sind jedoch nicht konstant, sondern eine Funktion $s_j(t)$ der Zeit. Die Unsicherheit des Zustandes wird durch seine Wahrscheinlichkeit $p_j(t)$ ausgedrückt. Da die Zellen als unabhängig voneinander betrachtet werden, kann die Fouriertransformation separat auf jede Zelle des Belegungsnetzes angewendet werden.

Die über die Zeit aufgetragenen Zustände einer Zelle $s(t)$ werden mittels der Fouriertransformation $P = FT(s(t))$ transformiert. Es werden l Koeffizienten P_i des Spektrums P

ausgewählt und zusammen mit ihren Frequenzen ω_i benutzt, um mittels der inversen Fouriertransformation $p(t) = IFT(P'(t))$ die Wahrscheinlichkeitsfunktion $p(t)$ des Zellzustandes zu bestimmen. Die Menge P besteht hierbei aus einer Anzahl von l Tripeln mit den Einträgen $(abs(P_i), arg(P_i), \omega_i)$, wobei $abs(P_i)$ für die Amplitude, $arg(P_i)$ für den Phasenversatz und ω_i für die Frequenz des jeweiligen periodischen Prozesses steht, welcher den Zustand $s(t)$ beeinflusst. Anschließend wird ein Schwellwert benutzt, um aus $p(t)$ eine Schätzung $s'(t)$ der tatsächlichen Zustandsfunktion $s(t)$ zu bestimmen.

Der Zustand einer Zelle kann somit durch

$$s(t) = (IFT(P) > 0.5) \quad (2.15)$$

approximiert werden.

Ist die Wahrscheinlichkeit $p(t)$ einer Zellbelegung größer als 0.5, so wird die Zelle als belegt geschätzt.

Der in Gleichung 2.15 benutzte Schwellwert von 0.5 kann willkürlich gesetzt werden. So können Vorhersagen über zukünftige Zustände der Zelle mit einem gewissen Konfidenzniveau von c durch die Gleichung

$$s'(t, c) = IFT(P) > c \quad (2.16)$$

getroffen werden. Diese Methode wird im Folgenden als Frequency Map Enhancement (FreMEn) bezeichnet. Grafisch verdeutlicht wird die Methode durch Bild 2.4.

In der linken Grafik rot dargestellt sind die, über einen zeitlichen Verlauf aufgenommenen, binären Zustände $s(t)$ einer Beispielzelle. Der grüne Graph beschreibt das zugehörige FreMEn-Modell $p(t)$ der Ordnung $l = 3$. Zur Konstruktion von $p(t)$ wurden somit drei periodische Prozesse verwendet. In blau aufgetragen sind die Vorhersagen $s'(t)$ des Modells, ermittelt anhand eines Schwellwertes von $c = 0.5$. Der lila Graph stellt die Zeitpunkte dar, zu denen die Modellvorhersage von den tatsächlichen Zellzuständen abweicht [KFC⁺14]. Die rechte obere Grafik repräsentiert das Frequenzspektrum der Zelle, die für das Modell ausgewählten Frequenzen sind durch blaue Kreise markiert. Das zuvor erwähnte Tripel bestehend aus Amplitude, Phasenversatz und Frequenz der jeweiligen periodischen Prozesse ist in der rechten unteren Grafik dargestellt. Daneben findet sich hier auch die Menge der Ausreißer / mit den Zeitpunkten, zu denen die Modellvorhersage $s'(t)$ von den tatsächlichen Zellzuständen $s(t)$ abweicht. Um die Auswirkungen des Modellgrades, also der Anzahl der in das Modell einfließenden periodischen Prozesse, zu erforschen, wurde die Methode auf einen Datensatz angewendet, bei welchem ein mobiler SCITOS-G5 Roboter, ausgestattet mit RGB-D und Lasersensoren, Personen in einem Bürogebäude über eine Dauer von einer

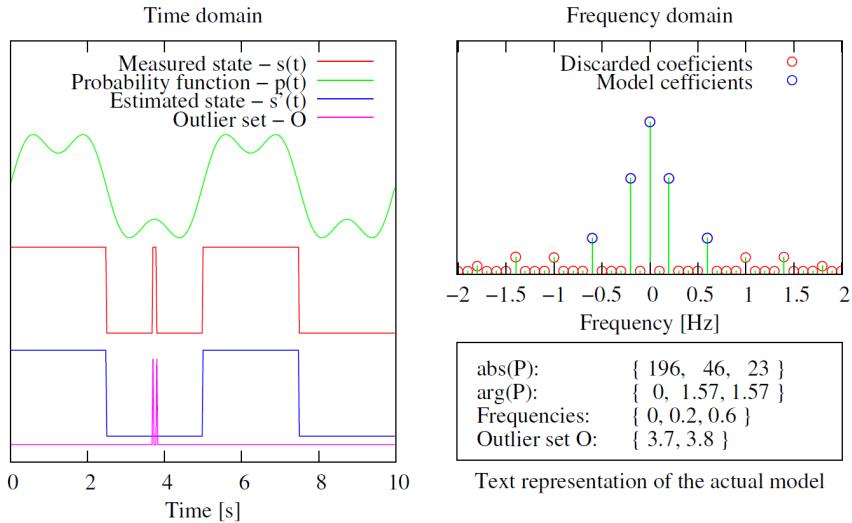


Bild 2.4: Beispiel eines über die Zeit gemessenen Zellzustandes sowie seines Spektralmodells und seiner Wahrscheinlichkeitsprädiktion [KFC⁺14]

Woche mit einer Rate von 30 Hz detektiert hat.

Die Genauigkeit des Modells $q(t_a, t_b)$ wird berechnet als

$$q(t_a, t_b) = \frac{1}{t_b - t_a} \int_{t_a}^{t_b} |s'(t) - s(t)| dt \quad (2.17)$$

und beschreibt das Verhältnis von korrekt geschätzten Zellzuständen zu der Gesamtdauer des betrachteten Intervalls.

Unterschieden wurde nun in [KFC⁺14] zwischen der Rekonstruktionsgenauigkeit q_r sowie der Prädiktionsgenauigkeit q_p . Die Rekonstruktionsgenauigkeit beschreibt, wie genau das Modell Zeitintervalle beschreibt, welche zur Ermittlung der Modellparameter verwendet wurden. Die Prädiktionsgenauigkeit hingegen beschreibt die Genauigkeit des Modells in Bezug auf Zeiträume, welche nicht zur Modellermittlung verwendet wurden. Die ermittelte Abhängigkeit der Rekonstruktions- sowie Prädiktionsgenauigkeit von der Modellordnung l ist in Bild 2.5 aufgezeigt. Hierbei erfolgte die Berechnung des Modells und der Rekonstruktionsgenauigkeit q_r anhand eines einwöchigen Datensatzes, die Evaluierung des Modells und die Ermittlung der Prädiktionsgenauigkeit q_p wurde mittels zwei externer Tage mit den zugehörigen Prädiktionsgenauigkeiten q_{p1} und q_{p2} durchgeführt.

Die Rekonstruktionsgenauigkeit liegt bei einer Modellordnung von $l = 15$, d.h. es wurden

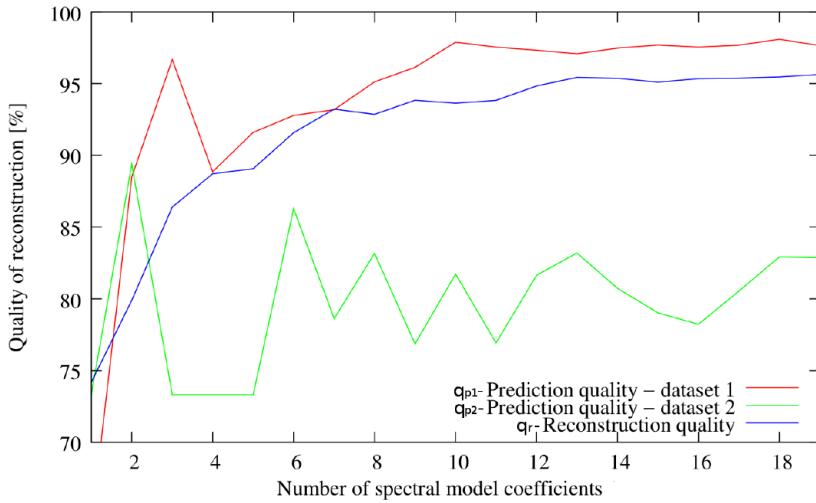


Bild 2.5: Modellgenauigkeit vs. Modellordnung [KFC⁺14]

15 periodische Prozesse zum Approximieren des Zustandssignales verwendet, bei 95 %. Die Rekonstruktionsgenauigkeit q_r steigt dabei monoton mit der Modellordnung. Für die Prädiktionsgenauigkeit q_p lässt sich nach [KFC⁺14] kein allgemeingültiger Zusammenhang finden. Während die Prädiktionsgenauigkeit des ersten Testtages bei $l = 3$ ein lokales Maximum, bei $l = 17$ jedoch ein globales Maximum besitzt, liegt das globale Maximum für den zweiten Testtag bei $l = 2$.

Die lokalen Maxima von q_{p1} und q_{p2} lassen laut [KFC⁺14] den Schluss zu, dass für die Vorhersage eine Modellordnung von zwei oder drei optimal ist (siehe Bild 2.5).

Einen Vergleich zwischen der in [KFC⁺14] beschriebenen FreMEn- Methode und der Anwendung von periodischen Gauß-Mischmodellen zur Darstellung der Dynamik von binären Umweltzuständen zieht [KKM⁺15]. FreMEn basiert hier, wie auch schon in [KFC⁺14] auf der Idee, die zeitliche Funktion $s(t)$ eines Umweltzustandes durch seine Wahrscheinlichkeitsfunktion $p(t)$ zu schätzen. Auch hier wird wieder mittels einer Fouriertransformation das Frequenzspektrum $S(\omega)$ der zeitlichen Funktion $s(t)$ bestimmt, und die l prominentesten Frequenzen mit ihren Amplituden a_j , ihrem Phasenversatz φ_j sowie ihrer Frequenz ω_j abgespeichert. Die Ermittlung der Wahrscheinlichkeit $p(t)$ eines Umweltzustandes zum Zeitpunkt t ergibt sich nun durch die Superposition der l Frequenzen zu

$$p(t) = a_0 + \sum_{j=1}^n a_j \cos(\omega_j t + \varphi_j). \quad (2.18)$$

Die erste spektrale Komponente a_0 stellt hierbei den Durchschnitt aller binären Werte von $s(t)$, also dessen Gleichanteil (siehe Abschnitt 2.1) dar. FreMEn besitzt aber laut [KKM⁺15] zwei wesentliche Nachteile. So erlaubt es zum einen, lediglich einen periodischen Prozess pro Frequenz zu modellieren. Des Weiteren bilde es wiederkehrende, aber kurze, Prozesse schlecht ab. Als Beispiel wird hier die morgendliche Dusche angeführt, welche eine tägliche, aber kurze Routine sei. Da in [KFC⁺14] herausgearbeitet wurde, dass die optimale Modellordnung l_{opt} für eine möglichst hohe Prognostizierfähigkeit bei einer Größe von lediglich zwei bis drei liegt, könnten solche kurzen Routinen nicht abgebildet werden.

Als zweiter Ansatz werden Gaussian Mixture Models (GMM) genannt. Diese können multi-dimensionale Funktionen als gewichtete Summe aus mehreren Gauß-Funktionen durch

$$f(t) = \frac{1}{\sqrt{2\pi}} \sum_{j=1}^m \frac{\omega_j}{\sigma_j} e^{-\frac{(t-\mu_j)^2}{2\sigma_j^2}} \quad (2.19)$$

approximieren. Die Parameter der individuellen Komponenten eines GMM, namentlich das Gewicht ω_j , der Durchschnitt μ_j sowie die Standardabweichung σ_j werden typischerweise mittels Trainingsdaten anhand des Iterative Expectation Maximization (EM) oder des Maximum A-Posteriori (MAP) Algorithmus ermittelt. Während GMM in der Lage sind, Funktionen jeglichen Aussehens zu modellieren, liegt ihre Limitation darin, dass sie definitivonsgemäß keine periodischen Funktionen repräsentieren können [KKM⁺15]. Um diesem Problem entgegenzuwirken, wird vorab eine Periodendauer von einem Tag vorgegeben. Diese Vorgabe erlaubt es, die gemessene Sequenz der Umweltzustände $s(t)$ in eine Sequenz $p'(t)$ umzuwandeln mit

$$p'(t) = \frac{k}{\tau} \sum_{i=1}^{\frac{k}{\tau}} s(t + i\tau). \quad (2.20)$$

In Gleichung (2.20) bezeichnet τ die vorab definierte Periodendauer, k beschreibt die Länge der Sequenz $s(t)$. Nach Anwendung des Expectation Maximization Algorithmus kann die Wahrscheinlichkeit für einen Umweltzustand berechnet werden zu

$$p(t) = \frac{1}{\sqrt{2\pi}} \sum_{j=1}^m \frac{w_j}{\tau_j} e^{-\frac{(mod(t,\tau)-\mu_j)^2}{2\sigma_j^2}}. \quad (2.21)$$

Hierbei beschreibt τ die vorgegebene Periodendauer der Funktion $p(t)$ und mod ist der Modulo-Operator. Dass die Stärken und Schwächen dieser periodischen GMM-basierten (PerGaM) Modelle komplementär zu jenen der FreMEn-Methodik sind, wir anhand von Bild 2.6 deutlich. Das PerGaM-Modell kann selbst kurze, mehrfach auftretende Routinen

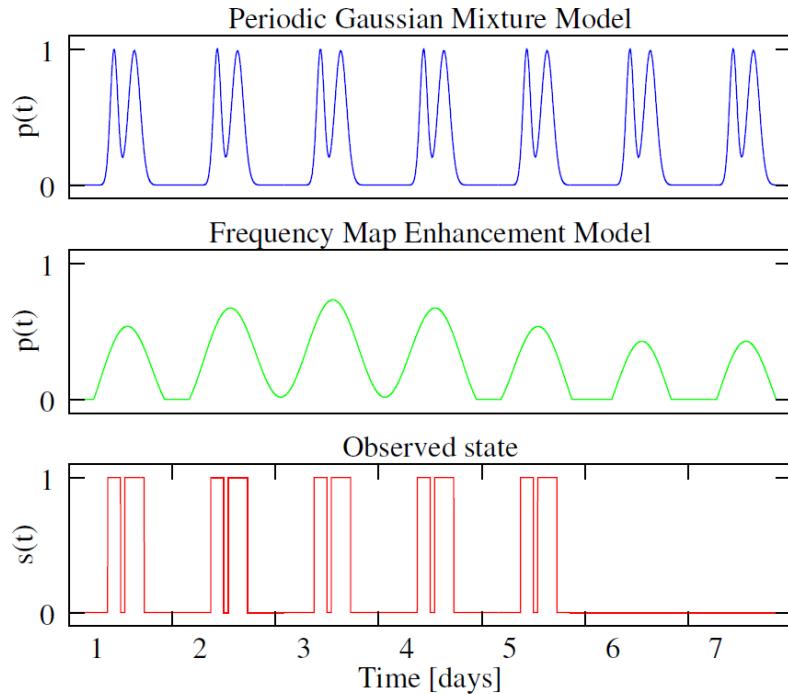


Bild 2.6: PerGaM und FreMEn Modellvergleich [KKM⁺15]

approximieren, jedoch kann es lediglich eine Periodendauer repräsentieren, welche a priori bekannt bzw. festgelegt werden muss. Als Resultat werden kurzzeitige Routinen, wie z.B. Mittagspausen, gut approximiert, die wöchentliche Dynamik mit dem Fehlen von Personen am Wochenende kann hingegen jedoch nicht modelliert werden. Im Vergleich dazu sieht man das FreMEn-Modell, welches diese Wochendynamik durch ein Abflachen der Signalamplitude an den beiden Wochenendtagen abbildet (siehe Bild 2.6).

In Bezug auf das zeitlich-räumliche Mapping durch mobile Roboter führt [KSD15] an, dass dies auch eine räumlich-zeitliche Explorationsstrategie benötigt. Im Vergleich zu klassischen Explorationsstrategien, bei denen, bedingt durch die endliche Größe der zu erforschenden Karte, die Exploration ebenfalls finit ist, sei die Exploration dynamischer Umgebungen niemals abgeschlossen. Vielmehr würde die räumlich-zeitliche Exploration Teil der täglichen Routine des Roboters. Es stellt sich ein wesentlicher Nachteil der in [KFC⁺14] vorgestellten Methode zur Darstellung von binären Umweltzuständen in Bezug auf die kontinuierliche Exploration einer Karte durch einen mobilen Roboter heraus. Diese beruht auf der traditionellen Fast Fourier Transformation (FFT). Die Fast Fourier Transformation kann jedoch lediglich die komplette Sequenz eines Umweltzustandes $s(t)$ in sein Frequenzspektrum $S(\omega)$

transformieren. Außerdem erfordert der Algorithmus, dass die Zustandsobservierungen mit der immer gleichen Frequenz aufgenommen werden. Orte mit der immer selben Frequenz zu erkunden, sei jedoch nicht effizient, sodass in [KSD15] eine neue Methode zur Darstellung von binären Umweltzuständen durch zeitlich variable Wahrscheinlichkeitsfunktionen vorgestellt wird. Die Methode erlaubt ein inkrementelles und kontinuierliches Aktualisieren des räumlich-zeitlichen Umgebungsmodells durch wenige Observierungen, welche zu unterschiedlichen, nicht gleichmäßig verteilten Zeitpunkten, und an unterschiedlichen Orten aufgenommen werden können.

Jeder Umweltzustand $s(t)$ wird durch die Anzahl getätigter Observierungen n , seines Durchschnittes μ sowie zwei Sets A, B komplexer Zahlen α_k und β_k , welche zu dem Set Ω periodischer Prozesse ω_k gehören, die den Umweltzustand beeinflussen, beschrieben. Anfangs wird der Wert μ jedes Umweltzustandes zu $\mu = 0.5$ und alle α_k sowie β_k zu 0 gesetzt, was einem vollkommen unbekannten Zustand entspricht. Die inkrementelle Aktualisierung des Modells erfolgt durch

$$\mu \leftarrow \frac{1}{n+1}(n\mu + s(t)), \quad (2.22)$$

$$\alpha_k \leftarrow \frac{1}{n+1}(n\alpha_k + s(t)e^{-jt\omega_k}), \quad \forall \omega_k \in \Omega, \quad (2.23)$$

$$\beta_k \leftarrow \frac{1}{n+1}(n\beta_k + \mu e^{-jt\omega_k}), \quad \forall \omega_k \in \Omega, \quad (2.24)$$

$$n \leftarrow n + 1. \quad (2.25)$$

Die schrittweise Aktualisierung entspricht dabei einer inkrementellen Mittelwertbildung. Der Betrag $\gamma_k = |\alpha_k - \beta_k|$ stellt den durchschnittlichen Einfluss des periodischen Prozesses k auf den Umweltzustand $s(t)$ dar. Wären die Zeitpunkte t der Observationen und die Frequenzen ω_k gleichmäßig verteilt, so entsprächen die obigen Formeln der diskreten Fouriertransformation. Um den zukünftigen Wert eines Umweltzustandes prognostizieren zu können, werden wie auch in [KFC⁺14] die m periodischen Prozesse mit den höchsten absoluten Werten $|\gamma_k|$ ausgewählt. Die Wahrscheinlichkeit eines Umweltzustandes wird mittels

$$p(t) = \varsigma(\mu + \sum_{l=1}^m |\gamma_l| \cos(\omega_k t + \arg(\gamma_l))) \quad (2.26)$$

berechnet. Die Funktion $\varsigma(\cdot)$ sorgt dafür, dass $p(t) \in [0, 1]$ gilt. Der optimale Wert für m wird wie schon in [KFC⁺14] so gewählt, dass die Prädiktionsgenauigkeit q_p maximiert wird.

2.5 Beschreibung quantitativer Zustandsmodelle

Aus Abschnitt 2.4 wurde ersichtlich, dass binäre Zustandsmodelle Aussagen über die Wahrscheinlichkeit $p(t)$ eines Zellzustandes, wie z.B. die Belegtheit einer Zelle $s(t)$, erlauben. Möchte man jedoch Schätzungen für die Anzahl, wie oft eine Zelle innerhalb eines Zeitintervalls belegt bzw. besucht wird, treffen, so ist dies nur durch eine quantitative Zustandsbeschreibung möglich. Eine Methode zur Modellierung von quantitativen Umweltzuständen wird in [JWHK16] vorgestellt. Die hier genannte Methode beruht auf der Kombination von zeitveränderlichen Poisson-Prozessen und einer Frequenzanalyse. Dabei wird die Häufigkeit des Auftretens eines Ereignisses innerhalb eines Zeitintervalls gezählt. Anders ausgedrückt wird gezählt, wie häufig ein Umweltzustand, beispielsweise das Vorhandensein einer Person in einer Zelle, den Wert *wahr* pro Zeitintervall annimmt. Somit kann anstatt der Wahrscheinlichkeitsfunktion $p(t)$ eines Umwelt- bzw. Zellzustandes dessen Intensität bzw. Rate innerhalb des Zeitintervalls dargestellt werden. Diese Raten $\lambda(t)$ werden mit Hilfe von Poisson-Prozessen modelliert. Wie schon in Abschnitt 2.3.2 beschrieben, wird auch hier die Poisson-Verteilung mittels

$$P(N; \lambda) = \frac{e^{-\lambda} \lambda^N}{N!}, \quad N = 0, 1, 2, \dots \quad (2.27)$$

berechnet, wobei $P(N; \lambda)$ die Wahrscheinlichkeit P für den Fall beschreibt, dass innerhalb eines Zeitintervalls Δt mit einer durchschnittlichen Aktivitätenanzahl, also einer durchschnittlichen Personenanzahl von λ , exakt N Aktivitäten, also Personen, gezählt werden. Die Daten in [JWHK16] wurden von einem mobilen Metralabs Scitos A5-Roboter aufgenommen, welcher sich, ausgestattet mit einem robusten Personen-Tracking-Algorithmus, einen Monat lang in einem Bürogebäude bewegte. Die Abhängigkeit der durchschnittlichen Personenanzahl λ vom betrachteten Zeitintervall wird durch $\lambda(t_i, t_j)$ ausgedrückt, wobei t_i den Anfangszeitpunkt und t_j den Endzeitpunkt des Intervalls beschreibt. Da die von dem Roboter aufgenommenen Daten nur einen kleinen Teil der Gesamtheit des Personenaufkommens repräsentieren, wird λ mittels einer Konfidenz-basierten Schätzung bestimmt. Der Poisson-Parameter λ folgt hierbei einer Gammaverteilung

$$\lambda \sim \Gamma(\lambda; \alpha, \beta). \quad (2.28)$$

Die a-posteriori Wahrscheinlichkeit für $\lambda(t_i, t_j)$ berechnet sich unter Berücksichtigung der

aufgenommenen Daten nun zu

$$P(\lambda|x_1, \dots, x_n) = \Gamma(\lambda, \alpha + \sum_{i=1}^n x_i, \beta + n), \quad (2.29)$$

wobei x_1, \dots, x_n die im betreffenden Intervall aufgezeichneten Daten bezeichnen, der Parameter α steht für den Formfaktor, β für den inversen Skalenparameter der Gammaverteilung. Der Datensatz wird in Wochen eingeteilt, für ein Zeitintervall wird eine Dauer von zehn Minuten gewählt. Die Maximum a posteriori-Wahrscheinlichkeit (MAP) jedes Parameters $\lambda(t_i, t_j)$ wird als Punktschätzung für λ gewählt. Die Verknüpfung sämtlicher Punktschätzungen über den definierten Zeitraum einer Woche ergibt das Poisson-Prozess-Modell, welches in Bild 2.7 grafisch aufgezeichnet ist.

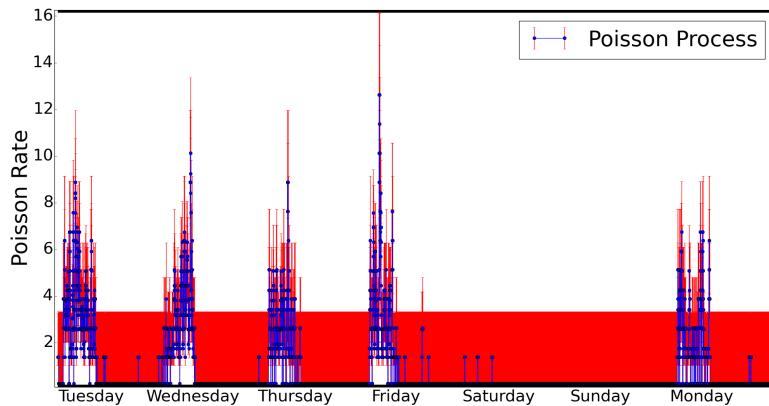


Bild 2.7: Aktivitätsraten λ des Poisson-Prozess-Modells ermittelt anhand eines 4 Wochen Zeitraumes [JWHK16]

Für jedes λ wurden die Daten von vier aufeinanderfolgenden Wochen verwendet, die roten Schranken zeigen die oberen und unteren Grenzen des Konfidenzintervalls für jedes λ . Nach der Berechnung des Poisson-Prozess-Modells wird nun die Fouriertransformation auf $\lambda(t)$ angewendet. Ebenso wie in [KFC⁺14] werden die l Frequenzen mit den höchsten Amplituden zur Konstruktion von $\lambda' = IFT(F'(\omega))$ verwendet. Im Gegensatz zu der in [KFC⁺14] durch Superposition der Parameter der l prominentesten Frequenzen verwendeten und hier als *l Best Amplitude Model* (BAM) bezeichneten Methode wird in [JWHK16] die *l Addition Amplitude Model* (AAM) Methode verwendet. Es wird angeführt, dass das BAM den Betrag des Original-Signals nicht komplett abbilden kann, sofern die Sampling-Rate der

Daten deutlich höher ist als die höchste beobachtete Frequenz.

AAM hingegen berechnet das Fourierspektrum des Poisson-Prozess-Modells, findet die Frequenz ω_k mit der höchsten Amplitude und zieht es von den Daten ab. Die modifizierten Daten werden wieder transformiert und das Frequenzspektrum erneut berechnet. Findet sich in diesem Frequenzspektrum eine bereits vorher identifizierte Frequenz, so wird dessen neuerliche Amplitude auf die bereits vorhandene addiert, und die Daten erneut modifiziert. Dieses Vorgehen wird bis zur Identifikation der l Frequenzen mit den höchsten Amplituden wiederholt. Bild 2.8 bietet einen Vergleich der beiden Methoden zur Abbildung des Poisson-Prozess-Modells. Aus der Grafik wird ersichtlich, dass das AAM die Beträge des Original-Modells deutlich besser abbilden kann als das BAM.

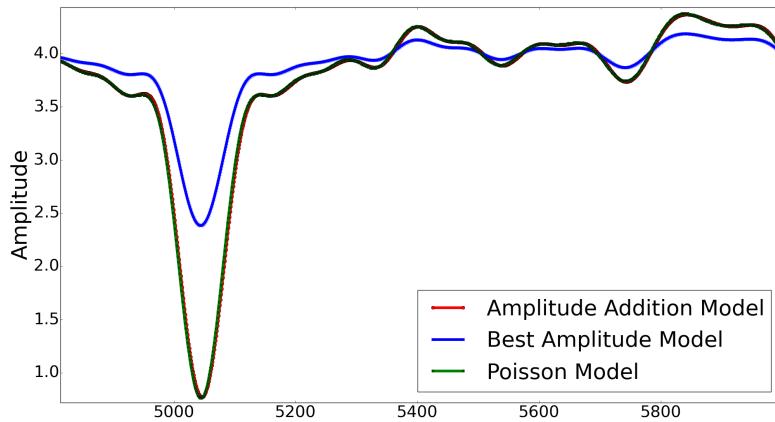


Bild 2.8: Vergleich l Best Amplitude Model und l Addition Amplitude Model [JWHK16]

Eine genauere Beschreibung der Berechnung des Formfaktors α und des inversen Skalenparameters β der Gammafunktion findet sich in [MTM⁺20]. Hier wird der Parameter λ für jede Zelle eines 2D-Gitters berechnet. Die Wahrscheinlichkeit für die Anzahl N an Aktivitäten innerhalb eines Zeitintervalls in einer Zelle des Gitters kann dargestellt werden über

$$P_{ij\tau}(N(t) = k) = \frac{(\lambda_{ij\tau}(t - t_\tau))^k}{k!} e^{-\lambda_{ij\tau}(t - t_\tau)}, \quad (2.30)$$

wobei $\lambda_{ij\tau}$ für die Rate an Aktivitäten der Zelle (i, j) innerhalb des Zeitintervalls τ steht. Die der Zelle und dem jeweiligen Intervall zugehörigen Parameter $\alpha_{ij\tau}$ sowie $\beta_{ij\tau}$ werden inkrementell für jeden Zeitschritt σ bestimmt mittels der Vorschrift

$$\alpha_\sigma = \alpha_{\sigma-1} + x_\sigma \mathbf{1}_{\mathcal{D}}(\mathbf{x}_R, t_\sigma), \quad \beta_\sigma = \beta_{\sigma-1} + \mathbf{1}_{\mathcal{D}}(\mathbf{x}_R, t_\sigma). \quad (2.31)$$

Als Anfangswerte werden $\alpha_0 = \beta_0 = 1$ gewählt. Die Indikator-Funktion $\mathbf{1}_{\mathcal{D}}(\mathbf{x}_r, t_\sigma)$ resultiert hierbei aus dem Detektionsbereich eines Roboters bei der Pose \mathbf{x}_R . Die a-posteriori erwarteten Werte der Aktivitätenrate λ und ihrer Varianz berechnen sich nun für jedes Intervall zu

$$\hat{\lambda}_{ij\tau} = E[\lambda_{ij\tau}] = \frac{\alpha_{ij\tau}}{\beta_{ij\tau}}, \quad \text{Var}[\lambda_{ij\tau}] = \frac{\alpha_{ij\tau}}{\beta_{ij\tau}^2}. \quad (2.32)$$

3 Methodik

Dieses Kapitel behandelt die Methodik zur Prädiktion von Umweltzuständen. Die Beschreibung der verwendeten Methoden erfolgt separat für binäre Zustandsmodelle (Abschnitt 3.1), bei denen die Wahrscheinlichkeit $p(t)$ für einen Umweltzustand, wie beispielsweise die Belegtheit $s(t)$ einer Zelle innerhalb eines geografischen Gitters, bestimmt werden soll, sowie für quantitative Zustandsmodelle (Abschnitt 3.2), bei denen Aussagen über die Anzahl an Ereignissen innerhalb einer Zelle während eines bestimmten Zeitintervalls getroffen werden sollen.

3.1 Binäre Zustandsmodelle

Binäre Zustandmodelle dienen, wie schon in Abschnitt 2.5 erläutert, der Beschreibung einer Zustandsfunktion $s(t)$ durch eine Wahrscheinlichkeitsfunktion $p(t)$. In den folgenden Abschnitten werden die Schritte zur Bestimmung dieser Modelle durchgegangen. Werden in einem ersten Schritt die Messdaten eines Belegtheitsgitters ermittelt (Abschnitt 3.1.1), so erfolgt in einem weiteren Schritt die Client-seitige Verarbeitung dieser Messdaten (Abschnitt 3.1.2), bevor die Daten an einen Server geschickt werden, auf welchem diese zur Erstellung binärer Zustandsmodelle verwendet werden (Abschnitt 3.1.3).

3.1.1 Messdatenermittlung eines Belegtheitsgitters

Den ersten Schritt der Methodik bildet die Aufzeichnung von Messdaten. Als Messdaten werden die Detektionen von Personen innerhalb einer Umgebung \mathcal{U} bezeichnet. Eine Umgebung \mathcal{U} ist ein geografisch abgegrenztes Gebiet, als Beispiele können hier ein Bürogebäude, ein Apartment oder ein offenes Gelände genannt werden. Die Ermittlung der Messdaten kann zum Beispiel durch einen, mit einem Personen-Detektions-Algorithmus ausgestatteten, mobilen Roboter erfolgen, oder durch mehrere, in \mathcal{U} verteilte, statische Sensoren, welche ebenfalls das Auftreten von Personen detektieren können. Werden innerhalb eines Zeitraumes T insgesamt N Personen detektiert, also N Messungen aufgezeichnet, so lässt sich die Gesamtheit der Messungen schreiben als

$$\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N)^T. \quad (3.1)$$

Die Messung einer einzelnen Personendetektion ist hierbei

$$\mathbf{x}_i = (x_{\text{det}}, y_{\text{det}}, t_{\text{det}})^T. \quad (3.2)$$

Eine Messung beinhaltet die x-Position x_{det} der Detektion innerhalb des Umgebungskoordinatensystems ($\text{KS}_{\mathcal{U}}$), die y-Position y_{det} der Detektion innerhalb des Umgebungskoordinatensystems, sowie den Zeitstempel t_{det} der Detektion. Für die weitere Betrachtung wird über die Umgebung \mathcal{U} ein Gitter gelegt, welches aus diskreten, räumlich finiten Zellen besteht. Grafisch veranschaulicht ist dieses Verfahren in Bild 3.1.

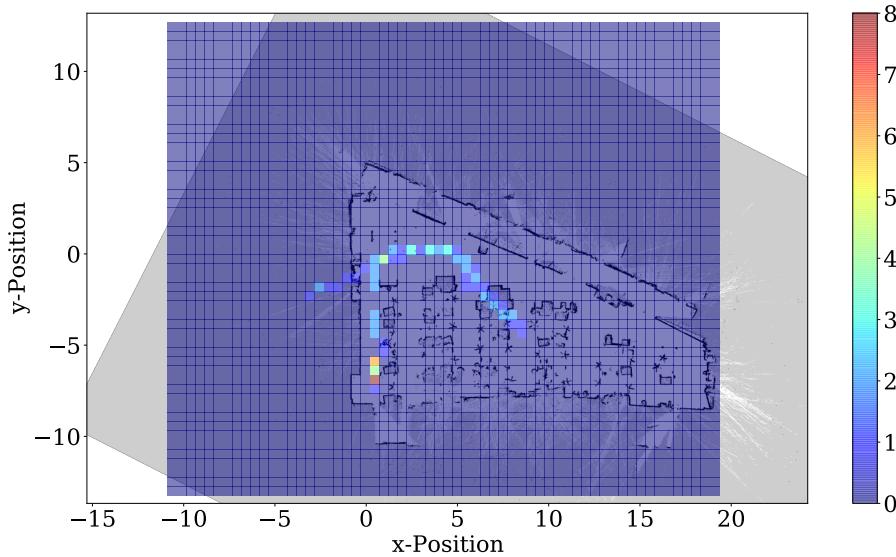


Bild 3.1: Belegungskarte eines Bürogebäudes, über welches ein Gitter (blau) gelegt ist

Zu sehen sind hier die schematischen Umrisse eines Bürogebäudes. In blau dargestellt und über die Büroumriss gelegt ist das oben beschriebene Gitter. Die Farbinformation spiegelt die Anzahl an Messdaten innerhalb der einzelnen Zellen wider. Eine Zelle ist dabei durch ihre x- und y-Position innerhalb des Umgebungscoordinatensystems ($\text{KS}_{\mathcal{U}}$) definiert. Ist die Umgebung \mathcal{U} in einzelne Zellen unterteilt, lässt sich das oben beschriebene Gitter in

Matrixschreibweise ausdrücken als

$$G_{\text{Gitter}} = \begin{pmatrix} A_{1,1} & A_{1,2} & \dots & A_{1,n} \\ A_{2,1} & A_{2,2} & \dots & A_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ A_{n,1} & A_{n,2} & \dots & A_{n,n} \end{pmatrix}. \quad (3.3)$$

Hierbei bezeichnet $A_{2,2}$ beispielsweise die Zelle der zweiten Reihe und der zweiten Spalte des Gitters, in welches die Umgebung eingeteilt wird. Es ist zu erwähnen, dass es sich um ein rechteckiges Gitter handelt, welches über die Umgebung \mathcal{U} gelegt wird. Der Bereich einer Zelle $A_{i,j}$ ist definiert durch ihre Grenzen x_{left} und x_{right} in x-Richtung, sowie die Grenzen y_{bottom} und y_{top} in y-Richtung des Umgebungskoordinatensystems $(KS)_{\mathcal{U}}$. Eine Detektion x_i wird der Zelle $A_{i,j}$ zugeordnet, sofern gilt

$$x_{\text{det}} \in [x_{\text{left}}, x_{\text{right}}] \wedge y_{\text{det}} \in [y_{\text{bottom}}, y_{\text{top}}]. \quad (3.4)$$

Ein Eintrag in einer Zelle $A_{i,j}$ besteht aus einem Tupel mit den Einträgen (a, t_{det}) . Der Parameter a nimmt im Fall einer Personendetektion den Wert 1 an, t_{det} beinhaltet die zeitliche Information der Personendetektion. Werden nach und nach mehr Detektionen innerhalb einer bestimmten Zelle getätigkt, enthält die Zelle $A_{i,j}$ eine Menge \mathcal{L} bestehend aus l Tupeln. Zeichnet man alle Detektionen für einen bestimmten Zeitraum, zum Beispiel für eine Woche auf, lassen sich die Messungen in Zeitintervalle Δt_n unterteilen. Beträgt die Gesamtdauer des zum Aufzeichnen von Detektionen betrachteten Zeitraumes T , so ergibt sich die Gesamtzahl an Intervallen bei einer Intervalllänge von Δt zu

$$n_t = \frac{T}{\Delta t}. \quad (3.5)$$

Die Dauer des Zeitraumes $T = t_b - t_a$ wird durch seinen Startzeitpunkt t_a sowie seinen Endzeitpunkt t_b definiert. Das n -te Zeitintervall Δt_n befindet sich innerhalb der Grenzen $[t_a + n\Delta t, t_a + (n+1)\Delta t]$. Um die Übersichtlichkeit der Methodik weiterhin gewährleisten zu können, wird im Folgenden die Zelle $A_{i,j}$ nur noch mit A bezeichnet. Um die Aktivität, beziehungsweise das Personenaufkommen in einer Zelle des Gitters bestimmen zu können, wird die Anzahl der Detektionen pro Zeitintervall aufsummiert. Die Summe an Detektionen in der Zelle A im n -ten Zeitintervall lässt sich schreiben als

$$a_n = \sum_{k=1}^K l_k \in [t_a + n\Delta t, t_a + (n+1)\Delta t], \quad (3.6)$$

wobei mit K die Gesamtanzahl der Detektionen innerhalb des Gesamtzeitraumes T bezeichnet ist. Nach der Unterteilung des gesamten Zeitraumes in Intervalle und das Aufsummieren der Detektionen innerhalb dieser Intervalle enthält jede Zelle die Information des zeitlichen Verlaufes des Personenaufkommens innerhalb ihrer geografischen Grenzen. Die Zelle \mathbf{A} und die in ihr enthaltene Information lässt sich schreiben als

$$\mathbf{A} = (\mathbf{a}, \mathbf{t})^T. \quad (3.7)$$

Hierbei bezeichnet $\mathbf{a} = (a_1, a_2, \dots, a_n)^T$ alle aufsummierten Personendetektionen innerhalb der Zeitintervalle mit den korrespondierenden Zeitstempeln $\mathbf{t} = (t_1, t_2, \dots, t_n)^T$. Als Zeitstempel jeden Intervalls wird dessen Startzeitpunkt gewählt. Anschaulich beschrieben erhält man für jeden Zeitstempel die Information, wie viele Personen sich innerhalb des betreffenden Zeitintervalls in den Zellen des Gitters befunden haben. Für einen Betrachtungszeitraum mit n Zeitstempeln ergibt sich eine dreidimensionale Matrix, auf dessen dritter Achse n Matrizen $\mathbf{G}_{\text{Gitter}}$ (vgl. Gleichung 3.3) hintereinander gestapelt werden. Im Falle des binären Zustandsmodells werden die Einträge jeder Zelle eines Zeitstempels durch die Werte $\{0, 1\}$ abgebildet. Es wird lediglich das Vorhandensein einer Person innerhalb eines Zeitintervalls in einer Zelle registriert, nicht jedoch die Anzahl der Personen innerhalb des Zeitintervalls. Ein qualitativer Vergleich der beiden Methoden kann durch Bild 3.2 gezogen werden.

Beiden Abbildungen liegen aufsummierte Personendetektionen innerhalb eines Zeitraumes von einer Woche mit der Aufteilung in Zeitintervalle von $\Delta t = 600$ s zugrunde. Im linken Bild sieht man die Darstellung von Detektionen, welche pro Zeitintervall auf $\{0, 1\}$ beschränkt sind. Farblich hervorgehoben sind hier also Zellen, welche über viele Zeitintervalle hinweg häufig besucht wurden. Im rechten Bild dargestellt sind die nicht beschränkten, aufsummierten Personendetektionen aufgeführt. Farblich hervorgehoben sind hier die Zellen, welche innerhalb des gesamten Betrachtungszeitraumes am häufigsten besucht wurden, dies sich aber auf eine relativ kurze Zeitspanne innerhalb des Betrachtungszeitraumes beschränken kann. Im weiteren Verlauf dieses Kapitels wird lediglich der binäre Fall behandelt, also die auf $\{0, 1\}$ beschränkte Detektion von Personen innerhalb eines Zeitintervalls. Die so ermittelten Daten bilden einen Trend über den Betrachtungszeitraum ab. Die Unterteilung in Zeitintervalle ist der Tatsache geschuldet, dass in der Praxis das Wissen über die Zellzustände lückenhaft ist. Es kann lediglich durch, von einem mobilen Roboter durchgeführte, stichprobenartige Messungen approximiert werden. Mit einer größer werdenden Intervalldauer lassen sich die Messungen flexibler durchführen. Eine größere Intervalldauer geht jedoch mit einer stetig steigenden Verallgemeinerung des Zellzustandes und dem Verlust von Informationen einher. Die registrierten Daten werden in einem weiteren Schritt in einer Datenbank gespeichert.

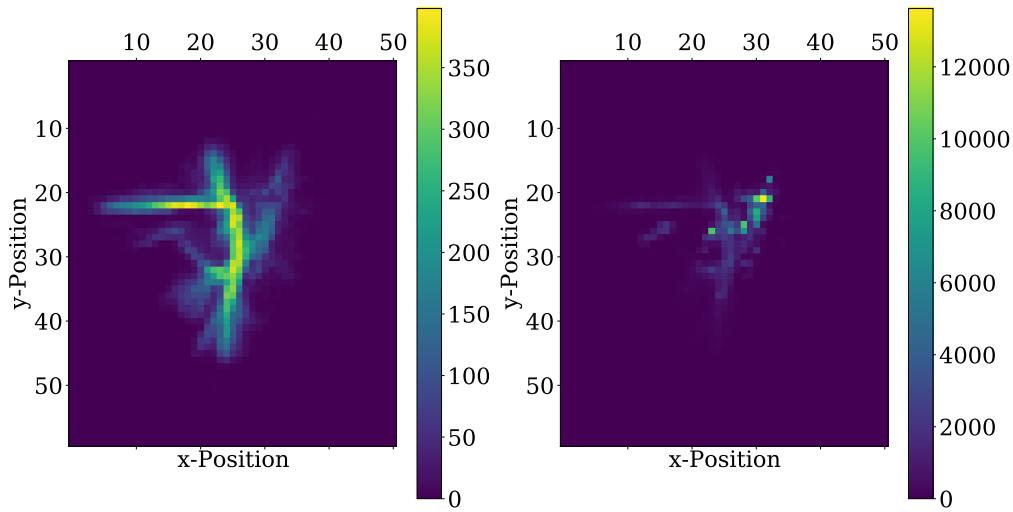


Bild 3.2: Aufsummierte Personendetektionen innerhalb eines Zeitraumes von einer Woche mit Beschränkung auf $\{0, 1\}$ (links) und ohne Beschränkung (rechts)

Dies ermöglicht den externen Zugriff eines in Abschnitt 3.1.2 behandelten Clients auf die Messdaten. Ein einzelner Eintrag in der Datenbank besitzt dabei immer den gleichen Aufbau. Neben dem Zellennamen werden der Zeitstempel sowie die Information, ob die Zelle im betrachteten Zeitintervall belegt oder frei war, gespeichert.

3.1.2 Verarbeitung der Messdaten Client-seitig

Auf der Clientseite wird das Gitter G_{Gitter} mit seinen Zelleinträgen $A_{i,j}$ rekonstruiert. Hierzu greift der Client auf die in Abschnitt 3.1.1 beschriebene Datenbank zu und erstellt seinerseits ein Gitter, in welchem jede Zelle einer Matrix, bestehend aus einem Vektor an Zeitstempeln und dem dazu korrespondierenden Vektor der Personendetektionen, nach Gleichung 3.7 angelegt wird. Der Zustand jeder einzelnen Zelle des Gitters ist als Funktion der Zeit innerhalb des Clients gespeichert und lässt sich nach [KFC⁺14] als $s(t)$ schreiben. Da auch in dieser Arbeit von dem Ansatz ausgegangen wird, dass das menschliche Verhalten, also auch das örtliche Auftreten von Personen, gewissen zeitlichen Periodizitäten unterliegt, werden die Daten der einzelnen Zellen im Folgenden an einen Server geschickt, auf welchem Untersuchungen ihrer Frequenzspektren erfolgen.

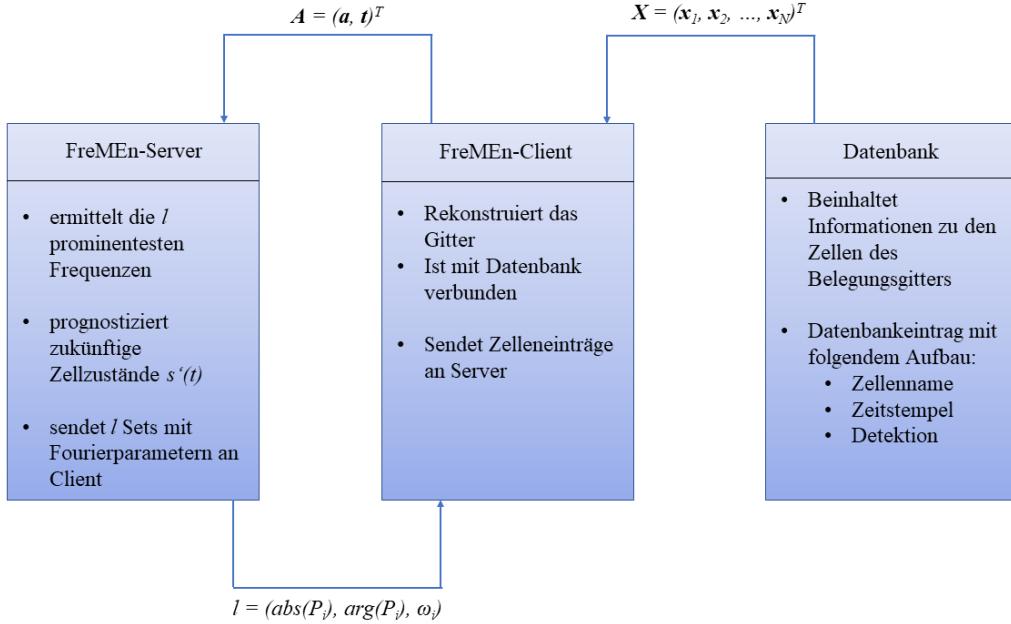


Bild 3.3: Informationsfluss binäres Modell

3.1.3 Verarbeitung der Messdaten Server-seitig

Der Server erstellt für jede Zelle des Belegtheitsgitters ein Modell. Als Eingang dienen dem Server die von dem Client gesendeten Datenarrays der einzelnen Zellen mit den Zeitstempeln und den dazu gehörigen Belegtheitsinformationen. Da die Zellen als linear unabhängig betrachtet werden, wird für jede Zelle ein eigenes Modell erstellt. Als Eingangsgröße dient, wie schon in [KFC⁺14], die Belegtheit der Zelle als Funktion von der Zeit $s(t)$. Es sei darauf hingewiesen, dass $s(t)$ keine kontinuierliche, sondern eine diskrete, binäre Funktion mit Einträgen zu den Zeitpunkten der Zeitstempel ist. Die Funktion $s(t)$ soll durch eine Wahrscheinlichkeitsfunktion $p(t)$ approximiert werden. Das Vorgehen entspricht der Frequency-Map-Enhancement (FreMEn) Methode aus [KKM⁺15]. Das Frequenzspektrum der Funktion $s(t)$ soll ermittelt werden. Hierzu wird eine inkrementelle Fouriertransformation des Zustandsvektors $s(t)$ durchgeführt mit

$$\begin{aligned}
\mu &\leftarrow \frac{1}{n+1}(n\mu + s(t)), \\
\alpha_k &\leftarrow \frac{1}{n+1}(n\alpha_k + s(t)e^{-jt\omega_k}), \quad \forall \omega_k \in \Omega, \\
\beta_k &\leftarrow \frac{1}{n+1}(n\beta_k + \mu e^{-jt\omega_k}), \quad \forall \omega_k \in \Omega, \\
n &\leftarrow n + 1.
\end{aligned} \tag{3.8}$$

Gleichung 3.8 gleicht dem Vorgehen aus [KSD15]. Mit jeder neuen Detektion werden die Werte aktualisiert. Zur Erinnerung sei darauf hingewiesen, dass die Grundidee dieser Methode darin besteht, die zeitliche Zustandsfunktion $s(t)$ jeder Zelle des Gitters durch eine Wahrscheinlichkeitsfunktion $p(t)$ zu approximieren, welcher l periodische Prozesse zugrunde liegen. Die Zustandsfunktion jeder Zelle wird dabei durch die Zellzustände zu den Zeitstempeln t_1, t_2, \dots, t_n , ihren Durchschnittswert μ , und zwei Mengen \mathcal{A}, \mathcal{B} komplexer Zahlen α_k und β_k des korrespondierenden periodischen Prozesses mit der Frequenz ω_k aus der Menge Ω beschrieben. Initialisiert wird jede Zelle mit dem Durchschnittswert $\mu = 0.5$, alle Werte α_k, β_k werden zu 0 gesetzt. Der Betrag $\gamma_k = |\alpha_k - \beta_k|$ entspricht dem durchschnittlichen Einfluss des periodischen Prozesses mit der Frequenz ω_k auf den Zellzustand $s(t)$.

Im Gegensatz zu [KSD15] wird im Vorhinein eine feste Periodendauer T von beispielsweise einer Woche vorgegeben. Da die Observationen innerhalb diskreter, über den Zeitraum T gleichmäßig verteilter Intervalle Δt erfolgen, vereinfacht sich Gleichung 3.8 formal zur traditionellen Diskreten Fouriertransformation (DFT). Die Informationen über den Zellzustand $s(t)$ werden, wie in Abschnitt 3.1.1 beschrieben, innerhalb einer Datenbank gespeichert. Beträgt die Gesamtdauer der in der Datenbank gespeicherten Daten n mal T , sind also n Samples der a priori definierten Periodendauer T gegeben, so erfolgt eine Mittelung der Werte innerhalb korrespondierender Zeitintervalle Δt_i durch

$$\begin{aligned}
\bar{\mu} &= \frac{1}{n} \sum_{i=1}^n \mu_i, \\
\bar{\alpha}_k &= \frac{1}{n} \sum_{i=1}^n \alpha_{k,i}, \\
\bar{\beta}_k &= \frac{1}{n} \sum_{i=1}^n \beta_{k,i}.
\end{aligned} \tag{3.9}$$

Die Wahrscheinlichkeitsfunktion $p(t)$ des Zellzustandes $s(t)$ wird wie in [KSD15] mittels Extraktion der l periodischen Prozesse mit den höchsten Amplituden $\bar{\gamma}_k = |\bar{\alpha}_k - \bar{\beta}_k|$ gebildet. Nach deren Überlagerung ergibt sich die Wahrscheinlichkeitsfunktion $p(t)$ zu

$$p(t) = \zeta(\bar{\mu} + \sum_{l=1}^m |\bar{\gamma}_l| \cos(\omega_k t + \arg(\bar{\gamma}_l))). \quad (3.10)$$

Hierbei versichert $\zeta(\cdot)$, dass die Funktion $p(t) \in [0, 1]$ ist. Zur Erläuterung sei angemerkt, dass, obwohl die Werte von $s(t)$ im hier betrachteten binären Fall lediglich die Zustände $\{0, 1\}$ annehmen können, die durch Fouriertransformation und inverse Fouriertransformation ermittelte Funktion $p(t)$ Werte größer als 1 annehmen kann.

Die Berechnung von $p(t)$ durch Gleichung 3.10 erlaubt es, zukünftige Zustände $s(t)$ einer Zelle zu ermitteln. Ein beliebiger Zeitpunkt t wird dazu auf dem entsprechenden Zeitintervall Δt_n innerhalb des Gesamtzeitraumes T abgebildet. Die Vorhersage $s'(t)$ des Zellzustandes erfolgt mittels eines Schwellwertes c zu

$$s'_i(t) = \begin{cases} 1 & , \quad p(t) \geq c \\ 0 & , \quad p(t) < c \end{cases}. \quad (3.11)$$

Zur Ermittlung der optimalen Anzahl l_{opt} an periodischen Prozessen zur Bestimmung der Wahrscheinlichkeitsfunktion $p(t)$ wird auf die Einteilung des Datensatzes in ein „Estimation-Set“ sowie ein „Prediction-Set“ eingegangen. Ist die Gesamtdauer der in der Datenbank vorhandenen Zelleinträge T , so werden zur Berechnung der Modellkoeffizienten nach Gleichung 3.8 Daten innerhalb des Zeitintervalls ΔT_{Est} verwendet. Der Schätzfehler $\epsilon_r(T)$, also die Genauigkeit, mit der das Modell die zu seiner Erstellung verwendeten Daten rekonstruiert kann, ergibt sich zu

$$\epsilon_r(\Delta T_{\text{Est}}) = \frac{1}{n} \sum_{i=1}^n |s'_i(t) - s_i(t)|. \quad (3.12)$$

Alle zur Berechnung des Fehlers ϵ_r verwendeten Daten müssen innerhalb des Intervalls ΔT_{Est} liegen.

Das Zeitintervall ΔT_{Pred} beinhaltet Messungen, welche nicht zur Erstellung des Modells verwendet wurden. Der Fehler ϵ_p beschreibt, wie genau das Modell zukünftige Zustände einer Zelle vorhersagen kann. Der Fehler ϵ_p berechnet sich als

$$\epsilon_p(\Delta T_{\text{Pred}}) = \frac{1}{n} \sum_{i=1}^n |s'_i(t) - s_i(t)|, \quad (3.13)$$

mit allen Messwerten innerhalb des Intervalls ΔT_{Pred} . Die optimale Modellordnung l_{opt} wird nach [KSD15] so gewählt, dass der Prädiktionsfehler ϵ_p minimiert wird. Die maximale Modellordnung wird zu $l_{\text{max}} = 20$ gesetzt.

3.2 Quantitative Zustandsmodelle

Um Aussagen über die Anzahl an Ereignissen innerhalb eines Zeitintervalls treffen zu können, kann dies, wie schon in Abschnitt 2.5 erwähnt, mittels quantitativer Zustandsmodelle erreicht werden. Es sollen Schätzungen $\lambda'(t)$ für die, intervallweise definierte, Funktion $\lambda(t)$ einer Aktivitätenrate berechnet werden. Hierzu folgt in einem ersten Schritt die Ermittlung von Messdaten eines Belegtheitsgitters (Abschnitt 3.2.1), bevor diese Daten Client-seitig verarbeitet werden (Abschnitt 3.2.2). In einem weiteren Schritt werden die Daten an einen Server gesendet, welcher für jede Zelle des Belegtheitsgitters ein quantitatives Zustandsmodell erstellt (Abschnitt 3.2.3).

3.2.1 Messdatenermittlung eines Belegtheitsgitters

Wie schon in Abschnitt 3.1 wird auch in diesem Abschnitt, welcher quantitative Zustandsmodelle behandelt, ein Gitter über eine Umgebung \mathcal{U} gelegt, und für einen Betrachtungszeitraum T , unterteilt in n Intervalle mit der Intervalldauer Δt , die Personendetektionen innerhalb der Zellen gezählt. Die Methodik gleicht der des binären Modells, jedoch erfolgt keine Beschränkung der Detektionen pro Intervall auf $\{0,1\}$. Die Einträge einer einzelnen Zelle des Gitters werden geschrieben als

$$\mathbf{A} = (\boldsymbol{\lambda}, \mathbf{t})^T. \quad (3.14)$$

Da im quantitativen Fall die Anzahl an Personen pro Zeitintervall Δt , also die Personenrate gezählt wird, enthält Gleichung 3.14 die Personenraten $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \dots, \lambda_n)$ der einzelnen Zeitintervalle sowie die Zeitstempel $\mathbf{t} = (t_1, t_2, \dots, t_n)$ der zugehörigen Intervalle. Eine Erhöhung der Intervalldauer Δt geht dabei mit steigenden Einträgen der Personenraten $\boldsymbol{\lambda}$ und einem Informationsverlust einher.

Die registrierten Daten werden, wie schon in Abschnitt 3.1.1, in einer Datenbank gespeichert. Ein Datenbankeintrag enthält neben dem Zellennamen den Zeitstempel des Zeitintervalls sowie die zugehörige Personenrate λ des Intervalls.

3.2.2 Verarbeitung der Messdaten Client-seitig

Die Verarbeitung der Messdaten auf der Clientseite gleicht dem Vorgehen in Abschnitt 3.1.2. Das Gitter G_{Gitter} mit seinen Zelleinträgen $A_{i,j}$ wird rekonstruiert. Jede rekonstruierte Zelle enthält einen Vektor t an Zeitstempeln und den Vektor λ der Personenraten der einzelnen Zeitintervalle. Die beiden Vektoren jeder Zelle werden im nächsten Schritt an den Server geschickt, auf welchem Untersuchungen der Frequenzspektren der Zelle erfolgen.

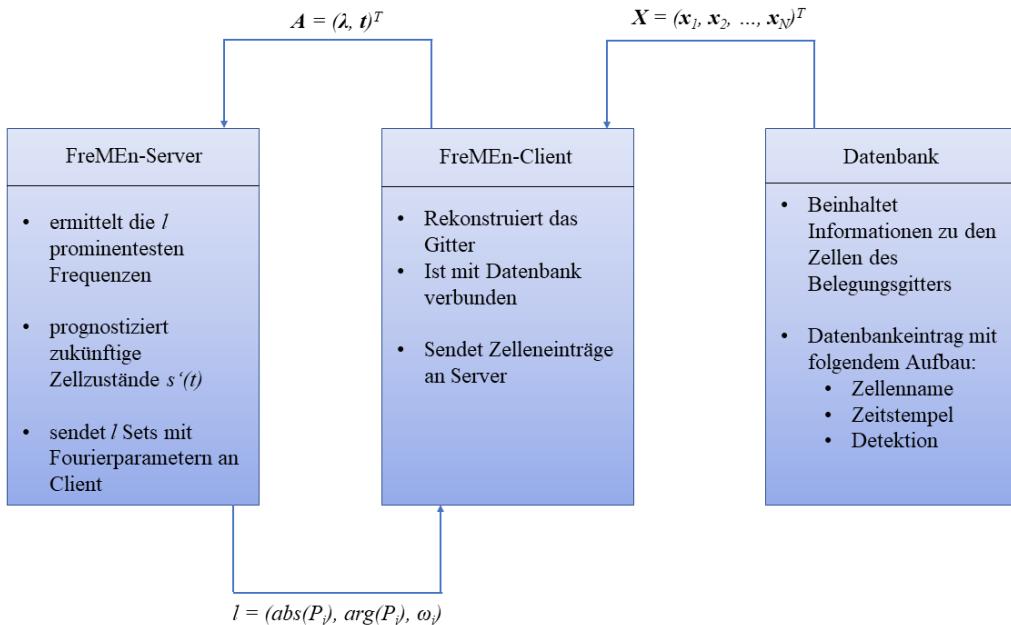


Bild 3.4: Informationsfluss quantitatives Modell

3.2.3 Verarbeitung der Messdaten Server-seitig

Wie schon in Abschnitt 3.1.2 erstellt der Server auch für den quantitativen Fall für jede Zelle des Belegtheitsgitters ein Modell. Wieder wird aufgrund der linearen Unabhängigkeit der Zellen für jede einzelne Zelle ein eigenes Modell erstellt. Als Eingangsgröße dient, wie in [JWHK16], die Personenrate $\lambda(t)$ als Funktion der Personenraten der einzelnen Zeitintervalle Δt . Die Funktion $\lambda(t)$ soll durch eine Funktion $\lambda'(t)$ approximiert werden. Nach [KKM⁺15] erfolgt eine inkrementelle Fouriertransformation der Personenraten-Funktion $\lambda(t)$ durch Gleichung 3.8. Liegen in der Datenbank insgesamt n Samples der a priori definierten Periodendauer T vor, so erfolgt eine Mittelung der Werte korrespondierender Zeitintervalle Δt_i .

nach Gleichung (3.9). Die Approximation $\lambda'(t)$ der Personenraten-Funktion $\lambda(t)$ ergibt sich zu

$$\lambda'(t) = \zeta(\bar{\mu} + \sum_{l=1}^m |\bar{\gamma}_l| \cos(\omega_k t + \arg(\bar{\gamma}_l))). \quad (3.15)$$

Hierbei versichert $\zeta(\cdot)$, dass die Funktion $\lambda'(t)$ den Wert der am nächsten liegenden, natürlichen Zahl, annimmt. Zur Ermittlung der optimalen Anzahl l_{opt} an periodischen Prozessen zur Bestimmung der Personenraten-Funktion $\lambda(t)$ wird der Datensatz in ein „Estimation-Set“ sowie ein „Prediction-Set“ eingeteilt. Der Schätzfehler $\epsilon_r(T)$, also die Genauigkeit, mit der das Modell die zu seiner Erstellung verwendeten Daten rekonstruieren kann, berechnet sich durch

$$\epsilon_r(\Delta T_{\text{Est}}) = \frac{1}{n} \sum_{i=1}^n |\lambda'_i(t) - \lambda_i(t)|. \quad (3.16)$$

Alle zur Berechnung des Fehlers ϵ_r verwendeten Daten müssen innerhalb des Intervalls ΔT_{Est} liegen.

Das Zeitintervall ΔT_{Pred} beinhaltet Messungen, welche nicht zur Erstellung des Modells verwendet wurden. Somit beschreibt der Fehler ϵ_p wie schon in Abschnitt 3.2.3, wie genau das Modell zukünftige Personenraten einer Zelle vorhersagen kann. Der Fehler ϵ_p beträgt

$$\epsilon_p(\Delta T_{\text{Pred}}) = \frac{1}{n} \sum_{i=1}^n |\lambda'_i(t) - \lambda_i(t)|, \quad (3.17)$$

mit allen Messwerten innerhalb des Intervalls ΔT_{Pred} . Die optimale Modellordnung l_{opt} wird so gewählt, dass der Prädiktionsfehler ϵ_p minimiert wird. Die maximale Modellordnung wird zu $l_{\text{max}} = 20$ gesetzt.

4 Evaluation

Ein paar einleitende Sätze über den Inhalt des Kapitals
sollten hier hin

4.1 Datensätze

Zur Evaluation der in dieser Arbeit präsentierten Methode dienen zwei separate Datensätze. Der im Folgenden als „Aruba-Datensatz“ bezeichnete Datensatz zeichnete über einen Zeitraum von 16 Wochen das Personenaufkommen innerhalb einer Wohnung auf. Hierbei wurde die Wohnung in verschiedene Räume aufgeteilt und minütlich der Aufenthaltsort einer Person dokumentiert. Als Beschränkung gilt, dass sich zu jedem Zeitpunkt nur maximal eine Person in der Wohnung befinden konnte. Befand sich die Person außerhalb der Wohnung, so ist dies im Datensatz als Raum „Outside“ dokumentiert. Die in den folgenden Abschnitten durchgeführten Untersuchungen beruhen stets auf einem Modell, welches mittels der Daten der ersten zwölf der insgesamt 16 Wochen nach den Gleichungen 3.8 trainiert wurde. Zur Evaluation des Modells wird der Prädiktionsfehler ϵ_p für die letzten vier Wochen des Datensatzes berechnet. Als Modellordnung l wird, wie schon in Abschnitt 3.1.3 beschrieben, die Ordnung mit dem geringsten Prädiktionsfehler ϵ_p gewählt.

Weiter

„p“

für
Prädiktion

sollt,
dann

nicht

WWIV
schreiben

Der zweite Datensatz, im Folgenden als „UOL-Datensatz“ bezeichnet, wurde durch einen, an einer statischen Position befindlichen, Roboter ermittelt. Dieser zeichnete innerhalb eines Bürogebäudes mit einer Frequenz von 0.5 Hz Personendetektionen mit den zugehörigen Zeit- und Positionsstempeln über einen Gesamtzeitraum von 23 Tagen auf. Zur Modellberechnung wurden jeweils die ersten zwei Wochen des Datensatzes verwendet. Zur Evaluierung wurde ϵ_p mittels der Daten der dritten Woche berechnet. Als Modellordnung wird auch hier die Ordnung l mit dem geringsten Prädiktionsfehler ϵ_p gewählt.

4.2 Beschreibung der Fehlermaß

4.2.1 Fehlermaße binäres Modells

Für die Bewertung der Modelle wird ein einheitliches Fehlermaß benutzt. Wie schon in Abschnitt 2.4 beschrieben und auch in [KFC⁺14] erwähnt, führt eine Erhöhung der Modellordnung dazu, dass die zur Erstellung des Modells verwendeten Daten genauer modelliert werden können. Der Rekonstruktionsfehler ϵ_r sinkt. Der Einfluss auf den Prädiktionsfehler ϵ_p , also die Genauigkeit, mit der zukünftige Zellzustände modelliert werden können, ist jedoch

← kurze Einleitung

du

Hier nur
Raum mit
Link
Wieviele
Räume insg.?

+ hier
auch Quelle
mit Link

komplexer. Grafisch dargestellt ist dies in Bild 4.1.

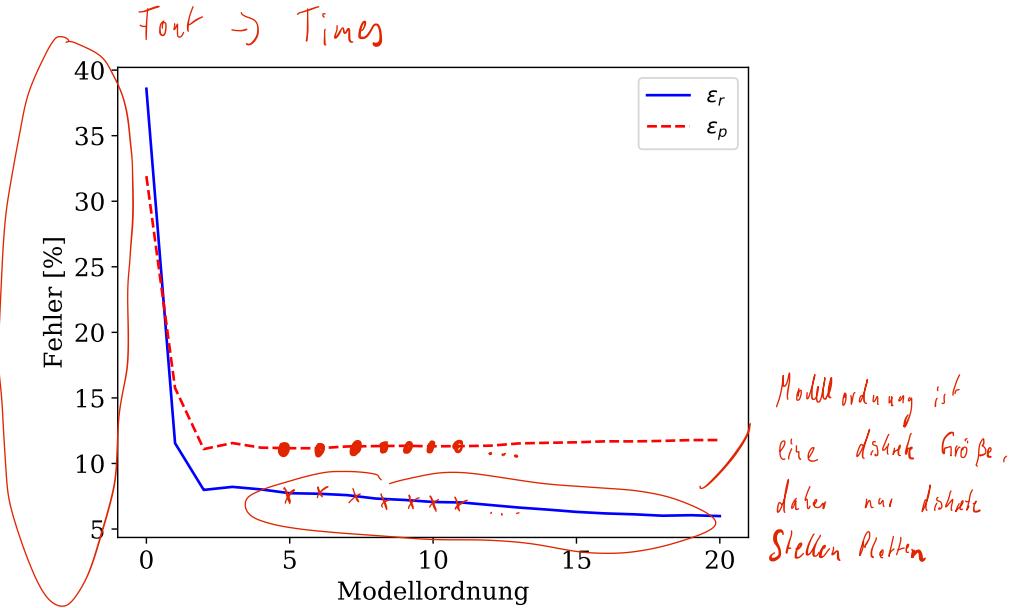


Bild 4.1: Rekonstruktionsfehler ϵ_r und Prädiktionsfehler ϵ_p mit steigender Modellordnung

Zur Bewertung der Modellgenauigkeiten wird in den folgenden Abschnitten stets die Modellordnung l_{opt} mit dem geringsten Prädiktionsfehler ϵ_p gewählt. Der Fehler berechnet sich dabei nach Gleichung 3.13. Die maximale Modellordnung wird zu $l_{\text{max}} = 20$ gesetzt. Der Schwellwert zur Ermittlung des prognostizierten Zellzustandes $s'(t)$ mittels der Zellwahrscheinlichkeitsfunktion $p(t)$ (siehe Gleichung 3.11) beträgt $c = 0.5$.

4.2.2 Fehlermaße quantitatives Modell

Die optimale Modellordnung l_{opt} des quantitativen Modells berechnet sich ebenfalls durch die Minimierung des Prädiktionsfehlers ϵ_p . Da für den quantitativen Fall jedoch die Personenraten $\lambda'(t)$ für die einzelnen Intervalle Δt_i berechnet werden, erfolgt die Ermittlung des Prädiktionsfehlers nach Gleichung 3.17. Die Rate $\lambda'(t)$ wird auf die nächste natürliche Zahl gerundet, damit sichergestellt ist, dass $\lambda'(t) \in \mathbb{N}$ gilt. Die maximale Modellordnung wird zu $l_{\text{max}} = 20$ gesetzt.

4.3 Binäres Modell

In diesem Abschnitt erfolgt eine Evaluation des binären Modells. Untersucht wird das Modell bei unterschiedlichen Intervalldauern Δt . Für den binären Fall berechnen sich die Personendetektionen im n -ten Zeitintervall (siehe Gleichung 3.6) zu

$$a_n = \begin{cases} 1 & , \text{ if } a_n \geq 1 \\ 0 & , \text{ else } a_n < 1 \end{cases} \quad (4.1)$$

Die Einteilung der gesamten Periodendauer, wie beispielsweise einer Woche, in unterschiedlich lange Intervalldauern, resultiert aus der Tatsache, dass ein mobiler Roboter im Normalfall keine komplette Übersicht über die zu modellierende Umgebung \mathcal{U} besitzt. Er kann nur stichprobenartig Teile des Gebietes abfahren. Je nach Umgebungsgröße und Übersicht des mobilen Roboters sollte die Intervalldauer angepasst werden. Die Summe an Zeitstempeln innerhalb der Periodendauer reduziert sich mit steigender Intervalldauer Δt . Wird innerhalb des zugehörigen Zeitintervalls mindestens eine Person detektiert, wird der Zellzustand $s(t)$ zu eins gesetzt. Die Auswirkungen unterschiedlicher Intervalldauern verdeutlicht Bild 4.2.

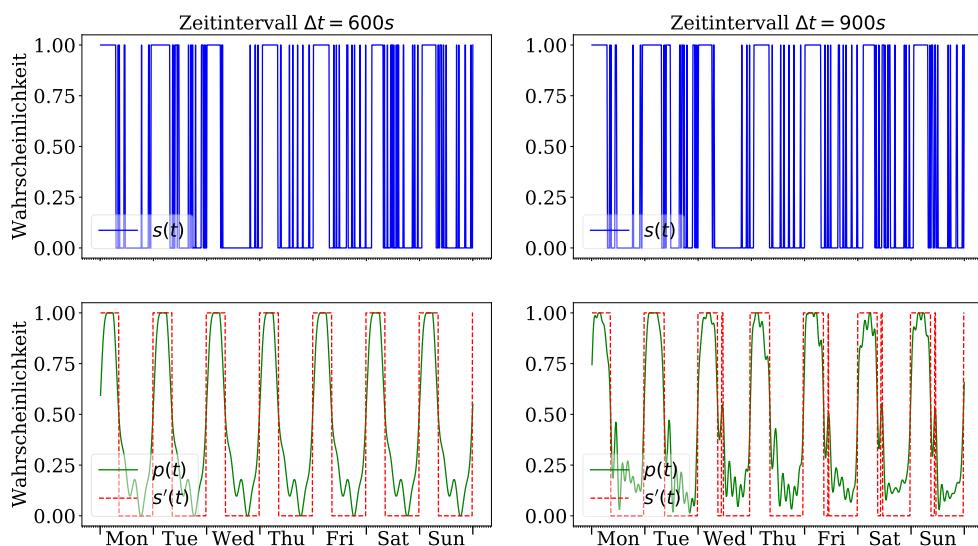


Bild 4.2: Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ des Schlafzimmers des Apartments mit einer Intervalldauer von $\Delta t = 600$ s (links) und $\Delta t = 900$ s (rechts)

Wie lange tatsächlich beobachtet wurde?
Doch wird davon ausgegangen, dass für jedes Intervall mindestens nur einmal jemanddetektiert werden muss und Nicht-Detektionen werden gleich behandelt wie ein Nicht-Beobachter des Bereiches!

4 Evaluation

mass nur am Anfang
es wird in Ablaufzeiten 34

Betrachtet wird hier das Schlafzimmer des Apartments des „Aruba-Datensatzes“. Die beiden Grafiken auf der linken Seite zeigen den Zellzustand $s(t)$ (oben) über einen Gesamtzeitraum von einer Woche für eine Intervalldauer von $\Delta t = 600$ s, die Wahrscheinlichkeitsfunktion $p(t)$ der Zelle sowie der anhand des Schwellwertes $c = 0.5$ prognostizierte Zellzustand $s'(t)$. Auf der rechten Seite von Bild 4.2 ist der Zellzustand $s(t)$ für eine Intervalldauer von $\Delta t = 900$ s sowie die Wahrscheinlichkeitsfunktion der Zelle und der prognostizierte Zellzustand $s'(t)$ aufgetragen. Während zur Bestimmung von $p(t)$ im Falle von $\Delta t = 600$ s eine Modellordnung von $l_{\text{opt}} = 2$ den Prädiktionsfehler auf einen Wert von $\epsilon_p = 17.8\%$ ~~Verringert?~~ minimiert, beträgt die optimale Modellordnung $l_{\text{opt}} = 3$ bei $\Delta t = 900$ s mit einem Prädiktionsfehler von $\epsilon_p = 7.4\%$. Für den statischen Fall, also die Annahme einer konstanten Wahrscheinlichkeit $p_{\text{stat}}(t) = \text{const.}$, ergibt sich $\epsilon_p = 40.5\%$ für eine Intervalldauer von $\Delta t = 600$ s, der statische Prädiktionsfehler bei einer Intervalllänge von $\Delta t = 900$ s berechnet sich zu $\epsilon_p = 44.3\%$. Die größere Intervalldauer spiegelt sich in dem Modell derart wieder, dass die Anzahl der Personendetektionen im Verhältnis zu der Anzahl n der Zeitstempel zunimmt, und die Breite der rot gestrichelten Balken, welche Phasen einer durchgängigen Zellbelegtheit signalisieren, in Bild 4.2 zunimmt.

Eine Limitation der Methode ist jedoch in Bild 4.3 zu sehen. Betrachtet wird der Zellzustand $s(t)$ des Gästeschlafzimmers innerhalb des Apartments.

Bei einer Intervalldauer von $\Delta t = 600$ s ergibt sich die, nach Gleichung 3.13, optimale Modellordnung zu $l_{\text{opt}} = 0$, dargestellt durch die konstante, statische Wahrscheinlichkeitsfunktion $p_{\text{stat}}(t)$. Zu dem selben Ergebnis kommt man bei einer Intervalldauer von $\Delta t = 900$ s. Auch hier beträgt die optimale Modellordnung $l_{\text{opt}} = 0$. Durch die Erhöhung der Personendetektionen im Vergleich zur Anzahl der Zeitstempel liegt die statische Wahrscheinlichkeit einer Personendetektion in der rechten, unteren Grafik von Bild 4.3 bei $p_{\text{stat}}(t) = 7.9\%$, während in der unteren linken Grafik $p_{\text{stat}}(t) = 7.5\%$ gilt. Die Personendetektionen beschränken sich auf seltene, kurzperiodige Bereiche, welche nicht durch die maximale Modellordnung von $l_{\text{max}} = 20$ modelliert werden können. Eine weitere Erhöhung von l würde jedoch dazu führen, dass der Rekonstruktionsfehler ϵ_r zwar sinken würde, die Generalisierungsfähigkeit des Modells jedoch verloren geht und es in der Folge zu einem Anstieg des Prädiktionsfehlers ϵ_p kommt. Der Prädiktionsfehler des statischen Modells bei einer Intervalldauer von $\Delta t = 600$ s ergibt sich zu $\epsilon_p = 6.5\%$, im Falle von $\Delta t = 900$ s zu $\epsilon_p = 7.4\%$.

Einen zusammenfassenden Überblick der Modellfehler gibt Tabelle 4.1.

Aufgeteilt nach unterschiedlichen Intervalldauern sind die Prädiktionsfehler ϵ_p aller Zellen für die optimale Modellordnung l_{opt} sowie für den statischen Fall aufgeführt. Betrachtet werden jedoch nur Zellen, welche während mindestens 5 % der betrachteten Zeitintervalle Δt_i belegt waren. Wie aus Bild 4.3 hervorgeht, ist die Modellierbarkeit kurzfristiger Zellen-

erhöht

Also mit dem darauffolgenden Satz
wurde bedacht das bei diesen
Datensatz wieviel Räume?

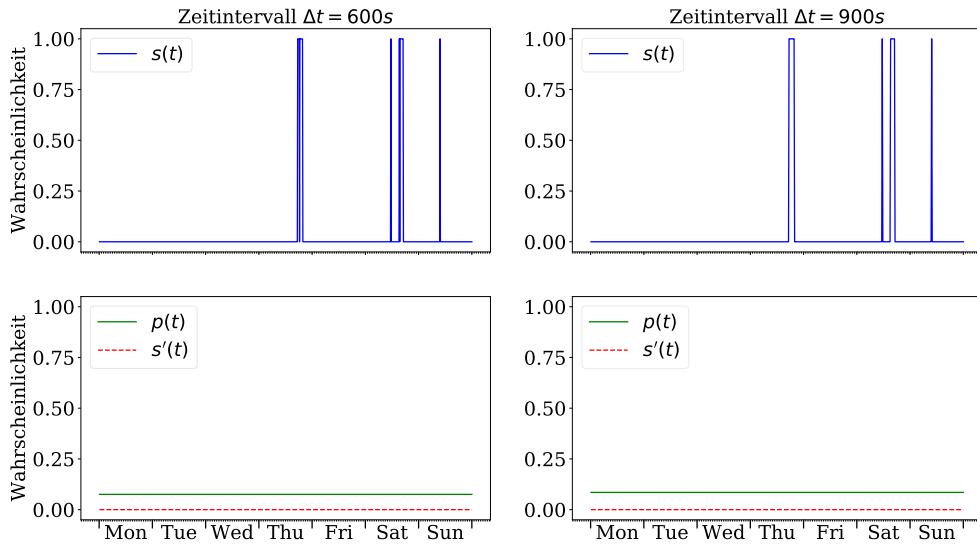


Bild 4.3: Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ des Gästeschlafzimmers des Apartments mit einer Intervalldauer von $\Delta t = 600\text{s}$ (links) und $\Delta t = 900\text{s}$ (rechts)

Tabelle 4.1: Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern Δt (Aruba)

Intervalldauer Δt	$\epsilon_{p,\text{opt}}$ bei $l = l_{\text{opt}}$	$\epsilon_{p,\text{stat}}$ bei $l = l_{\text{stat}}$	Vergleich l_{opt} zu l_{stat}
300 s	12.7 %	20.4 %	-37.74 %
600 s	14.4 %	23.42 %	-47.05 %
900 s	14.31 %	22.99 %	-37.5 %

wie genau wurde das berechnet?

belegtheiten limitiert. In diesen Fällen liegt das statische Modell mit einer prognostizierten, konstanten Zellenbelegtheit von $p(t) = \text{const} = 0$ bereits zu mindestens 95 % richtig und würde so die Evaluierung der Methode verfälschen.

Eine weitere Evaluation erfolgt anhand des „UOL-Datensatzes“. Erneut werden die Modelle bei verschiedenen Intervalldauern Δt , in welche die Periodendauer T eingeteilt wird, betrachtet. Wie in Abschnitt 4.1 erwähnt, werden zur Ermittlung der Modellparameter die Daten von zwei aufeinander folgenden Wochen benutzt. Die Ermittlung der optimalen Modellordnung l_{opt} mittels eines minimalen Prädiktionsfehlers ϵ_p erfolgt mit Daten einer weiteren, dritten Woche. Bild 4.4 zeigt den Unterschied des binären Modells bei einer Intervalldauer von

*wieviele Zellen insgesamt?
 Wieviel öfter als 5% belag?*

$\Delta t = 600 \text{ s}$ (links) sowie für $\Delta t = 900 \text{ s}$ (rechts) auf.

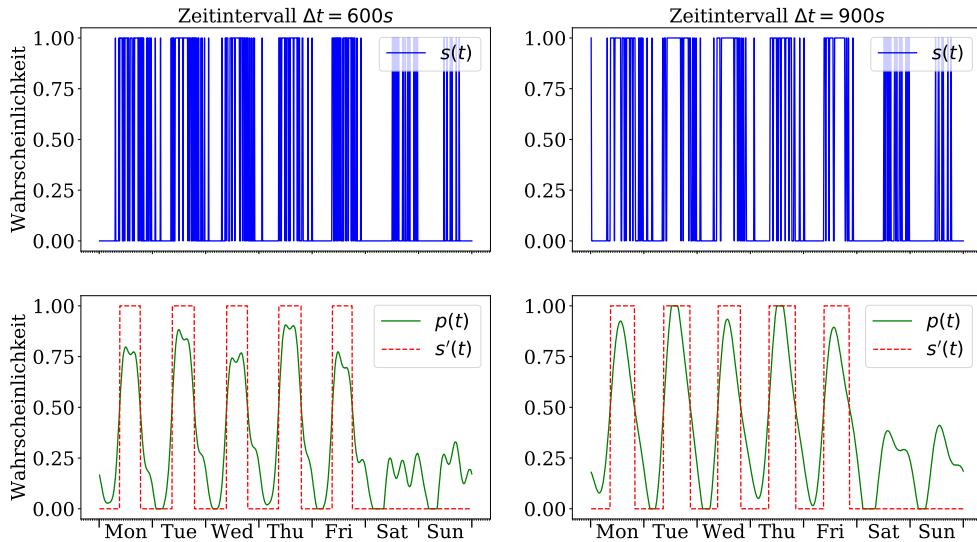


Bild 4.4: Zellzustand $s(t)$ sowie Wahrscheinlichkeitsfunktion $p(t)$ und prognostizierter Zellzustand $s'(t)$ einer Beispielzelle des UOL-Datensatzes mit einer Intervalldauer von $\Delta t = 600 \text{ s}$ (links) und $\Delta t = 900 \text{ s}$ (rechts)

Für die kürzere Intervalldauer $\Delta t = 600 \text{ s}$ liegt die optimale Modellordnung bei $l_{\text{opt}} = 10$ mit einem Prädiktionsfehler von $\epsilon_p = 15.1\%$. Der Prädiktionsfehler des statischen Modells beträgt $\epsilon_p = 28.5\%$. Es ist zu erkennen, dass das Modell den Wochentrend der Daten abbilden kann. An den beiden Wochenendtagen flachen die Amplituden der Wahrscheinlichkeitsfunktion des Zellzustandes $p(t)$ deutlich ab. Da sie den Schwellwert von $c = 0.5$ nicht überschreitet, liegt die Prädiktion des Zellzustandes während des Wochenendes bei $s'(t) = \text{const} = 0.0$. Bei einer Intervalldauer von $\Delta t = 900 \text{ s}$ berechnet sich die optimale Modellordnung zu $l_{\text{opt}} = 7$. Wie in Bild 4.2, resultiert eine Erhöhung der Intervalldauer Δt in einer Vergrößerung der Breite der rot gestrichelten Balken der Prädiktion des Zellzustandes $s'(t)$. Erklären lässt sich dieses Verhalten damit, dass eine Verlängerung der Intervalldauer Δt nach Gleichung 3.5 zu einer Erhöhung des durchschnittlichen Zellzustandes $\bar{s}(t)$ führt. Auch das Modell der größeren Intervalldauer $\Delta t = 900 \text{ s}$ kann den Wochentrend mit einem Abflachen der Personen-Auftrittswahrscheinlichkeiten während des Wochenendes abbilden. Liegt der Prädiktionsfehler der optimalen Modellordnung bei $\epsilon_p = 13.8\%$, so beträgt er bei dem statischen Zustandsmodell $\epsilon_p = 35.3\%$.

Einen zusammenfassenden Überblick der Modellfehler gibt Tabelle 4.2.

Tabelle 4.2: Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern Δt (UOL)

Intervalldauer Δt	ϵ_p bei $l = l_{\text{opt}}$	ϵ_p bei $l = l_{\text{stat}}$
300 s	8.93 %	9.03 %
600 s	10.49 %	11.62 %
900 s	10.75 %	12.92 %

Aufgeteilt nach Intervalllängen, sind hier die Prädiktionsfehler ϵ_p aller Zellen für die optimale Modellordnung l_{opt} sowie für das statische Zustandsmodell aufgelistet. Es werden erneut nur die Zellen betrachtet, welche während mindestens 5 % der betrachteten Zeitintervalle Δt_i belegt waren.

4.4 Quantitatives Modell

In diesem Abschnitt erfolgt eine Evaluation des quantitativen Modells. Betrachtet wird der quantitative Fall, d.h. der betrachtete Wert ist die Personenrate $\lambda(t)$, also die Anzahl von Personen innerhalb eines Zeitintervalls. Veranschaulicht wird dies in Bild 4.5.

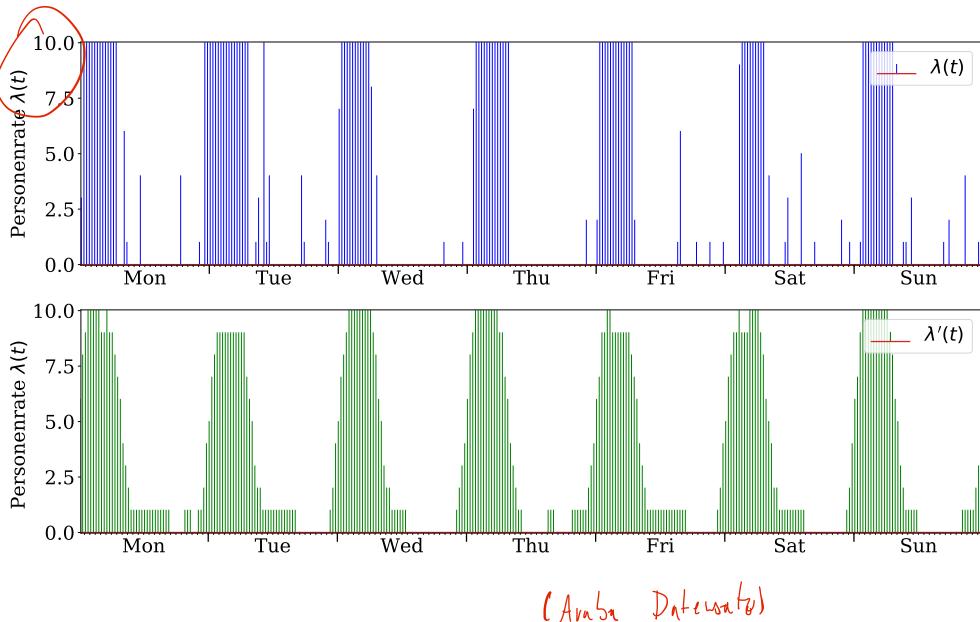


Bild 4.5: Personenrate $\lambda(t)$ des Schlafzimmers bei einer Intervalldauer von $\Delta t = 600\text{s}$ (oben) und Approximation $\lambda'(t)$ (unten)

da es hier keine reale Personenrate wider spiegelt, da es nur eine Person ist

Dargestellt sind die Personenraten $\lambda(t)$ des Schlafzimmers des „Aruba-Datensatzes“ bei einer Intervalldänge von $\Delta t = 600\text{ s}$ (oben). Die optimale Modellordnung zur Berechnung von $\lambda'(t)$, also der Approximation der tatsächlichen Personenrate $\lambda(t)$, liegt bei $l_{\text{opt}} = 5$. Die Approximation ist in der unteren Grafik von Bild 4.5 aufgezeichnet. Der Prädiktionsfehler ergibt sich zu $\epsilon_p = 2.61$. Der Fehler wurde nach dem „least-square mean error“ berechnet. Die von dem Modell prognostizierte Personenrate $\lambda'(t)$ hat also eine durchschnittliche Abweichung von 2.61 Personen pro Intervall von den tatsächlichen Daten. Die statische Personenrate beträgt $\lambda'_{\text{stat}}(t) = 4$. Der Prädiktionsfehler des statischen Modells liegt bei $\epsilon_p = 4.46$.

Bild 4.6 stellt $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 900\text{ s}$ dar. Im Vergleich zu Bild 4.5 liegen die Peaks von $\lambda(t)$ hier höher, was durch die größere Intervalldauer begründet ist. Die untere Grafik von 4.6 stellt erneut die im Sinne von Gleichung 3.16 optimale Approximation $\lambda'(t)$ von $\lambda(t)$ dar. Die optimale Modellordnung liegt erneut bei $l_{\text{opt}} = 5$. Der Prädiktionsfehler liegt hier bei $\epsilon_p = 3.81$. Die Personenrate des statischen Modells lautet $\lambda'_{\text{stat}} = 5$. Der Prädiktionsfehler des statischen Modells beträgt $\epsilon_p = 6.62$.

Im Vergleich zum statischen Modell kann also mit einer Modellordnung von $l_{\text{opt}} = 5$ eine Verbesserung um 43.45 % erreicht werden.

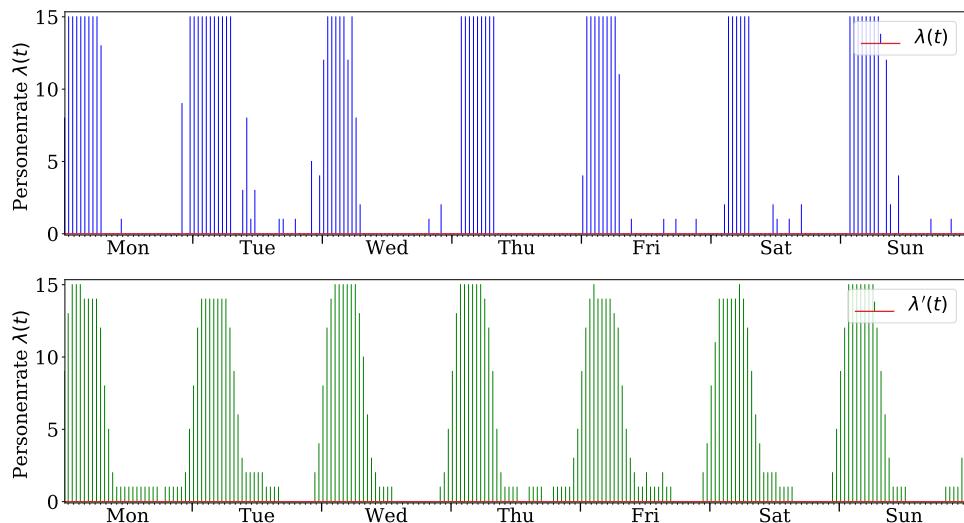


Bild 4.6: Personenrate $\lambda(t)$ des Schlafzimmers bei einer Intervalldauer von $\Delta t = 600\text{ s}$ (oben) und Approximation $\lambda'(t)$ (unten)

Die Personenraten $\lambda(t)$ des Gästeschlafzimmers mit einer Intervalldauer von $\Delta t = 600\text{ s}$ sind in Bild 4.7 aufgezeichnet. Die beste Approximation $\lambda'(t)$ wird hierbei mit einer Ordnung von $l_{\text{opt}} = 0$, also dem statischen Modell, erreicht. Die Prädiktion lautet für alle Intervalle $\lambda'_{\text{stat}}(t) = 0$. Der Prädiktionsfehler beträgt $\epsilon_p = 1.39$.

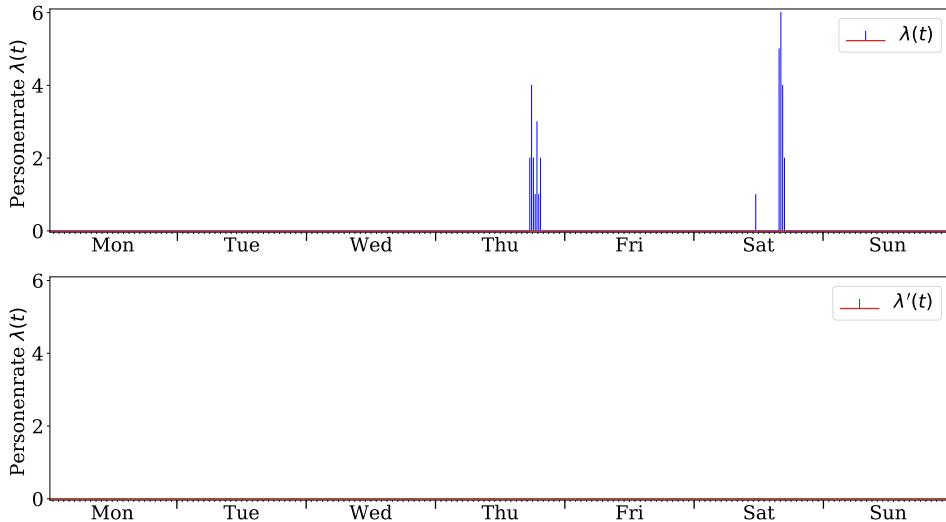


Bild 4.7: Personenrate $\lambda(t)$ des Gästeschlafzimmers bei einer Intervalldauer von $\Delta t = 600\text{ s}$ (oben) und Approximation $\lambda'(t)$ (unten)

Die untere Grafik von Bild 4.8 veranschaulicht $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 900\text{ s}$. Die beste Approximation wird in diesem Fall ebenfalls mit einer Modellordnung von $l_{\text{opt}} = 0$, also dem statischen Modell mit $\lambda'_{\text{stat}}(t) = \text{const}$, erreicht. Die Prädiktion lautet nun für alle Intervalle $\lambda'_{\text{stat}}(t) = 1$. Dies ist dadurch zu begründen, dass die durchschnittliche Personenrate bei größerer Intervalldauer steigt, und somit im Gegensatz zu Bild 4.7 auf die nach Gleichung 3.15 nächstgelegene natürliche Zahl gerundet wird, welche in diesem Fall 1 beträgt.

Der Prädiktionsfehler ergibt sich zu $\epsilon_p = 2.04$. In Tabelle 4.3 sind die durchschnittlichen Prädiktionsfehler der Zellen des Datensatzes bei verschiedenen Intervalldauern aufgeführt. In die Fehlerermittlung flossen nur solche Zellen ein, bei denen in mindestens 5 % der Intervalle eine Person detektiert worden ist.

Erneut zeigt sich wie schon in Abschnitt 4.3 eine Limitation des Modells. Kurzperiodige Folgen von Personenraten $\lambda(t)$ können nicht modelliert werden.

Wie ist es generell bei den anderen Räumen?
Die Plots geben bisher immer nur kleine Ausschnitte wieder
Zumindest einmal könne ich dir Plots aller Räume zeigen

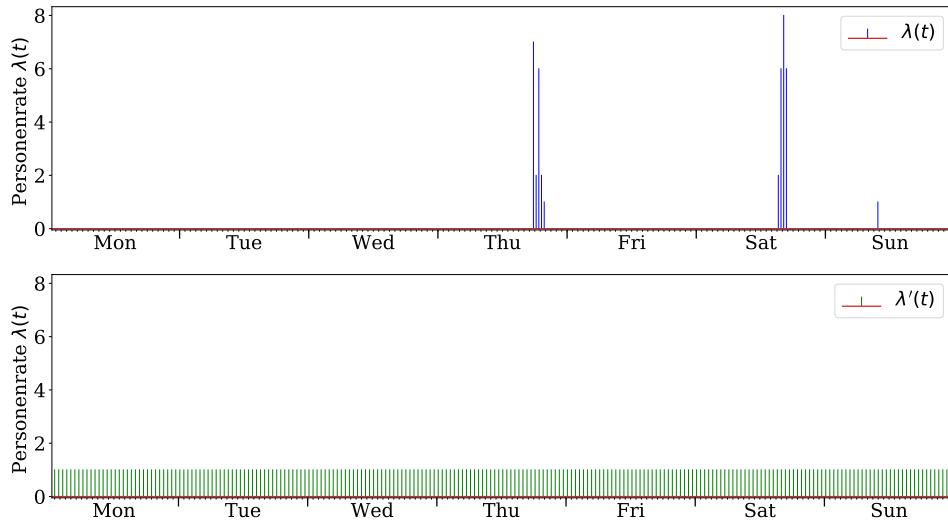


Bild 4.8: Personenrate $\lambda(t)$ des Gästeschlafzimmers bei einer Intervalldauer von $\Delta t = 600$ s (oben) und Approximation $\lambda'(t)$ (unten)

Tabelle 4.3: Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern (Aruba) Δt

Intervalldauer Δt	ϵ_p bei $l = l_{\text{opt}}$	ϵ_p bei $l = l_{\text{stat}}$	Vergleich l_{opt} zu l_{stat}
300 s	1.17	1.43	-18.18 %
600 s	2.23	2.76	-19.20 %
900 s	2.81	3.51	-19.94 %

Eine weitere Evaluation des Modells erfolgt anhand des „UOL-Datensatzes“. Bild 4.9 zeigt die Personenraten $\lambda(t)$ bei einer Intervalldauer von $\Delta t = 600$ s sowie die Prädiktion $\lambda'(t)$ der optimalen Modellordnung $l_{\text{opt}} = 2$ mit einem Prädiktionsfehler von $\epsilon_p = 11.38$.

Dieser, im Vergleich zu dem quantitativen Modell des „Aruba-Datensatzes“, hohe Fehler, lässt sich durch die höhere Varianz der einzelnen Wochen innerhalb des „UOL-Datensatzes“ erklären. Jedoch lassen sich auch hier der Tag-Nacht-Rhythmus sowie ein Abflachen der Personenraten während der beiden Wochenendtage erkennen. Die Annahme einer statischen Rate an Personen von $\lambda'_{\text{stat}}(t) = \text{const.} = 1$ resultiert in einem Prädiktionsfehler von $\epsilon_p = 11.46$. Im Vergleich zum statischen Modell kann also mit einer Modellordnung von $l_{\text{opt}} = 2$ eine Verbesserung um 0.7 % erreicht werden.

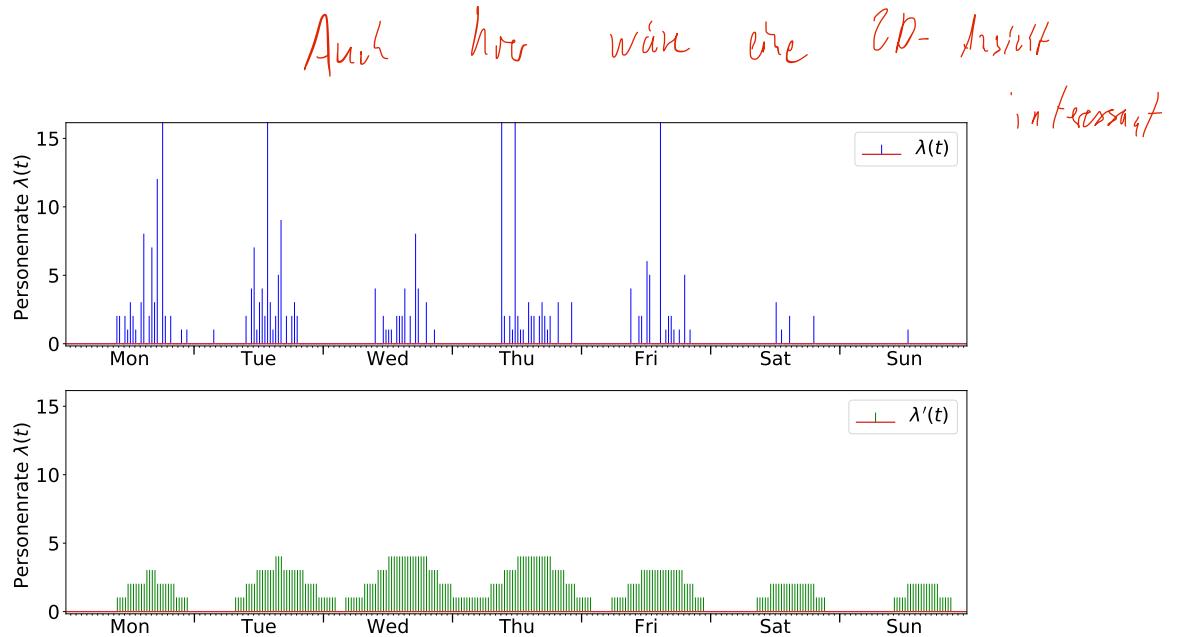


Bild 4.9: Personenraten einer Beispielzelle des UOL Datensatzes bei einer Intervalldauer von $\Delta t = 600\text{ s}$ mit optimaler Modellordnung

Das Modell bei einer Intervalldauer von $\Delta t = 900\text{ s}$ ist in Bild 4.10 dargestellt.

Zu erkennen ist, dass die Personenraten $\lambda(t)$ im Vergleich zu Bild 4.9 höher liegen. Dies ist erneut durch die längere Intervalldauer Δt zu erklären. Für $\Delta t = 900\text{ s}$ liegt die optimale Modellordnung ebenfalls bei $l_{\text{opt}} = 2$, mit einem Prädiktionsfehler von $\epsilon_p = 14.51$. Im Vergleich dazu liegt der Prädiktionsfehler des statischen Modells bei $\epsilon_p = 14.65$, es konnte also eine Verbesserung um 0.95 % erreicht werden.

In Tabelle 4.4 sind die durchschnittlichen Prädiktionsfehler der Zellen des Datensatzes bei verschiedenen Intervalldauern aufgeführt.

Tabelle 4.4: Prädiktionsfehler ϵ_p bei unterschiedlichen Intervalldauern (UOL) Δt

Intervalldauer Δt	ϵ_p bei $l = l_{\text{opt}}$	ϵ_p bei $l = l_{\text{stat}}$	Vergleich l_{opt} zu l_{stat}
300 s	4.80	4.83	-0.63 %
600 s	6.38	6.44	-0.93 %
900 s	6.91	6.99	-1.15 %

Verglichen werden hier erneut die Fehler der Modelle mit einer optimalen Modellordnung, demgegenüber gestellt sind die Prädiktionsfehler ϵ_p der statischen Modelle. In die Fehlerer-

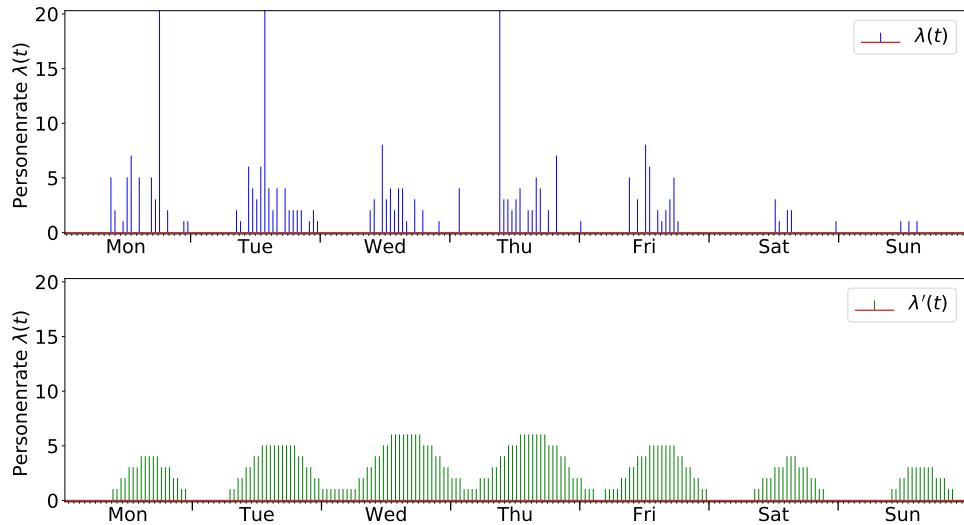


Bild 4.10: Personenraten einer Beispielzelle des UOL Datensatzes bei einer Intervalldauer von $\Delta t = 900$ s mit optimaler Modellordnung

mittlung flossen nur Zellen ein, bei welchen in mindestens 5 % der Intervalle Personendetektionen vorliegen.

Hier auch im
Präses
Schreiben, da
die Bevölkerung
sich auf die
vorliegende
Arbeit bezieht

5 Diskussion und Ausblick

In dieser Arbeit sollte die Darstellung von Personen-Auftrittswahrscheinlichkeiten mittels einer frequenzbasierten Modellierung erfolgen. Zu diesem Zweck wurde eine Server-Client-Struktur mit spezifischer Aufgabenverteilung geschaffen. Den Ausgangspunkt des Modells bildeten dabei Personendetektionen innerhalb eines Belegungsgitters, welches in einzelne Zellen unterteilt wurde. Die Zellinformationen wurden in einer dezentralen Datenbank in einem standardisierten Format gespeichert. Die Datenbankeinträge enthielten neben dem Zeitstempel des Intervalls die korrespondierende Anzahl an Personendetektionen. Es wurde eine Verbindung zwischen dem Client und der Datenbank erstellt. Die Daten wurden vom Client eingelesen und je nach betrachtetem Modell, welches dem binären oder dem quantitativen Fall entsprechen konnte, aufbereitet. ^{Basis sind darunter das} und das zugrunde liegende Belegungsgitter rekonstruiert. Die Daten wurden in einem weiteren Schritt in einen Trainings- und Testdatensatz eingeteilt und an den Server geschickt. Auf diesem erfolgte eine Untersuchung der Frequenzspektren der Daten. Für jede Zelle des Belegungsgitters wurde ein separates Modell erstellt. Mittels der FreMEn-Methode wurde eine vorher festgelegte Anzahl an prominenten Frequenzen identifiziert und zur Rekonstruktion der Personendetektions-Daten verwendet. Die Evaluation dieses rekonstruierten Modells erfolgte anhand eines Testdatensatzes, welcher nicht zur Erstellung des Modells verwendet wurde. Sowohl für den binären wie auch den quantitativen Fall konnte durch die Modellierung der Personen-Auftrittswahrscheinlichkeiten durch eine Superposition periodischer Funktionen eine Genauigkeitssteigerung gegenüber statischen Modellen, welche die Personen-Auftrittswahrscheinlichkeiten als zeitlich konstante Funktion approximieren, nachgewiesen werden. Die Höhe der Genauigkeitssteigerung variierte dabei jedoch stark je nach betrachtetem Datensatz. Für binäre Modelle konnte eine Genauigkeitssteigerung von bis zu 9.02 Prozentpunkten erreicht werden (vgl. Tabelle 4.1). Es wurden jedoch auch Limitationen des Modells sichtbar. Für Zellen, welche eine geringe Anzahl an Personendetektionen vorwiesen, konnten mit einer maximalen Anzahl periodischer Prozesse von $l_{\max} = 20$ diese hochfrequenten Ereignisse nicht modelliert werden. Eine weitere Erhöhung der Anzahl periodischer Prozesse resultiert in einem Verlust der Generalisierungsfähigkeit des Modells für Daten, welche nicht zur Modellerstellung verwendet wurden. Zellen, für welche beispielsweise nur innerhalb von fünf Prozent aller Zeitintervalle Personendetektionen ermittelt wurden, werden durch das statische Modell bereits mit einer Genauigkeit von bis zu 95 % dargestellt. Eine frequenzbasierte Modellierung

der Personen-Auftrittswahrscheinlichkeiten ist demnach nur auf Zellen anwendbar, welche eine gewisse Häufigkeit an Personendetektionen aufweisen.

Auch für den quantitativen Fall konnte durch eine frequenzbasierte Modellierung der Personenraten λ eine Steigerung der Prädiktionsgenauigkeit gegenüber einer statischen Modellierung erreicht werden. Erneut ist die Höhe der Genauigkeitssteigerung stark vom jeweils betrachteten Datensatz abhängig. Gegenüber dem statischen Modell konnte der Prädiktionsfehler um bis zu ~~19.94 %~~ reduziert werden (vgl. Tabelle 4.3).

Im Hinblick auf die frequenzbasierte Modellierung zur Prädiktion von Auftrittswahrscheinlichkeiten von Personen ergeben sich weiterführende Fragestellungen. So ist eine zeitliche Aktualisierung des Modells nötig. Einen Lösungsansatz stellt hierfür die Neuberechnung des Modells in festgeschriebenen Intervallen dar. So können die Modelle in einem wöchentlichen Takt unter Berücksichtigung von neuen, vom Roboter aufgezeichneten Daten, aktualisiert werden. Als Trainingsdaten könnten hierfür beispielsweise die Detektionen der letzten Wochen $[n, \dots, n - l]$ benutzt werden. Die Evaluierung erfolgt dann anhand der Daten der letzten l Wochen.

Eine weitere Fragestellung bildet die Unvollständigkeit der Detektionsdaten. Für die in dieser Arbeit behandelten Datensätze konnte der mobile Roboter die gesamte Umgebung \mathcal{U} überblicken. Die von ihm aufgezeichneten Informationen des zeitlichen Verlaufes der Belegtheit, bzw. Nichtbelegtheit von Zellen, ist also vollständig. In der Realität kann der Roboter die Umgebung jedoch nicht vollständig überblicken, des Weiteren steht eine dauerhafte statische Positionierung zum Aufnehmen von Personendetektionen im Widerspruch der weiteren Aufgaben eines Service-Roboters. Die Aufenthaltsdauer des Roboters auf dem Umgebungsgebiet ist ungleich verteilt. Für Bereiche mit einem längeren Aufenthalt kann eine genauere Schätzung der Personen-Auftrittswahrscheinlichkeiten abgegeben werden als für Bereiche, in denen sich der Roboter nur selten aufhält.

Die Unvollständigkeit der Daten ist zu berücksichtigen. Die tatsächlichen Daten sind durch Wahrscheinlichkeitsverteilungen zu approximieren. Die so ermittelten Daten bilden dann erneut die Eingangsgrößen des in dieser Arbeit vorgestellten Modells ab.

* wie? ?

Literaturverzeichnis

- [Bun20] BUNDESVERBAND GEOTHERMIE (Hrsg.): *Das Nyquist-Shannonsche Abtasttheorem.* Version: 2020. <https://www.geothermie.de/bibliothek/lexikon-der-geothermie/a/abtasttheorem.html>
- [EKS06] EICHLER, Hans J. ; KRONFELDT, Heinz-Detlef ; SAHM, Jürgen: *Das neue physikalische Grundpraktikum.* Zweite, erweiterte und aktualisierte Auflage. Berlin : Springer, 2006 (Springer-Lehrbuch). <http://dx.doi.org/10.1007/3-540-29968-8>. – ISBN 9783540299684
- [HSB02] HAHNEL, D. ; SCHULZ, D. ; BURGARD, W.: Map building with mobile robots in populated environments. In: *IEEE/RSJ International Conference on Intelligent Robots and System*, IEEE, 30 Sept.-5 Oct. 2002. – ISBN 0-7803-7398-7, S. 496–501
- [JWHK16] JOVAN, Ferdian ; WYATT, Jeremy ; HAWES, Nick ; KRAJNIK, Tomas: A Poisson-spectral model for modelling temporal patterns in human data observed by a robot. In: *2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* (2016), S. 4013–4018. <http://dx.doi.org/10.1109/iros.2016.7759591>. – DOI 10.1109/iros.2016.7759591
- [KFC⁺14] KRAJNIK, Tomas ; FENTANES, Jaime P. ; CIELNIAK, Grzegorz ; DONDRUP, Christian ; DUCKETT, Tom: Spectral analysis for long-term robotic mapping. In: *IEEE International Conference on Robotics and Automation (ICRA)*, 2014. Piscataway, NJ : IEEE, 2014. – ISBN 978-1-4799-3685-4, S. 3706–3711
- [KFSD] KRAJNIK, Tomas ; FENTANES, Jaime P. ; SANTOS, Joao M. ; DUCKETT, Tom: FreMEn: Frequency Map Enhancement for Long-Term Mobile Robot Autonomy in Changing Environments. <http://dx.doi.org/10.1109/TRO.2017.2665664>. – DOI 10.1109/TRO.2017.2665664, S. 964–977
- [KKM⁺15] KRAJNIK, Tomas ; KULICH, Miroslav ; MUDROVA, Lenka ; AMBRUS, Rares ; DUCKETT, Tom: Where's waldo at time t ? using spatio-temporal models for

- mobile robot search. In: *2015 IEEE International Conference on Robotics and Automation (ICRA 2015)*. Piscataway, NJ : IEEE, 2015. – ISBN 978–1–4799–6923–4, S. 2140–2146
- [KSD15] KRAJNIK, Tomas ; SANTOS, Joao M. ; DUCKETT, Tom: Life-long spatio-temporal exploration of dynamic environments. In: *2015 European Conference on Mobile Robots (ECMR)* (2015), S. 1–8. <http://dx.doi.org/10.1109/ecmr.2015.7324052>. – DOI 10.1109/ecmr.2015.7324052
- [LN03] LAKEMEYER, Gerhard (Hrsg.) ; NEBEL, Bernhard (Hrsg.): *Exploring artificial intelligence in the new millennium*. San Diego, CA : Morgan Kaufmann Publishers, 2003 <http://www.loc.gov/catdir/description/els031/2002104301.html>. – ISBN 1558608117
- [MMM08] MONTESANO, Luis ; MINGUEZ, Javier ; MONTANO, Luis: Modeling dynamic scenarios for local sensor-based motion planning. In: *Autonomous Robots* 25 (2008), Nr. 3, S. 231–251. <http://dx.doi.org/10.1007/s10514-008-9092-9>. – DOI 10.1007/s10514-008-9092-9. – ISSN 0929–5593
- [MTM⁺20] MARVIN STÜDE ; TIMO LERCHE ; MARTIN ALEXANDER PETERSEN ; MORITZ SCHAPPLER ; TOBIAS ORTMAYER: Behavior Tree-Based Person Search for Symbiotic Autonomous Mobile Robot Tasks. In: *2020*. 2020
- [MW10] MILFORD, Michael ; WYETH, Gordon: Persistent Navigation and Mapping using a Biologically Inspired SLAM System. In: *The International Journal of Robotics Research* 29 (2010), Nr. 9, S. 1131–1153. <http://dx.doi.org/10.1177/0278364909340592>. – DOI 10.1177/0278364909340592. – ISSN 0278–3649
- [TT14] TESCHL, Gerald ; TESCHL, Susanne: *Mathematik für Informatiker: Band 2: Analysis und Statistik*. 3., überarb. Aufl. Berlin : Springer, 2014 (eXamen.press). <http://dx.doi.org/10.1007/978-3-642-54274-9>. – ISBN 9783642542749
- [WA05] WENDEMUTH, Andreas ; ANDELIC, Edin: *Grundlagen der digitalen Signalverarbeitung: Ein mathematischer Zugang*. Berlin, Heidelberg : Springer-Verlag Berlin Heidelberg, 2005 (Springer-Lehrbuch). <http://dx.doi.org/10>.

1007/b138044. <http://dx.doi.org/10.1007/b138044>. – ISBN
9783540267706